

Universiteti i Tiranës
Fakulteti i Shkencave të Natyrës
Departamenti i Fizikës

Simulim dhe Metoda Numerike

Leksione të shkruara

Bachelor në Fizikë dhe Shkenca Kompjuterike

Prof. Asoc. Dr. Klaudio Peqini

Viti akademik 2026–2027

Parathënie

Ky tekst përmbledh në një tërësi koherente përmbajtjen e lëndës *Simulim dhe Metoda Numerike*, me 30 orë leksione dhe 30 orë laborator. Ai vazhdon filozofinë e kursit *Modelim në Fizikë*: nga pyetja fizike te modeli matematik, nga modeli te algoritmi dhe nga algoritmi te një eksperiment numerik i verifikueshëm e i riprodhueshëm. Theksi i ri vendoset te gabimi numerik, kampionimi, simulimi stokastik dhe metodat Monte Carlo.

Teksti nuk e lidh metodën shkencore me një gjuhë të vetme programimi. Shembujt mund të realizohen në Python ose MATLAB/Octave. Notebook-u përdoret për të bashkuar shpjegimin, kodin, figurat dhe interpretimin; funksionet dhe paketat përdoren për kod të ripërdorshëm. Termat *bredhje*, *statistike* dhe *pacaktueshmëri* përdoren në mënyrë të njëtrajtshme në të gjithë tekstin.



Figura 1: Cikli i punës në simulimin fizik. Rezultati kthehet te pyetja fillestare përmes verifikimit dhe vleftësimit.

Si të përdoret ky tekst

Çdo kapitull përmban objektiva, teori, derivime, shembuj fizikë, algoritme, analizë të gabimit dhe lidhje me laboratorin. Leximi nuk duhet të reduktohet në ndjekjen e formulave. Për çdo metodë përdorni ritmin e mëposhtëm:

1. formuloni pyetjen fizike dhe përcaktoni madhësinë që kërkohet;
2. deklaroni supozimet dhe nxirrni modelin matematik;
3. derivoni algoritmin dhe rendin e gabimit;
4. parashikoni sjelljen para ekzekutimit të kodit;
5. verifikoni zbatimin me rast analitik, ligj ruajtjeje ose studim konvergjence;
6. ndryshoni vetëm një parametër dhe interpretoni ndryshimin;
7. ruani kodin si skript dhe ekzekutojeni jashtë notebook-ut.

Në notebook-un përkatës, Seksioni 7 paraqet shembullin e plotë të zgjidhur, ndërsa Seksioni 8 është punishte eksploruese. Shembulli i plotë është pjesa themelore; punishtja përdoret për ndjeshmëri, regjime kufitare dhe pyetje “çfarë ndodh nëse?”. Python përdoret për zbatimin kryesor, ndërsa GNU Octave për të dalluar idenë numerike nga sintaksa e një gjuhe të vetme.

Kur paraqitet një rezultat numerik, studenti duhet të jetë në gjendje të përgjigjet: cilin model po zgjidhim, me cilën metodë, me çfarë gabimi, si u verifikua dhe brenda cilave kufizime fizike është i besueshëm?

Përmbajtja

1	Hyrje në simulimet fizike dhe programimin shkencor	1
1.1	Nga modeli të eksperimenti numerik	1
1.2	Hierarkia e modeleve	1
1.3	Diskretizimi	2
1.4	Programimi shkencor	2
1.5	Verifikimi, vleftësimi dhe riprodhueshmëria	2
1.6	Algoritmi bazë i një eksperimenti numerik	2
2	Aritmetika kompjuterike dhe analiza e gabimeve	7
2.1	Përfaqësimi me saktësi të fundme	7
2.2	Gabimi absolut dhe relativ	7
2.3	Anulimi dhe humbja e shifrave	8
2.4	Kushtëzimi i problemit	8
2.5	Gabimi i përpamë dhe i prapmë	8
2.6	Gabimet matricore	9
2.7	Algoritmet për diagnostikimin e gabimeve numerike	9
3	Ekuacionet jolineare, sistemet lineare dhe vlerat vetjake	14
3.1	Ekuacioni skalar $f(x) = 0$	14
3.2	Sistemet jolineare	15
3.3	Sistemet lineare	15
3.4	Vlerat dhe vektorët vetjakë	16
3.5	Renditja e faqeve si problem vetjak	16
3.6	Algoritmet kryesore dhe zbatimi në Python	17
4	Interpolimi, regresi dhe përshtatja e modeleve	22
4.1	Interpolimi polinomial	22
4.2	Interpolimi Hermitian dhe ekstrapolimi	22
4.3	Regresi linear	23
4.4	Mbetjet dhe diagnostika	23
4.5	Shmangiet minimale absolute	24
4.6	Algoritmet e interpolimit dhe përshtatjes	24
5	Diferencimi dhe integrimi numerik	29
5.1	Derivatet nga zhvillimi Taylor	29
5.2	Hapi optimal	29
5.3	Kuadratura e përbërë	30
5.4	Kuadratura e Gausit	30
5.5	Integrale të papërshtatshme dhe shumëfishta	31
5.6	Algoritmet e diferencimit dhe kuadraturës	31
6	Ekuacionet diferenciale dhe dinamika numerike	36
6.1	Problemi i vlerës fillestare	36

6.2	Stabiliteti	36
6.3	Metodat me shumë hapa	37
6.4	Dinamikë Hamiltoniane	37
6.5	Shembuj fizikë	37
6.6	Problemet e vlerave kufitare	38
6.7	Integruesit kohorë në Python	38
7	Diferencat e fundme dhe simulimi i valëve	43
7.1	Nga PDE te rrjeti	43
7.2	Kushtet fillestare dhe kufitare	43
7.3	Stabiliteti CFL	43
7.4	Dispersimi numerik	44
7.5	Valët e qëndrueshme	44
7.6	Reflektimi nga plazma	45
7.7	Algoritmi me diferenca të fundme për valën	45
8	Probabiliteti dhe variablat e rastit	50
8.1	Ngjarjet dhe probabiliteti	50
8.2	Ndryshoret e rastit	50
8.3	Shpërndarje të rëndësishme	51
8.4	Kovarianca dhe përhapja e pacaktueshmërisë	51
8.5	Ligji i numrave të mëdhenj dhe CLT	51
8.6	Algoritmet bazë të simulimit probabilistik	52
9	Numrat pseudorastësorë dhe kampionimi	57
9.1	Pseudo-rastësia	57
9.2	Testet statistike	58
9.3	Transformimi i anasjelltë	58
9.4	Mostrat Gauss	58
9.5	Kampionimi me refuzim	58
9.6	Kampionimi i rëndësishëm	59
9.7	Algoritmet e gjenerimit dhe kampionimit	59
10	Integrimi Monte Carlo	64
10.1	Integrali si pritje	64
10.2	Shembulli gjeometrik i π	64
10.3	Gabimi statistik	64
10.4	Reduktimi i variancës	65
10.5	Integrale shumëfishta dhe rajone të ndërlikuara	66
10.6	Përhapja Monte Carlo e pacaktueshmërisë	66
10.7	Algoritmet Monte Carlo në Python	66
11	Bredhjet e rastit, difuzioni dhe zinxhirët Markov	71
11.1	Bredhja simetrike në një përmasë	71
11.2	Kufiri i vazhdueshëm dhe difuzioni	71
11.3	Kufij, drift dhe kohë e parë kalimi	72
11.4	Zinxhirët Markov	72
11.5	Kthyeshmëria dhe balanca e detajuar	73
11.6	Korrelacioni dhe madhësia efektive	73
11.7	Algoritmet e bredhjes dhe të zinxhirit Markov	73
12	Metropolis–Hastings dhe Monte Carlo në fizikën statistike	78
12.1	Pse nevojitet MCMC	78
12.2	Algoritmi Metropolis–Hastings	78

12.3	Termalizimi dhe diagnostika	79
12.4	Modeli Ising dydimensional	79
12.5	Observatlat termodinamike	79
12.6	Algoritmi Metropolis për modelin Ising	80
A	Fjalorth, standarde të kodit dhe ura drejt notebook-eve	86
A.1	Fjalorth i termave kryesorë	86
A.2	Emërtimi i madhësive në kod	87
A.3	Struktura standarde e çdo notebook-u	88
A.4	Kontrollet minimale të cilësisë	88
A.5	Lidhja ndërmjet kapitujve dhe laboratorëve	88
A.6	Parimi i kalimit nga notebook-u te paketa	89
A.7	Udhëzues i burimeve shkencore në shqip	89
A.8	Rruga e rekomanduar e leximit	90
A.9	Parime për citimin në notebook	91

Kapitulli 1

Hyrje në simulimet fizike dhe programimin shkencor

Rezultatet e të nxënit. Studenti dallon sistemin real, modelin matematik, algoritmin dhe kodin; formulon hyrjet, daljet dhe supozimet; dallon simulimin determinist nga ai stokastik; organizon një eksperiment të riprodhueshëm në Python ose MATLAB/Octave.

Orientim për studim. Ky kapitull duhet lexuar si një hartë e gjithë lëndës. Ndiqni zinxhirin *dukuri fizike* $\rightarrow$ *idealizim* $\rightarrow$ *ekuacione* $\rightarrow$ *diskretizim* $\rightarrow$ *algoritëm* $\rightarrow$ *kod* $\rightarrow$ *verifikim* $\rightarrow$ *interpretim*. Në fund, përdorni rënien në ajër si shembull të plotë dhe ndryshoni vetëm një supozim të modelit për të kuptuar dallimin ndërmjet modelimit dhe programimit.

1.1 Nga modeli te eksperimenti numerik

Një simulim fizik është një eksperiment i kryer mbi një model. Ai nuk fillon me kodin, por me një pyetje: cilën madhësi kërkojmë, në çfarë kushtesh dhe me çfarë saktësie? Sistemi real përmban më shumë hollësi sesa mund të përfaqësohen. Modelimi zgjedh mekanizmat dominues, ndërsa simulimi zbaton pasojat e kësaj zgjedhjeje.

Një problem dinamik mund të shkruhet në formën

$$\frac{d\mathbf{y}}{dt} = \mathbf{f}(t, \mathbf{y}; \boldsymbol{\theta}), \quad \mathbf{y}(t_0) = \mathbf{y}_0, \quad (1.1)$$

ku $\mathbf{y}$ është gjendja dhe $\boldsymbol{\theta}$ përmbledh parametrat. Për një grimcë në një përmasë, $\mathbf{y} = (x, v)^T$. Në një model stokastik, evolucioni varet edhe nga një ndryshore rasti ξ_n ,

$$\mathbf{Y}_{n+1} = \mathbf{G}(t_n, \mathbf{Y}_n; \boldsymbol{\theta}, \xi_n). \quad (1.2)$$

Një ekzekutim determinist jep të njëjtën trajektore për të njëjtat hyrje; një ekzekutim stokastik jep një realizim. Përfundimi stokastik merret nga bashkësia e realizimeve.

1.2 Hierarkia e modeleve

Modelet ndërtohen në nivele. Modeli minimal izolon mekanizmin kryesor dhe lehtëson kontrollin analitik. Modeli i zgjeruar shton fërkim, forcë të jashtme, zhurmë ose gjeometri reale. Modeli më kompleks nuk është domosdoshmërisht më i mirë: ai kërkon më shumë parametra, të dhëna dhe prova vleftësimi.

Shembull Rënia e lirë. Pa rezistencë ajri, $y(t) = y_0 + v_0 t - gt^2/2$. Ky rast ka zgjidhje analitike dhe përdoret për verifikim. Me rezistencë lineare, $m\dot{v} = -mg - cv$; me rezistencë kuadratiqe, $m\dot{v} = -mg - cv|v|$. Zgjedhja ndërmjet tyre është vendim fizik, jo programues.

1.3 Diskretizimi

Kompjuteri ruan një numër të fundmë vlerash. Koha zëvendësohet nga rrjeti

$$t_n = t_0 + n\Delta t, \quad n = 0, 1, \dots, N. \quad (1.3)$$

Hapi Δt kontrollon rezolucionin dhe koston. Një hap më i vogël zakonisht ul gabimin e këputjes, por rrit numrin e veprimeve dhe mund të ekspozojë gabimin e rrumbullakimit. Përzgjedhja e hapit duhet të mbështetet në një studim konvergjence.

1.4 Programimi shkencor

Programimi shkencor e kthen arsyetimin në një procedurë që mund të përsëritet. Një notebook i mirë përmban: pyetjen fizike; supozimet; parametrat dhe njësitë; funksionet; eksperimentet; figurat; analizën e gabimit; përfundimin. Parametrat nuk duhen fshehur brenda funksioneve. Një funksion duhet të kryejë një detyrë të qartë dhe të kthejë rezultate që mund të testohen.

Tabela 1.1: Dy rrugë teknike me të njëjtin standard shkencor.

Python	MATLAB/Octave
NumPy për vektorë dhe matrica	Vektorë dhe matrica si objekte bazë
Matplotlib për figura	<code>plot</code> dhe funksionet grafike
Funksione dhe module <code>.py</code>	Funksione dhe skripte <code>.m</code>
Jupyter Notebook	Jupyter me kernel Octave ose Live Script

1.5 Verifikimi, vleftësimi dhe riprodhueshmëria

Verifikimi pyet nëse kodi zgjidh saktë ekuacionet e zgjedhura. Vleftësimi pyet nëse ekuacionet përshkruajnë mjaftueshëm sistemin real për qëllimin e deklaruar. Verifikimi përdor zgjidhje analitike, ligje ruajtjeje, teste njësishe dhe konvergjencë. Vleftësimi përdor matje, parametra të kalibruar dhe krahasim me modele alternative.

Riprodhueshmëria kërkon kodin, të dhënat, versionet e paketave, parametrat, farën e gjeneratorit dhe rendin e ekzekutimit. Një figurë pa këto të dhëna është dëshmi e paplotë.

Lidhja me laboratorin. Laboratori 1 ndërton të njëjtin notebook në njërën prej dy gjuhëve. Versioni i instruktorit shërben për shpjegim; versioni i studentit duhet të përmbajë arsyetimin, kodin dhe interpretimin e vet.

Pyetje kontrolli

1. Jepni një shembull ku kodi është i saktë, por modeli fizik është i papërshtatshëm.
2. Pse zvogëlimi i hapit nuk garanton gjithmonë përmirësim?
3. Cilat të dhëna duhen ruajtur për një eksperiment Monte Carlo të riprodhueshëm?

1.6 Algoritmi bazë i një eksperimenti numerik

Algoritmi kryesor i kapitullit nuk është një formulë e vetme, por cikli i plotë i punës. Ai duhet të përdoret në çdo notebook të kursit.

1. Formulohet pyetja fizike dhe përcaktohet madhësia e daljes.
2. Shënohen supozimet, njësitë, parametrat dhe kushtet fillestare.

3. Zgjidhet modeli minimal që mund t'i përgjigjet pyetjes.
4. Përcaktohen rrjeti, algoritmi, toleranca dhe kriteri i ndalimit.
5. Shkruhet kodi si funksione të testueshme.
6. Verifikohet me një rast analitik ose një ligj ruajtjeje.
7. Kryhet studimi i konvergjencës ose i numrit të mostrave.
8. Raportohen rezultati, gabimi numerik, pacaktueshmëria dhe kufijtë e modelit.

1.6.1 Një skelet Python për notebook-un

Listing 1.1: Skelet minimal për një eksperiment numerik.

```
from dataclasses import dataclass
import numpy as np
import matplotlib.pyplot as plt

@dataclass(frozen=True)
class Parametra:
    y0: float = 1.5 # m
    v0: float = 8.0 # m/s
    g: float = 9.81 # m/s2
    t_fund: float = 1.2 # s
    dt: float = 0.02 # s

def modeli_analitik(t, p):
    """Pozicioni vertikal pa rezistence ajri."""
    return p.y0 + p.v0*t - 0.5*p.g*t**2

def eksperiment(p):
    t = np.arange(0.0, p.t_fund + p.dt/2, p.dt)
    y = modeli_analitik(t, p)
    assert np.isclose(y[0], p.y0)
    return t, y

p = Parametra()
t, y = eksperiment(p)
plt.plot(t, y)
plt.xlabel("Koha t [s]")
plt.ylabel("Lartësia y [m]")
plt.grid(alpha=0.25)
plt.show()
```

1.6.2 Kontrolli i riprodhueshmërisë

Për simulime stokastike përdoret një gjenerator i deklaruar, jo gjendja globale e fshehur.

```
rng = np.random.default_rng(2026)
mostra = rng.normal(loc=0.0, scale=1.0, size=10_000)
```

Fara nuk e bën rezultatin “më të rastit”; ajo identifikon realizimin. Në raport shënohen fara, numri i mostrave dhe versionet e bibliotekave.

1.6.3 Terminologji dhe stil shkencor

Në këtë tekst përdoren *zbatim* për implementation, *rrjetë* për grid, *hap* për step, *mbetje* për residual, *vlefësim* për validation dhe *riprodhueshmëri* për reproducibility. Kodi nuk duhet të fshehtë njësitë fizike; ato shënohen në komente, tabela dhe boshte.

Lidhja me laboratorin. Notebook-u i studentit duhet të nisë nga ky skelet dhe të ruajë ndarjen ndërmjet parametrave, modelit, eksperimentit dhe paraqitjes grafike.

Për organizimin terminologjik të modelit, algoritmit dhe zbatimit numerik janë konsultuar tekstet universitare shqip të analizës numerike [1, 2, 3], krahas literaturës ndërkombëtare të fizikës llogaritëse [12, 17].

1.6.4 Nga ligji fizik te algoritmi: një shembull i plotë

Le të ndërtojmë modelin e rënies vertikale me rezistencë lineare të ajrit. Zgjedhim boshtin pozitiv për poshtë dhe shënojmë me $y(t)$ zhvendosjen dhe me $v(t) = \dot{y}(t)$ shpejtësinë. Ligji i dytë i Njutonit jep

$$m\dot{v} = mg - cv, \quad \dot{y} = v, \quad (1.4)$$

ku $m > 0$, $g > 0$ dhe $c \geq 0$. Përmasat fizike janë $[g] = LT^{-2}$ dhe $[c] = MT^{-1}$; prandaj c/m ka përmasën e inversit të kohës. Koha karakteristike $\tau = m/c$ tregon sa shpejt humbet kujtesa e kushtit fillestar. Zgjidhja analitike,

$$v(t) = v_\infty + (v_0 - v_\infty)e^{-t/\tau}, \quad v_\infty = \frac{mg}{c}, \quad (1.5)$$

është një pikë reference për verifikimin e kodit. Ajo nuk përdoret sepse problemi është i vështirë, por sepse na lejon të ndajmë gabimin e algoritmit nga gabimi i modelit.

Me metodën e Eulerit, derivati në t_n zëvendësohet nga diferenca përpara,

$$\dot{v}(t_n) = \frac{v(t_n + h) - v(t_n)}{h} + \mathcal{O}(h). \quad (1.6)$$

Duke neglizhuar termin $\mathcal{O}(h)$ dhe duke shënuar $v_n \approx v(t_n)$ merret

$$v_{n+1} = v_n + h \left(g - \frac{c}{m} v_n \right), \quad y_{n+1} = y_n + h v_n. \quad (1.7)$$

Gabimi lokal i një hapi është $\mathcal{O}(h^2)$, ndërsa grumbullimi në një interval kohor të fiksuar jep gabim global $\mathcal{O}(h)$. Kjo dallon rendin lokal nga rendi global dhe shpjegon pse përgjysmimi i hapit duhet ta përgjysmojë afërsisht gabimin për një metodë të rendit të parë.

Listing 1.2: Eksperiment konvergjence për rënien me rezistencë lineare.

```
import numpy as np

def renie_euler(m, c, g, y0, v0, T, h):
    n = int(np.ceil(T / h))
    h = T / n # hapi rregullohet që t_n të arrijë saktë T
    t = np.linspace(0.0, T, n + 1)
    y = np.empty(n + 1); v = np.empty(n + 1)
    y[0], v[0] = y0, v0
    for k in range(n):
        y[k + 1] = y[k] + h * v[k]
        v[k + 1] = v[k] + h * (g - (c / m) * v[k])
    return t, y, v

def v_sakte(t, m, c, g, v0):
    tau = m / c
    v_inf = m * g / c
    return v_inf + (v0 - v_inf) * np.exp(-t / tau)

for h in (0.2, 0.1, 0.05, 0.025):
    t, y, v = renie_euler(1.0, 0.4, 9.81, 0.0, 0.0, 4.0, h)
    gabimi = np.max(np.abs(v - v_sakte(t, 1.0, 0.4, 9.81, 0.0)))
    print(f"h={h:7.4f}, gabimi maksimal={gabimi:.6e}")
```

Ky program ndan modelin, integruesin dhe testin analitik. Në MATLAB/Octave të njëjtat vargje ndërtohen me `linspace` dhe cikli me `for`; ndryshimi sintaksor nuk ndryshon logjikën shkencore.

1.6.5 Verifikim, vleftësim dhe analizë ndjeshmërie

Një rezultat mund të jetë i konverguar ndaj $h \rightarrow 0$ dhe përsëri të jetë fizikisht i gabuar. Konvergjenca kontrollon vetëm diskretizimin. Për vleftësim duhen të dhëna ose një model referimi. Në shembullin e mësipërm, koeficienti c mund të varet nga forma, dendësia e ajrit dhe regjimi i rrjedhjes. Nëse c është matur me pacaktueshmëri, kjo pacaktueshmëri duhet të përhapet deri te $v(t)$.

Ndjeshmëria lokale ndaj parametrat c mund të vlerësohet me

$$S_c(t) \approx \frac{v(t; c + \Delta c) - v(t; c - \Delta c)}{2\Delta c}. \quad (1.8)$$

Vlera S_c ka njësi dhe varet nga shkalla; një ndjeshmëri pa përmasa është cS_c/v . Në një studim të plotë raportohen veçmas gabimi i diskretizimit, pacaktueshmëria e parametrave dhe mospërputhja model-eksperiment.

1.6.6 Përmbledhje dhe punë e pavarur

Eksperimenti numerik është një zinxhir argumentesh: përkufizim i pyetjes, zgjedhje e modelit, kontroll dimensional, diskretizim, implementim, verifikim dhe interpretim fizik. Studenti duhet të jetë në gjendje të tregojë ku hyn çdo supozim dhe cilin lloj gabimi kontrollon çdo provë.

1. Nxirrni zgjidhjen analitike për $y(t)$ dhe përdoreni për të matur rendin e Eulerit.
2. Zëvendësoni forcën $-cv$ me $-cv|v|$ dhe përcaktoni shpejtësinë kufitare.
3. Ndërtoni të njëjtin eksperiment në MATLAB/Octave dhe krahasoni rezultatet deri në tolerancën e rrumbullakimit.
4. Shpjegoni pse krahasimi me të dhënat eksperimentale është vleftësim, ndërsa krahasimi me zgjidhjen analitike është verifikim.

1.6.7 Analiza pa përmasa dhe projektimi i simulimit

Para se të zgjidhet një metodë numerike, është e dobishme të identifikohen shkallët karakteristike të problemit. Në modelin e rënies me rezistencë lineare,

$$m \frac{dv}{dt} = mg - cv, \quad (1.9)$$

shpejtësia karakteristike është $V = mg/c$ dhe koha karakteristike është $T = m/c$. Duke vendosur $u = v/V$ dhe $\tau = t/T$, ekuacioni bëhet

$$\frac{du}{d\tau} = 1 - u. \quad (1.10)$$

Të tre parametrat dimensionalë janë reduktuar në një ekuacion universal. Kjo formë tregon se çdo trup që i bindet të njëjtit model ka të njëjtën kurbë $u(\tau)$; parametrat vetëm ndryshojnë shkallët e boshteve. Në simulim, analiza pa përmasa ndihmon në zgjedhjen e hapit: $\Delta\tau = \Delta t/T$ duhet të jetë mjaft i vogël për të përshkruar relaksim. Ajo ndihmon edhe në testim, sepse rezultatet për grupe të ndryshme parametrash duhet të bien mbi të njëjtën kurbë të reduktuar.

Në modelin kuadratik $m\dot{v} = mg - cv|v|$, shpejtësia kufitare është $V = \sqrt{mg/c}$ dhe një shkallë kohe është $T = V/g$. Përsëri merret një ekuacion pa përmasa, por struktura jolineare mbetet. Krahasimi i dy modeleve duhet bërë në të njëjtat madhësi të reduktuara; përndryshe ndryshimi i njërive ose i shkallëve mund të ngatërrohet me ndryshim fizik.

Nga kërkesa shkencore te kriteri i pranimit

Një simulim duhet të fillojë me një kërkesë të matshme. Pohimi “të simulohet lavjerrësi” nuk përcakton as produktin, as saktësinë. Një kërkesë operative mund të jetë: “të përcaktohet perioda për $0 \leq \theta_0 \leq 1.2$ rad me gabim relativ nën 10^{-3} dhe të kontrollohet ruajtja e energjisë për

njëqind perioda”. Kjo fjali përcakton madhësinë dalëse, domenin e parametrave, tolerancën dhe një invariant verifikimi.

Kriteri i pranimit nuk duhet të jetë vetëm “kodi ekzekutohet”. Për një metodë të rendit p , raporti

$$R_h = \frac{\|y_h - y_{h/2}\|}{\|y_{h/2} - y_{h/4}\|} \quad (1.11)$$

duhet të afrohet me 2^p në regjimin asimptotik. Nëse kjo nuk ndodh, mund të ketë gabim implementimi, hap ende të madh, zgjidhje jo të lëmuar ose dominim të rrumbullakimit. Kriteret fizike përfshijnë shenjat, kufijtë, njësitë dhe ligjet e ruajtjes. Kriteret statistike përfshijnë përsëritjen me fara të ndryshme dhe intervalin e besimit.

Hierarkia e pacaktueshmërive

Në një raport të plotë dallohen së paku katër nivele. Pacaktueshmëria e hyrjeve vjen nga matjet e parametrave. Gabimi i modelit vjen nga mekanizmat e neglizhuar. Gabimi numerik vjen nga diskretizimi dhe aritmetika me saktësi të fundme. Gabimi i kampionimit vjen nga përdorimi i një numri të fundmë realizimesh. Zvogëlimi i hapit kontrollon vetëm një pjesë të nivelit të tretë; rritja e numrit të mostrave kontrollon vetëm nivelin e katërt. Një grafik me shumë shifra nuk mund të kompensojë një model fizik të papërshtatshëm.

Për laboratorin rekomandohet që çdo notebook të përmbajë një tabelë të shkurtër me kolonat: burimi i pacaktueshmërisë, mënyra e vlerësimit, madhësia e efektit dhe prova e kontrollit. Kjo e kthen notebook-un nga një demonstrim kodi në dokument shkencor.

Kapitulli 2

Aritmetika kompjuterike dhe analiza e gabimeve

Rezultatet e të nxënit. Studenti përshkruan numrat me pikë të lëvizshme; dallon gabimin absolut e relativ, gabimin e përpasmë e të prapmë; analizon kushtëzimin dhe qëndrueshmërinë; njeh anulimin, humbjen e rëndësisë dhe grumbullimin e gabimeve.

Orientim për studim. Qëllimi nuk është të mësohen përmendësh kufijtë e tipave numerikë, por të kuptohet pse një algoritëm matematikisht i saktë mund të japë rezultat të gabuar në kompjuter. Për çdo derivim dalloni: kushtëzimin e problemit, qëndrueshmërinë e algoritmit, gabimin e përpasmë, gabimin e prapmë dhe mbetjen. Eksperimentet me anulimin dhe matricën gati singulare janë provat numerike të këtyre dallimeve.

2.1 Përfaqësimi me saktësi të fundme

Një numër normal binar përfaqësohet si

$$x = (-1)^s (1.b_1 b_2 \dots b_p)_2 2^e. \quad (2.1)$$

Në standardin IEEE 754, formati double ka 53 bita saktësi në mantisë. Distanca relative ndërmjet numrave pranë njësisë është afërsisht 2^{-52} . Madhësia

$$u = \frac{1}{2} \beta^{1-p} \quad (2.2)$$

quhet njësia e rrumbullakimit. Modeli bazë është

$$\text{fl}(x \circ y) = (x \circ y)(1 + \delta), \quad |\delta| \leq u, \quad (2.3)$$

për një veprim $\circ$, me kusht që të mos ndodhë tejmbushje ose nënmbushje.

Numrat **Inf**, **-Inf** dhe **NaN** sinjalizojnë rezultate jashtë bashkësisë së numrave të fundmë ose veprime të papërcaktuara. Krahasimi i numrave realë nuk duhet të mbështetet verbërisht në barazinë bit për bit; përdoret një tolerancë që merr parasysh shkallën e problemit.

2.2 Gabimi absolut dhe relativ

Nëse x është vlera e saktë dhe $\tilde{x}$ përafrimi,

$$e_a = |\tilde{x} - x|, \quad e_r = \frac{|\tilde{x} - x|}{|x|}. \quad (2.4)$$

Gabimi relativ nuk ka kuptim kur $x = 0$ dhe bëhet i paqëndrueshëm pranë zeros. Në vektorë përdoret një normë, për shembull

$$e_r = \frac{\|\tilde{\mathbf{x}} - \mathbf{x}\|_2}{\|\mathbf{x}\|_2}. \quad (2.5)$$

2.3 Anulimi dhe humbja e shifrave

Zbritja e dy numrave pothuaj të barabartë heq shifrat kryesore të përbashkëta dhe zmadhon gabimin relativ të mbetjes. Shprehja $\sqrt{x+1} - \sqrt{x}$ për $x \gg 1$ llogaritet më mirë si

$$\frac{1}{\sqrt{x+1} + \sqrt{x}}. \quad (2.6)$$

Të dyja janë algjebrikisht të njëjta, por jo numerikisht të barasvlershme.




Figura 2.1: Gabimi i shkaktuar nga anulimi kur x bëhet i krahasueshëm me saktësinë e makinës.

Kujdes numerik. Renditja e veprimeve ka rëndësi. Në një shumë me terma me madhësi shumë të ndryshme, termat e vegjël mund të humbasin. Mbledhja nga moduli më i vogël te më i madhi ose algoritmi Kahan redukton humbjen.

2.4 Kushtëzimi i problemit

Kushtëzimi është veti e problemit matematik. Për $y = f(x)$, numri relativ i kushtëzimit lokal është

$$\kappa_f(x) = \left| \frac{x f'(x)}{f(x)} \right|. \quad (2.7)$$

Në sistemin $Ax = b$,

$$\frac{\|\delta x\|}{\|x\|} \lesssim \kappa(A) \frac{\|\delta b\|}{\|b\|}, \quad \kappa(A) = \|A\| \|A^{-1}\|. \quad (2.8)$$

Një matricë me $\kappa \gg 1$ është e keqkushtëzuar: perturbime të vogla në të dhëna mund të prodhojnë ndryshime të mëdha në zgjidhje.

2.5 Gabimi i përparmë dhe i prapëm

Gabimi i përparmë mat distancën ndërmjet rezultatit numerik dhe zgjidhjes së saktë. Analiza e prapme kërkon problemin pak të perturbur që zgjidhet saktësisht nga rezultati i llogaritur. Një algoritëm është i qëndrueshëm në kuptimin e prapëm nëse perturbimi i kërkuar është i vogël. Marrëdhënia konceptuale është

$$\text{gabimi i përparmë} \lesssim \text{kushtëzimi} \times \text{gabimi i prapëm}. \quad (2.9)$$

Prandaj, edhe algoritmi më i mirë nuk mund ta shpëtojë një problem intrinsikisht të keqkushtëzuar.




Figura 2.2: Rritja e numrit të kushtëzimit kur dy rreshta të matricës bëhen pothuaj linearë të varur.

2.6 Gabimet matricore

Shumëzimi matricor kryen shumë mbledhje dhe shumëzime. Kufiri klasik për një produkt skalar me n terma ka faktor

$$\gamma_n = \frac{nu}{1 - nu} \approx nu. \quad (2.10)$$

Invertimi eksplisit i matricës për të zgjidhur $A\mathbf{x} = \mathbf{b}$ është zakonisht më i shtrenjtë dhe më pak i qëndrueshëm se faktorizimi i drejtpërdrejtë. Në kod përdoret operatori i zgjidhjes, jo $A^{-1}\mathbf{b}$.

Shembull Shuma e energjive. Nëse energjia totale merret si diferencë e dy energjive të mëdha, gabimi relativ mund të jetë i lartë edhe kur secila energji është llogaritur me shumë shifra. Një formulim që llogarit drejtpërdrejt madhësinë e vogël mund të jetë numerikisht më i sigurt.

Lidhja me laboratorin. Në laborator maten u , anulimi dhe ndikimi i rendit të mbledhjes. Pastaj ndërtohet një familje sistemesh 2×2 dhe krahasohet gabimi i zgjidhjes me $\kappa(A)$.

Pyetje kontrolli

1. Dalloni një problem të keqkushtëzuar nga një algoritëm i paqëndrueshëm.
2. Pse $A^{-1}\mathbf{b}$ nuk është mënyra e rekomanduar për të zgjidhur sistemin?
3. Jepni një reformulim që shmang anulimin katastrofik.

2.7 Algoritmet për diagnostikimin e gabimeve numerike

Qëllimi praktik është të dallohen katër burime: gabimi i të dhënave, kushtëzimi i problemit, gabimi i algoritmit dhe rrumbullakimi. Një diagnozë e mirë ndryshon vetëm një faktor në çdo provë.

2.7.1 Matja e saktësisë së makinës

Listing 2.1: Vlerësimi empirik i distancës pranë njësisë.

```
eps = 1.0
while 1.0 + eps/2.0 != 1.0:
    eps /= 2.0
print(eps, np.finfo(float).eps)
```

Vlera e marrë është epsilon-i i makinës sipas konventës së NumPy. Njësia e rrumbullakimit është afërsisht gjysma e saj.

2.7.2 Shuma Kahan

Në mbledhjen e shumë termave, një kompensim ruan pjesën e humbur nga rrumbullakimi.

Listing 2.2: Mbledhja e kompensuar Kahan.

```
def shuma_kahan(x):
    s = 0.0
    c = 0.0
    for value in x:
        y = value - c
        t = s + y
        c = (t - s) - y
        s = t
    return s

x = np.r_[1e16, np.ones(1_000_000), -1e16]
print(np.sum(x), shuma_kahan(x))
```

Ky test duhet përsëritur me renditje të ndryshme. Rezultati tregon se asociativiteti algjebrik nuk ruhet plotësisht në pikë të lëvizshme.

2.7.3 Kushtëzimi dhe mbetja

Listing 2.3: Krahassimi i gabimit me mbetjen.

```
def diagnostiko(A, b, x_ref):
    x = np.linalg.solve(A, b)
    mbetja = np.linalg.norm(b - A @ x) / np.linalg.norm(b)
    gabimi = np.linalg.norm(x - x_ref) / np.linalg.norm(x_ref)
    return np.linalg.cond(A), mbetja, gabimi

for e in [1e-2, 1e-6, 1e-10]:
    A = np.array([[1.0, 1.0], [1.0, 1.0 + e]])
    x_ref = np.array([1.0, 1.0])
    b = A @ x_ref
    print(e, diagnostiko(A, b, x_ref))
```

Mbetja mund të mbetet e vogël edhe kur gabimi i zgjidhjes rritet. Prandaj raportohen të dyja bashkë me $\kappa(A)$.

2.7.4 Algoritmi i auditimit

1. Përcaktohet një zgjidhje reference me saktësi të lartë ose analitike.
2. Ndryshohet hapi, toleranca ose rendi i veprimeve.
3. Vizatohet gabimi në shkallë logaritmike.
4. Kontrollonhet pjerrësia e pritur e konvergjencës.
5. Përsëritet me të dhëna pak të perturbura për të matur kushtëzimin.

Terminologjia *gabim i përparmë*, *gabim i prapëm*, *kushtëzim* dhe *qëndrueshmëri* përdoret sipas traditës së analizës numerike në shqip, veçanërisht në tekstet e Hanellit–Osmanit dhe Hoxhës.

Për trajtimin në shqip të gabimeve, sistemeve lineare dhe qëndrueshmërisë janë përdorur [1, 2, 3]; analiza moderne e qëndrueshmërisë krahasohet me [16].

2.7.5 Modeli standard i rrumbullakimit dhe përhapja e gabimit

Le të jetë $\text{fl}(x)$ numri i përfaqësueshëm më i afërt me x . Për numrat normalë dhe rrumbullakimin drejt më të afërtit shkruhet

$$\text{fl}(x) = x(1 + \delta), \quad |\delta| \leq u. \quad (2.11)$$

Ky model është relativ dhe prandaj nuk përshkruan drejtpërdrejt sjelljen pranë nënmbushjes. Për një varg veprimesh, çdo hap fut një faktor të ri $(1 + \delta_i)$. Prodhimi plotëson

$$\prod_{i=1}^n (1 + \delta_i) = 1 + \theta_n, \text{ ku } |\theta_n| \leq \gamma_n = \frac{nu}{1 - nu}, \quad (2.12)$$

kur $nu < 1$. Formula $\gamma_n \simeq nu$ është e dobishme, por nuk duhet interpretuar si parashikim i saktë i gabimit: ajo është kufi në rastin më të pafavorshëm.

Për $f(x_1, \dots, x_p)$, linearizimi jep

$$\Delta f \simeq \sum_{j=1}^p \frac{\partial f}{\partial x_j} \Delta x_j. \quad (2.13)$$

Nëse perturbimet trajtohen si të pavarura me devijime standarde σ_j , përhapja probabilitare e rendit të parë është

$$\sigma_f^2 \simeq \sum_{j=1}^p \left(\frac{\partial f}{\partial x_j} \right)^2 \sigma_j^2, \quad (2.14)$$

ndërsa për hyrje të korreluara shfaqen termat $2(\partial_i f)(\partial_j f) \text{Cov}(x_i, x_j)$. Analiza deterministe e rrumbullakimit dhe përhapja probabilitare e pacaktueshmërisë nuk janë e njëjta gjë, megjithëse përdorin të njëjtin mjet të linearizimit.

2.7.6 Kushtëzimi absolut dhe relativ

Për një hartë $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$, perturbimi i rendit të parë është $\Delta \mathbf{y} \simeq J_f(\mathbf{x}) \Delta \mathbf{x}$. Numri absolut i kushtëzimit në normat e zgjedhura është

$$\kappa_{\text{abs}}(\mathbf{x}) = \|J_f(\mathbf{x})\|, \quad (2.15)$$

kurse numri relativ mund të shkruhet

$$\kappa_{\text{rel}}(\mathbf{x}) = \frac{\|J_f(\mathbf{x})\| \|\mathbf{x}\|}{\|f(\mathbf{x})\|}. \quad (2.16)$$

Kjo formulë tregon pse kushtëzimi rritet pranë një rezultati zero: një ndryshim absolut i moderuar bëhet ndryshim relativ i madh. Për sistemin linear, nga

$$(A + \Delta A)(\mathbf{x} + \Delta \mathbf{x}) = \mathbf{b} + \Delta \mathbf{b} \quad (2.17)$$

dhe neglizhimi i produkteve të rendit të dytë merret

$$A \Delta \mathbf{x} \simeq \Delta \mathbf{b} - \Delta A \mathbf{x}. \quad (2.18)$$

Prandaj

$$\frac{\|\Delta \mathbf{x}\|}{\|\mathbf{x}\|} \lesssim \kappa(A) \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta \mathbf{b}\|}{\|\mathbf{b}\|} \right), \quad (2.19)$$

me kusht që perturbimi i matricës të jetë mjaft i vogël.

2.7.7 Mbetja dhe kufiri i gabimit të zgjidhjes

Për një përafrim $\hat{\mathbf{x}}$, mbetja është $\mathbf{r} = \mathbf{b} - A\hat{\mathbf{x}}$. Gabimi i vërtetë $\mathbf{e} = \mathbf{x} - \hat{\mathbf{x}}$ plotëson $A\mathbf{e} = \mathbf{r}$, kështu që

$$\|\mathbf{e}\| \leq \|A^{-1}\| \|\mathbf{r}\|. \quad (2.20)$$

Duke normalizuar dhe përdorur $\|\mathbf{b}\| \leq \|A\| \|\mathbf{x}\|$ merret kufiri praktik

$$\frac{\|\mathbf{e}\|}{\|\mathbf{x}\|} \leq \kappa(A) \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|}. \quad (2.21)$$

Pra mbetja e vogël është e nevojshme, por jo e mjaftueshme për saktësi të lartë kur $\kappa(A)$ është e madhe.

Listing 2.4: Raport diagnostik për një sistem linear.

```
import numpy as np

def raport_sistemi(A, b, x_hat):
    r = b - A @ x_hat
    mbetje_relative = np.linalg.norm(r) / np.linalg.norm(b)
    kappa = np.linalg.cond(A)
    kufi_gabimi = kappa * mbetje_relative
    return {"kappa": kappa,
            "mbetje_relative": mbetje_relative,
            "kufi_i_perafert": kufi_gabimi}
```

Funksioni nuk pretendon se kufiri është gabimi real; ai jep një alarm të arsyetuar. Në MATLAB/Octave përdoren `norm`, `cond` dhe prodhimi `A*x_hat`.

2.7.8 Përmbledhje dhe ushtrime

Gabimi i të dhënave, kushtëzimi i problemit dhe qëndrueshmëria e algoritmit duhet të analizohen veçmas. Një raport numerik pa mbetje, kushtëzim dhe studim të saktësisë është i paplotë.

1. Nxirrni numrin relativ të kushtëzimit të $f(x) = 1/(1-x)$ dhe interpretojeni pranë $x = 1$.
2. Provoni kufirin $|\theta_n| \leq \gamma_n$ për $n = 2$ dhe diskutoni rolin e termit u^2 .
3. Krahasoni shumën naive, shumën nga termi më i vogël dhe shumën Kahan për një varg me shkallë të ndryshme.
4. Ndërttoni matrica me numër kushtëzimi të kontrolluar nga vlerat singulare dhe studioni gabimin përpara.

2.7.9 Shuma, produkti skalar dhe gabimet e grumbulluara

Shuma $s_n = \sum_{i=1}^n x_i$ duket operacion elementar, por është një nga burimet më të zakonshme të humbjes së saktësisë. Në mbledhjen naive,

$$\hat{s}_k = \text{fl}(\hat{s}_{k-1} + x_k), \quad (2.22)$$

secili hap rrumbullakon rezultatin e pjesshëm. Analiza standarde jep

$$|\hat{s}_n - s_n| \leq \gamma_{n-1} \sum_{i=1}^n |x_i|, \quad (2.23)$$

ku $\gamma_{n-1} \simeq (n-1)u$. Kufiri varet nga shuma e moduleve, jo nga moduli i shumës. Kur ka anulim të fortë, $|s_n| \ll \sum |x_i|$, gabimi relativ mund të jetë i madh edhe pse gabimi absolut respekton kufirin.

Mbledhja në çift formon një pemë binare dhe ka thellësi $\lceil \log_2 n \rceil$ në vend të $n-1$; kufiri përkatës rritet afërsisht me $u \log_2 n$. Kjo është e rëndësishme në llogaritjen paralele, ku rendi i reduktimit ndryshon rezultatin bit për bit. Algoritmi Kahan ruan një kompensim për pjesën e humbur dhe shpesh arrin gabim të krahasueshëm me një rrumbullakim të vetëm, megjithëse nuk është ilaq universal për të gjitha vargjet.

Produkti skalar $\mathbf{x}^T \mathbf{y}$ kombinon shumëzime dhe mbledhje. Kufiri tipik është

$$|\text{fl}(\mathbf{x}^T \mathbf{y}) - \mathbf{x}^T \mathbf{y}| \leq \gamma_n |\mathbf{x}|^T |\mathbf{y}|. \quad (2.24)$$

Ky rezultat përhapet te shumëzimi matricor element për element. Në simulime të mëdha, ndryshimi i bibliotekës BLAS, numrit të threads ose rendit të ndarjes mund të ndryshojë bitat e fundit pa ndryshuar vlefshmërinë shkencore. Riprodhueshmëria duhet të përcaktojë nëse kërkohet identitet bit për bit apo vetëm pajtim brenda një tolerance.

Kushtëzimi komponentor

Numri klasik $\kappa(A) = \|A\|\|A^{-1}\|$ mat perturbime normore. Në disa probleme, hyrjet kanë pacaktueshmëri relative komponent më komponent. Atëherë një matricë me elemente në shkallë shumë të ndryshme mund të duket keq në një normë, edhe pse struktura fizike e perturbimeve është më e kufizuar. Analiza komponentore përdor $|\Delta A| \leq \varepsilon|A|$ dhe $|\Delta b| \leq \varepsilon|b|$. Ky dallim është me rëndësi në rrjete rezistive, sisteme bilanci dhe matrica që përmbajnë koeficientë me njësi të ndryshme.

Shkallëzimi me matrica diagonale $D_r A D_c$ mund të barazojë madhësitë e rreshtave dhe kolonave. Ai nuk ndryshon zgjidhjen fizike pasi ndryshoret rikthehen, por mund të përmirësojë sjelljen e eliminimit dhe kuptimin e tolerancave. Shkallëzimi nuk e shëron një varësi reale lineare; ai vetëm shmang që njësitë e papërshtatshme të duken si keqkushtëzim.

Aritmetika e intervaleve si kontroll

Në aritmetikën e intervaleve, një madhësi ruhet si $[a, b]$ që garanton përfshirjen e vlerës së saktë. Veprimet rrumbullakohen nga jashtë. Për shembull,

$$[a, b] + [c, d] = [a + c, b + d]. \quad (2.25)$$

Avantazhi është një kufi i garantuar; kufizimi është mbivlerësimi nga varësia. Nëse $x \in [0, 1]$, shprehja $x - x$ vlerësohet si $[-1, 1]$, megjithëse është saktësisht zero, sepse dy paraqitjet e x trajtohen si të pavarura. Aritmetika e intervaleve është e dobishme për verifikime lokale dhe kufij, por nuk zëvendëson analizën e kushtëzimit ose modelin probabilitar të pacaktueshmërisë.

Kapitulli 3

Ekuacionet jolineare, sistemet lineare dhe vlerat vetjake

Rezultatet e të nxënit. Studenti zbaton përgjysmimin, pikën fikse, Njutonin dhe sekanten; zgjidh sisteme lineare me eliminim e faktorizim; interpreton kushtëzimin; llogarit vlera e vektorë vetjakë me metodën fuqi dhe algoritmin QR.

Orientim për studim. Metodatat në këtë kapitull bashkohen nga ideja e mbetjes. Për rrënjët ajo është $f(x_k)$, për sistemet $\mathbf{b} - A\mathbf{x}_k$, ndërsa për çiftin vetjak $A\mathbf{v}_k - \lambda_k\mathbf{v}_k$. Derivoni hapin, parashikoni regjimin e konvergjencës dhe vetëm pastaj zbatoni kriterin e ndalimit. Krahasimi ndërmjet metodës së sigurt dhe metodës së shpejtë është pjesë e rezultatit.

3.1 Ekuacioni skalar $f(x) = 0$

Rrënja është pikë ku modeli plotëson një kusht fizik: ekuilibër force, energji e caktuar, kohë goditjeje ose parametër kalibrimi. Metoda duhet zgjedhur sipas informacionit të disponueshëm, intervalit të sigurt dhe koston e vlerësimit të funksionit.

3.1.1 Përgjysmimi

Nëse f është e vazhdueshme dhe $f(a)f(b) < 0$, ekziston të paktën një rrënjë në $[a, b]$. Pas n hapash,

$$|x_n - x_*| \leq \frac{b - a}{2^{n+1}}. \quad (3.1)$$

Metoda është e ngadaltë, por robuste. Ajo nuk dallon rrënjët me shumëfish çift, sepse shenja mund të mos ndryshojë.

Shembull Algoritmi i përgjysmimit. Jepen f , a , b dhe toleranca τ , me $f(a)f(b) < 0$. Për sa kohë $(b - a)/2 > \tau$, vendoset $c = (a + b)/2$. Nëse $f(a)f(c) \leq 0$, zëvendësohet b me c ; përndryshe zëvendësohet a me c . Në fund kthehet $(a + b)/2$.

3.1.2 Pika fikse dhe Njutoni

Shkrimi $x = g(x)$ jep iteracionin $x_{n+1} = g(x_n)$. Konvergjenca lokale kërkon $|g'(x_*)| < 1$. Përzgjedhja e g është pjesë e metodës; forma algebrike e papërshtatshme mund të divergojë.

Linearizimi i f rreth x_n jep metodën e Njutonit,

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}. \quad (3.2)$$

Pranë një rrënje të thjeshtë, gabimi është kuadratik: $|e_{n+1}| \approx C|e_n|^2$. Megjithatë, derivati i vogël, pika fillestare e keqe ose dalja nga domeni mund ta dështojnë metodën. Një strategji praktike kombinon intervalin e përgjysmimit me hapin e Njutonit.

Sekantja zëvendëson derivatin me pjerrësinë ndërmjet dy pikave. Ajo nuk kërkon derivat dhe ka rend konvergjence $\varphi = (1 + \sqrt{5})/2$.




Figura 3.1: Konvergjencia lineare e përgjysmimit dhe konvergjencia e shpejtë e Njutonit për $\cos x - x = 0$.

3.2 Sistemet jolineare

Për $\mathbf{F}(\mathbf{x}) = \mathbf{0}$, linearizimi përdor Jakobin $J_{ij} = \partial F_i / \partial x_j$:

$$J(\mathbf{x}_k) \Delta \mathbf{x}_k = -\mathbf{F}(\mathbf{x}_k), \quad \mathbf{x}_{k+1} = \mathbf{x}_k + \Delta \mathbf{x}_k. \quad (3.3)$$

Në çdo hap zgjidhet një sistem linear; inversi nuk formohet. Shkallëzimi i ndryshoreve është i rëndësishëm kur komponentët kanë njësi ose madhësi shumë të ndryshme. Në probleme të vështira përdoret amortizimi $\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda \Delta \mathbf{x}_k$, $0 < \lambda \leq 1$.

Shembull Ekuilibri mekanik. Për dy masa të lidhura me susta jolineare, $\mathbf{F}(\mathbf{x})$ përmbledh forcat neto. Jakobiani është matrica e ngurtësisë tangjente. Konvergjencia e Njutonit tregon jo vetëm zgjidhjen, por edhe afërsinë ndaj humbjes së stabilitetit kur J bëhet pothuaj singular.

3.3 Sistemet lineare

Eliminimi i Gausit e shndërron A në formë trekëndore. Pivotimi i pjesshëm zgjedh elementin me modul më të madh në kolonën aktive dhe shmang pjesëtimin me numra të vegjël. Faktorizimi shkruhet

$$PA = LU, \quad (3.4)$$

ku P është matricë permutimi, L trekëndore e poshtme dhe U trekëndore e sipërme. Për shumë anë të djathta, faktorizimi kryhet një herë dhe zëvendësimet përsëriten.

Për matrica simetrike pozitivisht të përcaktuara përdoret Cholesky,

$$A = LL^T, \quad (3.5)$$

që shfrytëzon simetrinë dhe ka rreth gjysmën e kostos së LU. Kostoja e faktorizimit të një matrice të dendur $n \times n$ është $\mathcal{O}(n^3)$; ruajtja është $\mathcal{O}(n^2)$.

Kujdes numerik. Determinanti i vogël nuk është masë e mirë e kushtëzimit, sepse varet nga shkalla. Përdoret $\kappa(A)$ ose vlera singulare më e vogël. Gjithashtu, një mbetje e vogël $\mathbf{r} = \mathbf{b} - A\tilde{\mathbf{x}}$ nuk garanton gabim të vogël kur A është e keqkushtëzuar.

3.4 Vlerat dhe vektorët vetjakë

Problemi

$$A\mathbf{v} = \lambda\mathbf{v} \quad (3.6)$$

shfaqet në modet normale, stabilitet, mekanikë kuantike dhe analiza të rrjeteve. Për një sistem masë–sustë,

$$K\mathbf{u} = \omega^2 M\mathbf{u}. \quad (3.7)$$

Vektorët vetjakë janë format modale; vlerat vetjake japin frekuencat katrore.




Figura 3.2: Mode normale të një sistemi njëpërmator me skaje të fiksuar.

3.4.1 Metoda fuqi

Iteracioni $\mathbf{x}_{k+1} = A\mathbf{x}_k / \|A\mathbf{x}_k\|$ izolon vektorin e lidhur me vlerën vetjake me modul më të madh, nëse komponenti fillestar përkatës nuk është zero. Shpejtësia përcaktohet nga $|\lambda_2/\lambda_1|$. Vlera vlerësohet me kuocientin Rayleigh

$$\rho(\mathbf{x}) = \frac{\mathbf{x}^T A \mathbf{x}}{\mathbf{x}^T \mathbf{x}}. \quad (3.8)$$

3.4.2 Algoritmi QR

Faktorizimi $A_k = Q_k R_k$ dhe përditësimi $A_{k+1} = R_k Q_k$ prodhojnë matrica të ngjashme, pra me të njëjtat vlera vetjake. Për matrica simetrike, A_k afrohet drejt formës diagonale. Në praktikë përdoren reduktimi Hessenberg/tridiagonal dhe zhvendosjet për konvergencë të shpejtë.

3.5 Renditja e faqeve si problem vetjak

Një matricë kalimi P përshkruan probabilitetin e kalimit ndërmjet faqeve. Vektori stacionar plotëson $\mathbf{p} = P\mathbf{p}$. Faktori i amortizimit shmang nyjet pa dalje dhe komponentët e shkëputur:

$$G = \alpha P + (1 - \alpha) \frac{\mathbf{1}\mathbf{1}^T}{n}. \quad (3.9)$$

Metoda fuqi mbi G jep renditjen. Ky shembull lidh algjebrën lineare, zinxhirët Markov dhe simulimin.

Lidhja me laboratorin. Laboratori ndërton sistemin masë-sustë, verifikon simetrinë, llogarit frekuencat dhe vizaton modet. Një ushtrim shtesë ndërton një rrjet të vogël faqesh dhe krahason iteracionin e fuqisë me zgjidhjen e drejtpërdrejtë.

Pyetje kontrolli

1. Kur preferohet përgjysmimi ndaj Njutonit?
2. Pse pivotimi është pjesë e qëndrueshmërisë së eliminimit?
3. Çfarë përcakton shpejtësinë e metodës fuqi?

3.6 Algoritmet kryesore dhe zbatimi në Python

Ky kapitull përmban tri familje problemesh. Secila kërkon një kriter ndalimi të lidhur me mbetjen, jo vetëm me ndryshimin ndërmjet dy iteracioneve.

3.6.1 Përgjysmimi dhe Njutoni i mbrojtur

Listing 3.1: Përgjysmimi me kontroll të intervalit.

```
def pergjysmimi(f, a, b, tol=1e-12, max_iter=200):
    fa, fb = f(a), f(b)
    if fa * fb > 0:
        raise ValueError("Intervali nuk kufizon nje ndryshim shenje.")
    for _ in range(max_iter):
        c = 0.5 * (a + b)
        fc = f(c)
        if abs(fc) < tol or 0.5*(b-a) < tol:
            return c
        if fa * fc <= 0:
            b, fb = c, fc
        else:
            a, fa = c, fc
    raise RuntimeError("Nuk u arrit konvergjenca.")
```

Listing 3.2: Njutoni me kontroll të derivatit.

```
def njutoni(f, df, x, tol=1e-12, max_iter=50):
    for _ in range(max_iter):
        fx, dfx = f(x), df(x)
        if abs(fx) < tol:
            return x
        if abs(dfx) < np.sqrt(np.finfo(float).eps):
            raise ArithmeticError("Derivat shume i vogel.")
        hapi = -fx / dfx
        x = x + hapi
        if abs(hapi) < tol * (1 + abs(x)):
            return x
    raise RuntimeError("Nuk u arrit konvergjenca.")
```

Në një zbatim robust, hapi i Njutonit pranohet vetëm nëse qëndron brenda intervalit dhe zvogëlon mbetjen; përndryshe kryhet një përgjysmim.

3.6.2 Zgjidhja e sistemit linear

Listing 3.3: Zgjidhja dhe diagnostika pa formuar inversin.

```
A = np.array([[4., -1., 0.], [-1., 4., -1.], [0., -1., 3.]])
b = np.array([15., 10., 10.])
x = np.linalg.solve(A, b)
r = b - A @ x
print("x =", x)
print("mbetja relative =", np.linalg.norm(r)/np.linalg.norm(b))
print("kappa_2 =", np.linalg.cond(A))
```

Operatori `solve` përdor faktorizime të përshtatshme. Shkrimi `inv(A) @ b` shmanget.

3.6.3 Metoda fuqi

Listing 3.4: Vlera vetjake dominante dhe kuocienti Rayleigh.

```
def metoda_fuqi(A, tol=1e-11, max_iter=10_000):
    x = np.ones(A.shape[0])
    x /= np.linalg.norm(x)
    lam_old = 0.0
    for k in range(max_iter):
        y = A @ x
        x = y / np.linalg.norm(y)
        lam = x @ A @ x
        if abs(lam - lam_old) < tol * (1 + abs(lam)):
            return lam, x, k + 1
        lam_old = lam
    raise RuntimeError("Metoda fuqi nuk konvergjo.")
```

Kontrolli përfundimtar është norma $\|Ax - \lambda x\|$. Shenja e vektorit vetjak nuk ka kuptim fizik më vete: x dhe $-x$ përfaqësojnë të njëjtin mod.

3.6.4 Lidhja me modet normale

Për $Ku = \omega^2 Mu$, përdoret `scipy.linalg.eigh(K, M)` kur K dhe M janë simetrike dhe M pozitivisht e përcaktuar. Frekuencat renditen, normalizohen dhe kontrollohet ortogonaliteti $U^T MU = I$.

Rendi i paraqitjes së metodave të rrënjëve, sistemeve dhe vlerave vetjake ndjek traditën e teksteve shqip [1, 2, 3]; termat e algjebërës lineare numerike kontrollohen edhe kundrejt punimeve të Departamentit të Matematikës së Aplikuar të UT-së [10].

3.6.5 Konvergjencia e metodave për rrënjët

Le të jetë x_* rrënjë e thjeshtë. Në iteracionin e pikës fikse $x_{k+1} = g(x_k)$, teorema e vlerës mesatare jep

$$e_{k+1} = x_{k+1} - x_* = g'(\xi_k)(x_k - x_*) = g'(\xi_k)e_k. \quad (3.10)$$

Nëse $|g'(x)| \leq q < 1$ në një interval që ruhet nga g , atëherë $|e_k| \leq q^k |e_0|$. Ky është konvergjim linear. Për Njرتونin, zhvillimi Taylor rreth x_k jep

$$0 = f(x_*) = f(x_k) + f'(x_k)(x_* - x_k) + \frac{f''(\xi_k)}{2}(x_* - x_k)^2. \quad (3.11)$$

Pas zëvendësimit të hapit të Njرتونit merret

$$e_{k+1} = \frac{f''(\xi_k)}{2f'(x_k)} e_k^2. \quad (3.12)$$

Konvergjencia kuadratike vlen vetëm pasi iteracioni ka hyrë në fqinjësinë e rrënjës dhe kur $f'(x_*) \neq 0$. Për një rrënjë me shumëfish m , Njرتونi standard bëhet linear; formula e modifikuar $x_{k+1} = x_k - mf(x_k)/f'(x_k)$ rikthen rendin kuadratik kur m dihet.

Metoda e Müller-it ndërton një polinom kuadratik në tri pika dhe zgjedh rrënjën e tij që vazhdon trajektoren e iteracionit. Ajo mund të prodhojë rrënjë komplekse edhe nga pika fillestare reale, çka është avantazh për polinomet, por kërkon trajtim të kujdesshëm të degës së rrënjës katrore dhe të anulimit në emërues.

3.6.6 Eliminimi i Gausit dhe pivotimi

Në hapin k , elementi $a_{kk}^{(k)}$ përdoret si pivot dhe shumëzuesit janë

$$\ell_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}, \quad i = k + 1, \dots, n. \quad (3.13)$$

Rreshti i përditësohet me $a_{ij}^{(k+1)} = a_{ij}^{(k)} - \ell_{ik}a_{kj}^{(k)}$. Në aritmetikë të saktë, kjo është një sekuencë transformimesh elementare. Në aritmetikë me saktësi të fundme, pivot i vogël prodhon shumëzues të mëdhenj dhe zmadhon gabimet. Pivotimi i pjesshëm zgjedh

$$p = \arg \max_{i \geq k} |a_{ik}^{(k)}| \quad (3.14)$$

dhe këmben rreshtat p dhe k . Rezultati ruhet si $PA = LU$. Faktorizimi kushton afërsisht $2n^3/3$ veprime me presje të lëvizshme, kurse dy zëvendësimet për çdo anë të djathtë kushtojnë $\mathcal{O}(n^2)$.

Formimi i A^{-1} kërkon zgjidhjen e n sistemeve dhe pastaj një shumëzim tjetër me $\mathbf{b}$; ai shton punë dhe rumbullakime pa nevojë. Për këtë arsye `solve(A,b)` është zgjedhja standarde.

3.6.7 Njutoni për sisteme dhe kriteret e ndalimit

Nga zhvillimi shumëpërmasor

$$\mathbf{F}(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{F}(\mathbf{x}) + J(\mathbf{x})\Delta\mathbf{x} + \mathcal{O}(\|\Delta\mathbf{x}\|^2) \quad (3.15)$$

vendosja e anës së majtë në zero jep sistemin e Njutonit. Duhet të kontrollohen njëkohësisht norma e mbetjes dhe madhësia relative e hapit,

$$\|\mathbf{F}(\mathbf{x}_k)\| \leq \tau_F, \quad \|\Delta\mathbf{x}_k\| \leq \tau_x(1 + \|\mathbf{x}_k\|). \quad (3.16)$$

Vetëm kriteri i hapit mund të pranojë stagnim; vetëm mbetja mund të mashtrojë kur ekuacionet kanë shkallë shumë të ndryshme. Shkallëzimi i secilit ekuacion me një madhësi karakteristike i bën kriteret fizikisht të krahasueshme.

Listing 3.5: Njutoni i amortizuar për një sistem jolinear.

```
import numpy as np

def njutoni_sistem(F, J, x0, tol=1e-10, maksimumi=50):
    x = np.array(x0, dtype=float)
    for k in range(maksimumi):
        Fx = np.asarray(F(x), dtype=float)
        if np.linalg.norm(Fx, ord=np.inf) <= tol:
            return x, k
        hapi = np.linalg.solve(J(x), -Fx)
        alfa = 1.0
        # Kërkim prapa: pranohet vetëm ulja e normës së mbetjes.
        while np.linalg.norm(F(x + alfa*hapi)) >= np.linalg.norm(Fx):
            alfa *= 0.5
            if alfa < 2.0**-20:
                raise RuntimeError("Njutoni stagnoi; kontrolloni shkallëzimin.")
        x = x + alfa*hapi
    raise RuntimeError("U arrit numri maksimal i iteracioneve.")
```

3.6.8 Metoda fuqi dhe algoritmi QR: derivim spektral

Nëse A ka një bazë vektorësh vetjakë dhe $\mathbf{x}_0 = \sum_i c_i \mathbf{v}_i$, atëherë

$$A^k \mathbf{x}_0 = \lambda_1^k \left[c_1 \mathbf{v}_1 + \sum_{i=2}^n c_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{v}_i \right]. \quad (3.17)$$

Kur $|\lambda_1| > |\lambda_2|$ dhe $c_1 \neq 0$, termat e tjerë shuhen relativisht si $|\lambda_2/\lambda_1|^k$. Normalizimi shmang tejmbushjen, por nuk ndryshon drejtimin.

Në algoritmin QR, $A_k = Q_k R_k$ dhe $A_{k+1} = R_k Q_k = Q_k^T A_k Q_k$, kështu që A_{k+1} është e ngjashme me A_k . Për matrica simetrike, transformimet ortogonale ruajnë mirë normën dhe diagonalja konvergjon te vlerat vetjake. Zhvendosja $A_k - \mu_k I = Q_k R_k$, e ndjekur nga $A_{k+1} = R_k Q_k + \mu_k I$, përshpejton ndarjen e vlerave të afërta.

3.6.9 Përmbledhje dhe ushtrime

Metodat e këtij kapitulli bashkohen nga linearizimi: Njutoni linearizon funksionin, eliminimi zgjidh problemin linear dhe analiza spektrale shpjegon mënyrën si vepron matrica në drejtime të veçanta.

1. Nxirrni rendin e sekantes duke supozuar $|e_{k+1}| \simeq C|e_k e_{k-1}|$.
2. Implementoni Müller-in me numra kompleksë dhe provojeni te $x^4 + 1 = 0$.
3. Numëroni veprimet e eliminimit të Gausit dhe nxirrni termin $2n^3/3$.
4. Për një sistem masë-sustë, verifikoni ortogonalitetin e modeve ndaj matricës së masës.
5. Ndërttoni një rrjet faqesh dhe studioni ndikimin e parametrut të amortizimit në konvergjencën e renditjes.

3.6.10 Metoda e Müller-it dhe rrënjët komplekse

Metoda e Müller-it përdor tri pika x_0, x_1, x_2 dhe ndërtton polinomin kuadratik interpolues për f . Duke vendosur $h_1 = x_1 - x_0$, $h_2 = x_2 - x_1$ dhe diferencat e pjesëtuara

$$\delta_1 = \frac{f(x_1) - f(x_0)}{h_1}, \quad \delta_2 = \frac{f(x_2) - f(x_1)}{h_2}, \quad (3.18)$$

koeficienti kuadratik është $d = (\delta_2 - \delta_1)/(h_1 + h_2)$. Polinomi rreth x_2 shkruhet

$$p(x_2 + s) = f(x_2) + bs + ds^2, \quad qquad b = \delta_2 + h_2 d. \quad (3.19)$$

Rrënja që jep hapin më të qëndrueshëm është

$$s = -\frac{2f(x_2)}{b + \operatorname{sgn}_*(b)\sqrt{b^2 - 4df(x_2)}}, \quad (3.20)$$

ku shenja zgjidhet që emëruesi të ketë modul maksimal. Kjo zgjedhje shmang anulimin ndërmjet b dhe rrënjës katrore. Pika e re është $x_3 = x_2 + s$, pastaj ruhet tresha më e fundit.

Diskriminanti mund të jetë negativ edhe kur pikat janë reale, prandaj implementimi duhet të lejojë aritmetikë komplekse. Kjo e bën Müller-in të dobishëm për polinome pa rrënjë reale. Renditja e konvergjencës është afërsisht 1.84, më e lartë se e sekantes, por çdo hap përdor më shumë informacion dhe mund të jetë më pak i parashikueshëm. Për probleme ku kërkohet një rrënjë reale brenda një intervali fizik, një metodë e mbrojtur me përgjysmim është zakonisht më e sigurt.

Refinimi iterativ i sistemeve lineare

Pas zgjidhjes së $A\hat{x} = b$, llogaritet mbetja $r = b - A\hat{x}$ dhe zgjidhet

$$A\delta x = r, \quad qquad \hat{x} \leftarrow \hat{x} + \delta x. \quad (3.21)$$

Në aritmetikë të saktë, një hap do të korrigjonte të gjithë gabimin. Në praktikë, nëse mbetja llogaritet me saktësi më të lartë se faktorizimi, refinimi mund të rikuperojë disa shifra. Faktorizimi LU ripërdoret, kështu që çdo korrigjim kushton vetëm dy zëvendësime trekëndore. Procesi ndalet kur mbetja e shkallëzuar nuk ulet më ose korrigjimi bëhet i papërfillshëm.

Një kriter i dobishëm komponentor është

$$\eta = \max_i \frac{|r_i|}{(|A||\hat{x}| + |b|)_i}. \quad (3.22)$$

Ai interpretohet si perturbimi relativ minimal i afërt i të dhënave që e bën $\hat{x}$ zgjidhje të saktë. Një η pranë saktësisë së makinës tregon algoritëm të qëndrueshëm në prapavijë, por gabimi përpara mund të mbetet i madh kur sistemi është i keqkushtëzuar.

Problemi i përgjithësuar i vlerave vetjake

Në mekanikën e sistemeve me shumë shkallë lirie shfaqet

$$K\mathbf{u} = \omega^2 M\mathbf{u}, \quad (3.23)$$

ku M është matrica e masës dhe K matrica e ngurtësisë. Nëse M është simetrike pozitivisht e përcaktuar, faktorizimi Cholesky $M = LL^T$ e kthen problemin në

$$L^{-1}KL^{-T}\mathbf{z} = \omega^2\mathbf{z}, \text{ qquad } \mathbf{u} = L^{-T}\mathbf{z}. \quad (3.24)$$

Matrica e transformuar është simetrike. Modet mund të normalizohen që $\mathbf{u}_i^T M\mathbf{u}_j = \delta_{ij}$ dhe atëherë $\mathbf{u}_i^T K\mathbf{u}_j = \omega_i^2 \delta_{ij}$. Këto identitete janë prova numerike: mbetja $\|K\mathbf{u}_i - \omega_i^2 M\mathbf{u}_i\|$ kontrollon çdo çift vetjak, ndërsa ortogonaliteti kontrollon të gjithë bazën.

Në rrjete ose sisteme me simetri, vlera vetjake të shumëfishta nuk përcaktojnë vektorë unikë; përcaktohet vetëm nënhapësira vetjake. Krahasimi komponent më komponent i dy vektorëve nga programe të ndryshme mund të jetë i pakuptimtë. Duhet krahasuar mbetja, vlera vetjake dhe hapësira e shtrirë nga modet përkatëse.

Kapitulli 4

Interpolimi, regresi dhe përshtatja e modeleve

Rezultatet e të nxënit. Studenti ndërton polinomin e Lagranzhit dhe interpolimin Hermitian; dallon interpolimin nga regresi; zbaton katrorët më të vegjël linearë e jolinearë; interpreton mbetjet, peshat dhe pacaktueshmërinë e parametrave.

Orientim për studim. Mbani të ndara dy pyetje: interpolimi kalon nëpër të dhënat, ndërsa regresi vlerëson një marrëdhënie në prani të shpërndarjes eksperimentale. Çdo formulë duhet shoqëruar me term të mbetjes ose me model statistikor. Shembulli i Keplerit përdoret për të lidhur linearizimin, njësitë, mbetjet dhe pacaktueshmërinë e parametrave.

4.1 Interpolimi polinomial

Për nyje të dallueshme (x_i, y_i) ekziston një polinom unik me gradë jo më të madhe se n që kalon në $n + 1$ pika. Forma e Lagranzhit është

$$p_n(x) = \sum_{i=0}^n y_i L_i(x), \quad L_i(x) = \prod_{j \neq i} \frac{x - x_j}{x_i - x_j}. \quad (4.1)$$

Gabimi për $f \in C^{n+1}$ është

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^n (x - x_i). \quad (4.2)$$

Formula tregon rolin e lëmueshmërisë dhe të vendosjes së nyjeve. Rritja e gradës në nyje të baraslarguara mund të përkeqësojë përafrimin pranë skajeve: fenomeni Runge.

Në llogaritje përdoret forma baricentrike, jo prodhimi i drejtpërdrejtë i polinomeve bazë. Për grupe të mëdha të dhënash preferohen splinet kubike, të cilat përdorin polinome lokale dhe ruajnë vazhdimësinë e dy derivateve të para.

4.2 Interpolimi Hermitian dhe ekstrapolimi

Interpolimi Hermitian përdor edhe vlerat e derivateve. Për dy pika, polinomi kubik përcaktohet nga $f(x_0)$, $f'(x_0)$, $f(x_1)$ dhe $f'(x_1)$. Kjo është bazë për trajektore të lëmuara dhe skema integrimi.

Ekstrapolimi vlerëson jashtë intervalit të të dhënave dhe është shumë më i rrezikshëm. Ekstrapolimi Richardson shfrytëzon një zhvillim të njohur të gabimit,

$$A(h) = A + ch^p + \mathcal{O}(h^{p+1}), \quad qquad A \approx \frac{2^p A(h/2) - A(h)}{2^p - 1}. \quad (4.3)$$

Ai përdoret për të rritur rendin ose për të vlerësuar kufirin $h \rightarrow 0$.




Figura 4.1: Interpolimi i funksionit Runge. Nyjet e Çebishevit zvogëlojnë lëkundjet në skaje.

4.3 Regresi linear

Në regres, pikat nuk kërkohet të kalohen saktësisht. Modeli $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ përshtatet duke minimizuar

$$S(\boldsymbol{\beta}) = \|X\boldsymbol{\beta} - \mathbf{y}\|_2^2. \quad (4.4)$$

Ekuacionet normale janë $X^T X \hat{\boldsymbol{\beta}} = X^T \mathbf{y}$, por formimi i $X^T X$ katrorëzon numrin e kushtëzimit. Faktorizimi QR është më i qëndrueshëm. Kur devijimet standarde σ_i njihen, minimizohet

$$\chi^2 = \sum_i \frac{[y_i - f(x_i; \boldsymbol{\beta})]^2}{\sigma_i^2}. \quad (4.5)$$




Figura 4.2: Linearizimi logaritmik i $T^2 \propto a^3$. Pjerrësia e pritur për $\ln T$ kundrejt $\ln a$ është $3/2$.

Shembull Ligji i tretë i Keplerit. Modeli $T = Ca^p$ bëhet $\ln T = \ln C + p \ln a$. Përshtatja jep p dhe pacaktueshmërinë e tij. Transformimi logaritmik ndryshon strukturën e gabimit; nëse gabimi është aditiv në T , përshtatja jolineare në shkallën origjinale mund të jetë më e përshtatshme.

4.4 Mbetjet dhe diagnostika

Mbetjet $r_i = y_i - \hat{y}_i$ nuk janë mbeturina; ato testojnë modelin. Një strukturë sistematike në r_i tregon jolinearitet të munguar, heteroskedasticitet, korrelacion ose pikë jashtë modelit. Koeficienti R^2 nuk mjafton për vleftësim dhe nuk duhet përdorur si provë shkakësie.

Për gabime Gauss të pavarura me variancë σ^2 , kovarianca e parametrave është afërsisht

$$\text{Cov}(\hat{\beta}) = \sigma^2(X^T X)^{-1}. \quad (4.6)$$

Në modele jolineare përdoret Jakobiani në optimum, bootstrap-i ose kampionimi probabilitar.

4.5 Shmangiet minimale absolute

Minimizimi $\sum_i |r_i|$ është më robust ndaj pikave ekstreme se katrorët më të vegjël. Funkzioni nuk është i derivueshëm në zero, por problemi mund të formulohet si program linear. Zgjedhja e humbjes shpreh një supozim statistik: L_2 lidhet me gabimin Gauss, ndërsa L_1 me shpërndarje me bishta më të rëndë.

Lidhja me laboratorin. Laboratori përdor të dhëna planetare, përshtat $T = Ca^p$, vizaton mbetjet dhe krahason regresin e papeshuar, të peshuar dhe një përshtatje robuste.

Pyetje kontrolli

1. Pse interpolimi me gradë të lartë mund të dështojë edhe për funksion të lëmuar?
2. Kur linearizimi logaritmik ndryshon interpretimin statistik të gabimit?
3. Çfarë informacioni japin mbetjet që nuk e jep R^2 ?

4.6 Algoritmet e interpolimit dhe përshtatjes

4.6.1 Interpolimi baricentrik

Forma baricentrike është më e qëndrueshme se vlerësimi i drejtpërdrejtë i bazës së Lagranzhit. Peshat janë

$$w_i = \left[\prod_{j \neq i} (x_i - x_j) \right]^{-1}, \quad p(x) = \frac{\sum_i w_i y_i / (x - x_i)}{\sum_i w_i / (x - x_i)}. \quad (4.7)$$

Nëse x përputhet me një nyje, kthehet drejtpërdrejt y_i .

Listing 4.1: Interpolimi baricentrik nga SciPy.

```
import numpy as np
from scipy.interpolate import BarycentricInterpolator

f = lambda x: 1.0/(1.0 + 25.0*x*x)
n = 15
i = np.arange(n)
x_cheb = np.cos((2*i + 1)*np.pi/(2*n))
interp = BarycentricInterpolator(x_cheb, f(x_cheb))

x = np.linspace(-1, 1, 1000)
gabimi = np.max(np.abs(interp(x) - f(x)))
print("gabimi maksimal =", gabimi)
```

4.6.2 Katrorët më të vegjël me QR

Listing 4.2: Përshtatja e një modeli linear në parametra.

```
def pershtat_linearisht(X, y, sigma=None):
    if sigma is not None:
        W = 1.0 / np.asarray(sigma)
        X = X * W[:, None]
        y = y * W
```

```

beta, mbetje, rank, singular = np.linalg.lstsq(X, y, rcond=None)
return beta, mbetje, rank, singular

# ln(T) = beta0 + beta1 ln(a)
X = np.column_stack([np.ones_like(a), np.log(a)])
beta, *_ = pershtat_linearisht(X, np.log(T))
print("eksponenti i Keplerit =", beta[1])

```

lstsq përdor faktorizime numerikisht më të sigurta se zgjidhja eksplicite e ekuacioneve normale.

4.6.3 Përshtatja jolineare

Listing 4.3: Përshtatja e modelit $T = Ca^p$ në shkallën origjinale.

```

from scipy.optimize import curve_fit

def kepler(a, C, p):
    return C * a**p

param, kov = curve_fit(kepler, a, T, p0=(1.0, 1.5), sigma=sigma_T,
                        absolute_sigma=True)
gabim_param = np.sqrt(np.diag(kov))
print(param, gabim_param)

```

4.6.4 Diagnostika e mbetjeve

Pas përshtatjes vizatohen r_i kundrejt x_i , histogrami dhe, kur rendi kohor ka rëndësi, autokorrelacioni. Një lakim sistematik tregon model të mangët; formë hinke tregon variancë jo të njëtrajtshme; pika me ndikim të madh kërkojnë kontroll fizik, jo fshirje automatike.

Kujdes numerik. Termi *përshtatje* përdoret për fitting, *mbetje* për residual dhe *shmangie minimale absolute* për least absolute deviations. *Regres* i referohet modelit të statistikës, ndërsa *interpolim* kalon saktësisht nëpër nyje.

Për interpolimin, përafrimin dhe shembujt MATLAB/Python janë konsultuar [1, 2, 3]. Për terminologjinë e rizgjedhjes, mbetjeve dhe vlerësimit statistik janë përdorur edhe punimet doktorale të UT-së [7, 8].

4.6.5 Interpolimi i Lagranzhit dhe termi i mbetjes

Për nyje të ndryshme $x_0, \dots, x_n$, polinomi interpolues është

$$p_n(x) = \sum_{i=0}^n f(x_i) L_i(x), \quad L_i(x) = \prod_{j \neq i} \frac{x - x_j}{x_i - x_j}. \quad (4.8)$$

Vërtetimi është i drejtpërdrejtë: $L_i(x_j) = \delta_{ij}$, prandaj $p_n(x_j) = f(x_j)$. Uniciteti rrjedh sepse diferenca e dy polinomeve interpoluese do të kishte $n + 1$ rrënjë, por gradë jo më të madhe se n .

Nëse $f \in C^{n+1}$, gabimi në një pikë x është

$$f(x) - p_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \omega_{n+1}(x), \quad \omega_{n+1}(x) = \prod_{i=0}^n (x - x_i). \quad (4.9)$$

Kjo formulë ndan dy burime: lëmueshmërinë e funksionit dhe gjeometrinë e nyjeve. Nyjet e baraslarguara mund ta bëjnë ω_{n+1} shumë të madhe pranë skajeve; nyjet e Çebishev-it e kontrollojnë këtë faktor dhe zbusin dukurinë Runge.

Forma baricentrike

$$p_n(x) = \frac{\sum_i w_i f_i / (x - x_i)}{\sum_i w_i / (x - x_i)}, \quad w_i = \left[\prod_{j \neq i} (x_i - x_j) \right]^{-1}, \quad (4.10)$$

është numerikisht më e përshtatshme se zgjerimi i polinomit në fuqi. Nëse x përkon me një nyje, kthehet drejtpërdrejt f_i për të shmangur pjesëtimin me zero.

4.6.6 Interpolimi Hermitian dhe ekstrapolimi i Richardson-it

Interpolimi Hermitian përdor jo vetëm $f(x_i)$, por edhe derivate. Për dy nyje dhe vlera të derivateve ndërtohet një polinom kub. Në formë të përgjithshme, nyjet përsëriten në tabelën e diferencave të pjesëtueshme dhe diferenca e parë në një nyje të përsëritur zëvendësohet nga $f'(x_i)$.

Ekstrapolimi nis nga një përafrim me zhvillim asimptotik

$$A(h) = A + c_p h^p + c_{p+1} h^{p+1} + \dots \quad (4.11)$$

Dy vlera me hapa h dhe h/r japin

$$A_R = \frac{r^p A(h/r) - A(h)}{r^p - 1} = A + \mathcal{O}(h^{p+1}), \quad (4.12)$$

ose rend edhe më të lartë kur zhvillimi përmban vetëm fuqi çiftë. Kjo është ideja pas derivimit të përmirësuar dhe integritit Romberg. Ekstrapolimi nuk duhet zbatuar jashtë regjimit asimptotik; nëse hapi është shumë i madh, modeli i gabimit nuk vlen, ndërsa për hap tepër të vogël dominon rrumbullakimi.

4.6.7 Katrorët më të vegjël dhe QR

Për modelin linear $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, minimizohet

$$S(\boldsymbol{\beta}) = \|\mathbf{y} - X\boldsymbol{\beta}\|_2^2. \quad (4.13)$$

Gradienti është $\nabla S = -2X^T(\mathbf{y} - X\boldsymbol{\beta})$. Kushti $\nabla S = 0$ jep ekuacionet normale

$$X^T X \hat{\boldsymbol{\beta}} = X^T \mathbf{y}. \quad (4.14)$$

Gjeometrikisht, mbetja është ortogonale me hapësirën e kolonave të X . Megjithatë, $\kappa(X^T X) = \kappa(X)^2$, prandaj formimi i ekuacioneve normale përkeqëson kushtëzimin. Me $X = QR$, ku $Q^T Q = I$, zgjidhet

$$R\hat{\boldsymbol{\beta}} = Q^T \mathbf{y}, \quad (4.15)$$

pa katrorëzuar numrin e kushtëzimit.

Nëse gabimet kanë kovariancë Σ , kriteri i peshuar është

$$(\mathbf{y} - X\boldsymbol{\beta})^T \Sigma^{-1} (\mathbf{y} - X\boldsymbol{\beta}). \quad (4.16)$$

Kjo formulë tregon se peshat nuk janë dekorim: ato përfaqësojnë modelin probabilitar të matjeve. Kur gabimet kanë shpërndarje Gauss, katrorët më të vegjël përkojnë me vlerësimin e gjasës më të madhe.

4.6.8 Shmangiet minimale absolute

Kriteri

$$\min_{\boldsymbol{\beta}} \sum_{i=1}^n |y_i - \mathbf{x}_i^T \boldsymbol{\beta}| \quad (4.17)$$

është më pak i ndjeshëm ndaj vlerave ekstreme se kriteri kuadratik. Duke futur $u_i \geq 0$ me

$$-u_i \leq y_i - \mathbf{x}_i^T \boldsymbol{\beta} \leq u_i, \quad (4.18)$$

problemi bëhet programim linear me objektivi $\min \sum_i u_i$. Funksioni absolut nuk është i derivueshëm në zero, prandaj nuk duhet trajtuar verbërisht me ekuacionet normale.

Listing 4.4: Përshtatje lineare me QR dhe diagnostikë të mbetjeve.

```
import numpy as np

def pershtatje_qr(x, y):
    x = np.asarray(x, float); y = np.asarray(y, float)
    X = np.column_stack((np.ones_like(x), x))
    Q, R = np.linalg.qr(X, mode="reduced")
    beta = np.linalg.solve(R, Q.T @ y)
    mbetje = y - X @ beta
    sigma2 = (mbetje @ mbetje) / (len(y) - X.shape[1])
    kov_beta = sigma2 * np.linalg.inv(R) @ np.linalg.inv(R).T
    return beta, mbetje, kov_beta
```

4.6.9 Përmbledhje dhe ushtrime

Interpolimi supozon se të dhënat duhet të kalohen saktësisht; regresi pranon mbetje dhe kërkon një model të tyre. Zgjedhja nuk është thjesht numerike, por lidhet me kuptimin e të dhënave.

1. Vërtetoni formulën e mbetjes së Lagranzhit duke ndërtuar një funksion me $n + 2$ zero.
2. Krahasoni nyjet e baraslarguara dhe të Çebishevit për funksionin Runge.
3. Nxirrni Richardson-in për një metodë të rendit të dytë dhe ndërtoni tabelën Romberg.
4. Përshtatni ligjin e tretë të Keplerit në shkallë lineare dhe logaritmike; diskutoni modelin e gabimit në secilin rast.
5. Formuloni regresin me shmangie minimale absolute si program linear.

4.6.10 Ndërtimi i interpoluesit Hermitian

Për nyje x_i ku njihen $f_i = f(x_i)$ dhe $f'_i = f'(x_i)$, interpoluesi Hermitian me $n + 1$ nyje ka gradë jo më të madhe se $2n + 1$. Duke përdorur bazën e Lagranzhit $L_i(x)$, përkufizohen

$$H_i(x) = [1 - 2L'_i(x_i)(x - x_i)] L_i(x)^2, \quad K_i(x) = (x - x_i)L_i(x)^2. \quad (4.19)$$

Ato plotësojnë $H_i(x_j) = \delta_{ij}$, $H'_i(x_j) = 0$, $K_i(x_j) = 0$ dhe $K'_i(x_j) = \delta_{ij}$. Prandaj

$$p(x) = \sum_{i=0}^n [f_i H_i(x) + f'_i K_i(x)]. \quad (4.20)$$

Nëse $f \in C^{2n+2}$, mbetja është

$$f(x) - p(x) = \frac{f^{(2n+2)}(\xi_x)}{(2n+2)!} \prod_{i=0}^n (x - x_i)^2. \quad (4.21)$$

Fuqia katrore tregon se vlera dhe pjerrësia përputhen në çdo nyje. Në të dhëna eksperimentale, derivatet e vlerësuar me zhurmë mund ta përkeqësojnë rezultatin; interpolimi Hermitian është më i vlefshëm kur derivatet vijnë nga ligji fizik ose maten me cilësi të mjaftueshme.

Regresi, gjasa dhe pacaktueshmëria e parametrave

Në modelin $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, me $\boldsymbol{\varepsilon} \sim \mathcal{N}(0, \sigma^2 I)$, logaritmi i gjasës ndryshon nga një konstante me

$$-\frac{1}{2\sigma^2} \|\mathbf{y} - X\boldsymbol{\beta}\|_2^2. \quad (4.22)$$

Prandaj vlerësuesi i katrorëve më të vegjël është edhe vlerësuesi i gjasës më të madhe. Kur X ka rang të plotë,

$$\hat{\boldsymbol{\beta}} = (X^T X)^{-1} X^T \mathbf{y}, \quad \text{Cov}(\hat{\boldsymbol{\beta}}) = \sigma^2 (X^T X)^{-1}. \quad (4.23)$$

Kjo formulë përdoret për teori, por jo domosdoshmërisht për llogaritje: QR ose SVD janë më të qëndrueshme. Varianca vlerësohet me

$$s^2 = \frac{\|\mathbf{r}\|^2}{n - p}, \quad (4.24)$$

ku p është numri i parametrave. Pjesëtimi me $n - p$ merr parasysh shkallët e lirisë të përdorura në përshtatje.

Një interval për mesataren e modelit në $\mathbf{x}_*$ ka variancë $s^2 \mathbf{x}_*^T (X^T X)^{-1} \mathbf{x}_*$. Një interval parashikimi për një matje të re shton edhe s^2 , sepse matja e re ka zhurmën e vet. Ngatërrimi i këtyre dy intervaleve çon në deklaram tepër optimist të parashikimit.

Diagnostika dhe zgjedhja e modelit

Mbetjet duhet të kontrollohen ndaj vlerave të përshtatura, kohës dhe ndryshoreve shpjeguese. Një hark sistematik tregon jolinearitete të pambuluar; një hinkë tregon variancë jo konstante; grupe të ndara tregojnë ndryshore të munguar. Autokorrelacioni i mbetjeve shkel pavarësinë dhe ndryshon pacaktueshmërinë e parametrave.

Shtimi i parametrave ul gjithmonë shumën e katrorëve, prandaj ajo nuk mjafton për zgjedhje modeli. Vleftësimi i kryqëzuar ndan të dhënat në pjesë trajnimit dhe kontrolli. Kriteret AIC ose BIC kombinojnë përshtatjen me penalizim të kompleksitetit, por bazohen në supozime probabilitare që duhet deklaruar. Në ligjin e Keplerit, përshtatja e $T^2 = a^3$ mund të bëhet me një parametër fizik; një polinom i gradës së lartë mund të përshtatë pikat më mirë, por nuk jep interpretim dhe ekstrapolon keq.

Ekstrapolimi është gjithmonë më i rrezikshëm se interpolimi sepse largohet nga mbështetja e të dhënave. Intervale të statistikë të një modeli nuk përfshijnë automatikisht gabimin nga forma e gabuar e modelit. Për këtë arsye, çdo ekstrapolim duhet të shoqërohet me arsyetim fizik dhe analizë ndjeshmërie ndaj modeleve alternative.

Kapitulli 5

Diferencimi dhe integrimi numerik

Rezultatet e të nxënit. Studenti nxjerr formulat e diferencave të fundme; analizon gabimin e këputjes dhe rrumbullakimit; zbaton trapezin, Simpsonin dhe kuadraturën e Gausit; zgjedh metodën sipas lëmueshmërisë dhe dimensionit.

Orientim për studim. Formulat duhet të rindërtohen nga zhvillimi Taylor, jo të përdoren si receta. Në çdo rast identifikoni rendin e këputjes, numrin e vlerësimeve të funksionit dhe ndikimin e rrumbullakimit. Grafiku log-log i gabimit kundrejt hapit është po aq i rëndësishëm sa vlera e integralit ose e derivatit.

5.1 Derivatet nga zhvillimi Taylor

Nga

$$f(x+h) = f(x) + hf'(x) + \frac{h^2}{2}f''(x) + \dots \quad (5.1)$$

merret diferenca përpara

$$f'(x) = \frac{f(x+h) - f(x)}{h} + \mathcal{O}(h), \quad (5.2)$$

ndërsa kombinimi simetrik jep

$$f'(x) = \frac{f(x+h) - f(x-h)}{2h} + \mathcal{O}(h^2). \quad (5.3)$$

Për derivatin e dytë,

$$f''(x) = \frac{f(x+h) - 2f(x) + f(x-h)}{h^2} + \mathcal{O}(h^2). \quad (5.4)$$

Koeficientët mund të ndërtohen sistematikisht duke kërkuar që kombinimi linear të riprodhojë polinomet deri në një gradë të caktuar.

5.2 Hapi optimal

Gabimi i këputjes ulet me h , por zbritja $f(x+h) - f(x)$ humbet shifra kur h është shumë i vogël. Për diferencën përpara,

$$E(h) \approx C_1 h + C_2 \frac{u}{h}, \quad (5.5)$$

prandaj ekziston një hap optimal i rendit $\sqrt{u}$. Për diferencën qendrore, kompromisi tipik jep $h \sim u^{1/3}$.




Figura 5.1: Gabimi total ka formë U: këputja dominon për hapa të mëdhenj, rrumbullakimi për hapa tepër të vegjël.

5.3 Kuadratura e përbërë

Integrali ndahet në nënintervale. Rregulla e trapezit është

$$T_n = h \left[\frac{f(a) + f(b)}{2} + \sum_{i=1}^{n-1} f(a + ih) \right], \quad h = \frac{b-a}{n}, \quad (5.6)$$

me gabim global $\mathcal{O}(h^2)$. Rregulla e Simpsonit për n çift është

$$S_n = \frac{h}{3} \left[f_0 + f_n + 4 \sum_{i \text{ tek}} f_i + 2 \sum_{i \text{ çift}, i \neq 0, n} f_i \right], \quad (5.7)$$

me gabim global $\mathcal{O}(h^4)$ për funksione mjaft të lëmuara.




Figura 5.2: Konvergenca e trapezit dhe Simpsonit për një integral me zgjidhje të njohur.

5.4 Kuadratura e Gausit

Rregulli me n nyje

$$\int_{-1}^1 f(x) dx \approx \sum_{i=1}^n w_i f(x_i) \quad (5.8)$$

zgjedh nyjet si zerot e polinomit Legendre P_n . Ai integron saktë çdo polinom me gradë deri $2n - 1$. Një transformim afin e çon intervalin $[a, b]$ në $[-1, 1]$. Kuadratura Gauss është e fuqishme kur funksioni është i lëmuar dhe dimension i vogël.

5.5 Integrale të papërshtatshme dhe shumëfishta

Singularitetet e integrueshme trajtohen me ndryshim ndryshoreje ose ndarje të intervalit. Intervali i pafund mund të hartohet në interval të fundmë. Në d përmasa, prodhimi tensorial i n nyjeve kërkon n^d vlerësime: mallkimi i dimensionalitetit. Kjo është pika ku metodat Monte Carlo bëhen konkurruese, sepse gabimi i tyre bazë varet nga numri i mostrave dhe jo drejtpërdrejt nga d .

Shembull Perioda e lavjerrësit. Për amplitudë θ_0 , perioda e saktë e modelit ideal është

$$T = 4\sqrt{\frac{L}{g}} \int_0^{\pi/2} \frac{d\phi}{\sqrt{1 - k^2 \sin^2 \phi}}, \quad k = \sin(\theta_0/2). \quad (5.9)$$

Integrali eliptik mund të llogaritet me Simpson ose Gauss dhe të krahasohet me $T_0 = 2\pi\sqrt{L/g}$. Diferenca mat kufirin e përafritit të këndit të vogël.

Lidhja me laboratorin. Laboratori llogarit periodën për disa amplituda, kryen studim konvergjence dhe ndan gabimin e kuadraturës nga gabimi i modelit $\sin \theta \approx \theta$.

Pyetje kontrolli

1. Pse derivati numerik nuk përmirësohet pafundësisht kur $h \rightarrow 0$?
2. Çfarë kushti duhet për rendin e katërt të Simpsonit?
3. Pse prodhimi tensorial bëhet i papërshtatshëm në dimension të lartë?

5.6 Algoritmet e diferencimit dhe kuadraturës

5.6.1 Derivati qendror dhe studimi i hapit

Listing 5.1: Gabimi i derivatit qendror për një varg hapash.

```
import numpy as np

def derivat_qendror(f, x, h):
    return (f(x + h) - f(x - h)) / (2.0*h)

f = np.sin
x0 = 1.0
h = np.logspace(-16, -1, 200)
D = derivat_qendror(f, x0, h)
gabimi = np.abs(D - np.cos(x0))
h_opt = h[np.argmin(gabimi)]
print("h optimal empirik =", h_opt)
```

Grafiku $E(h)$ duhet të paraqitet në bosht log-log. Në zonën e këputjes pritet pjerrësi afërsisht 2; në zonën e rrumbullakimit gabimi rritet kur h zvogëlohet.

5.6.2 Rregulli i përbërë i Simpsonit

Listing 5.2: Integrimi Simpson me kontrollin e numrit çift të nënintervaleve.

```
def simpson(f, a, b, n):
    if n <= 0 or n % 2 != 0:
```

```

        raise ValueError("n duhet te jete numer pozitiv çift.")
    x = np.linspace(a, b, n + 1)
    y = f(x)
    h = (b - a) / n
    return h/3 * (y[0] + y[-1]
                + 4*np.sum(y[1:-1:2])
                + 2*np.sum(y[2:-2:2]))

for n in [4, 8, 16, 32, 64]:
    I = simpson(np.sin, 0.0, np.pi, n)
    print(n, I, abs(I - 2.0))

```

5.6.3 Vlerësimi Runge i gabimit

Nëse metoda ka rend p , dy llogaritje me h dhe $h/2$ japin

$$E_{h/2} \approx \frac{|A(h/2) - A(h)|}{2^p - 1}. \quad (5.10)$$

Ky vlerësim është i vlefshëm vetëm në regjimin asimptotik. Prandaj kontrollohet edhe raporti i gabimeve për tri hapa radhazi.

```

def studim_konvergjence(llogarit, ns, p):
    v = np.array([llogarit(n) for n in ns])
    e_runge = np.abs(v[1:] - v[:-1]) / (2**p - 1)
    return v, e_runge

```

5.6.4 Kuadratura e Gausit

Listing 5.3: Gauss–Legendre në një interval të përgjithshëm.

```

from numpy.polynomial.legendre import leggauss

def gauss_legendre(f, a, b, n):
    xi, w = leggauss(n)
    x = 0.5*(b-a)*xi + 0.5*(a+b)
    return 0.5*(b-a) * np.sum(w * f(x))

```

Në notebook krahasohen numri i vlerësimeve të funksionit, gabimi dhe koha e ekzekutimit. Kjo e lidh kuadraturën klasike me motivimin për Monte Carlo në dimension të lartë.

Formulat dhe emërtimet shqip të diferencimit e integrimit numerik mbështeten te [1, 2, 3]; interpretimi fizik dhe krahasimi me Monte Carlo plotësohen nga [12, 14].

5.6.5 Nxjerrja sistematike e formulave të diferencimit

Nga zhvillimet Taylor

$$f(x+h) = f(x) + hf'(x) + \frac{h^2}{2}f''(x) + \frac{h^3}{6}f'''(x) + \mathcal{O}(h^4), \quad (5.11)$$

$$f(x-h) = f(x) - hf'(x) + \frac{h^2}{2}f''(x) - \frac{h^3}{6}f'''(x) + \mathcal{O}(h^4) \quad (5.12)$$

dalin dy kombinime të rëndësishme. Zbritja e barazimeve anulon termat çift dhe jep

$$f'(x) = \frac{f(x+h) - f(x-h)}{2h} - \frac{h^2}{6}f'''(x) + \mathcal{O}(h^4), \quad (5.13)$$

pra diferenca qendrore ka gabim të këputjes $\mathcal{O}(h^2)$. Mbledhja anulon termat tek dhe jep

$$f''(x) = \frac{f(x+h) - 2f(x) + f(x-h)}{h^2} - \frac{h^2}{12}f^{(4)}(x) + \mathcal{O}(h^4). \quad (5.14)$$

Koeficientët e formulave me më shumë pika gjenden duke kërkuar që kombinimi linear të riprodhojë saktë monomet $1, x, x^2, \dots$ deri në gradën e dëshiruar.

Gabimi i rumbullakimit në diferencën e parë rritet afërsisht si $u|f|/h$, ndërsa gabimi i këputjes për diferencën qendrore ulet si Ch^2 . Modeli

$$E(h) \simeq C_1 h^2 + C_2 \frac{u}{h} \quad (5.15)$$

ka minimum për $h_{\text{opt}} \sim u^{1/3}$. Kjo shpjegon formën në U të grafikut të gabimit: zvogëlimi i pakufizuar i hapit nuk rrit saktësinë.

5.6.6 Rregulla e trapezit dhe termi i gabimit

Në intervalin $[a, b]$, polinomi linear interpolues është

$$p_1(x) = f(a) \frac{b-x}{b-a} + f(b) \frac{x-a}{b-a}. \quad (5.16)$$

Integrimi i tij jep

$$T_1 = \frac{b-a}{2} [f(a) + f(b)]. \quad (5.17)$$

Nga mbetja e interpolimit ose nga Taylor-i rreth mesit merret

$$\int_a^b f(x) dx - T_1 = -\frac{(b-a)^3}{12} f''(\xi). \quad (5.18)$$

Për n nënintervale me hap $h = (b-a)/n$, mbledhja e gabimeve lokale jep gabim global

$$E_T = -\frac{b-a}{12} h^2 f''(\xi), \quad (5.19)$$

pra rregulla e përbërë është e rendit të dytë.

5.6.7 Rregulla e Simpsonit

Mbi dy nënintervale, integrohet polinomi kuadratik që kalon në $x_0, x_1 = x_0 + h$ dhe $x_2 = x_0 + 2h$:

$$S_2 = \frac{h}{3} [f(x_0) + 4f(x_1) + f(x_2)]. \quad (5.20)$$

Edhe pse interpoluesi ka gradë dy, simetria e bën rregullën të saktë edhe për polinomet kubike. Gabimi lokal është

$$-\frac{h^5}{90} f^{(4)}(\xi), \quad (5.21)$$

ndërsa përbërja në një interval të fiksuar jep gabim global $\mathcal{O}(h^4)$. Numri i nënintervaleve duhet të jetë çift. Një kod i mirë e verifikon këtë parakusht, në vend që të prodhojë në heshtje një rezultat të pakuptimtë.

5.6.8 Kuadratura e Gausit

Kërkohen nyje x_i dhe pesha w_i të tilla që

$$\int_{-1}^1 f(x) dx \approx \sum_{i=1}^n w_i f(x_i) \quad (5.22)$$

të jetë e saktë për gradën më të lartë të mundshme. Me $2n$ parametra përcaktohen momentet deri në gradën $2n-1$. Nyjet optimale janë rrënjët e polinomit Legendre P_n . Për $n=2$, simetria kërkon nyje $\pm a$ dhe pesha të barabarta w ; saktësia për 1 dhe x^2 jep $2w = 2$ dhe $2wa^2 = 2/3$, prandaj $w = 1$ dhe $a = 1/\sqrt{3}$.

Për intervalin $[a, b]$ përdoret transformimi

$$x = \frac{a+b}{2} + \frac{b-a}{2}\xi, \quad \text{dhe} \quad dx = \frac{b-a}{2} d\xi. \quad (5.23)$$

Avantazhi është saktësia e lartë me pak vlerësime; kufizimi është se nyjet nuk janë të futura natyrshëm, prandaj kontrolli adaptiv kërkon çifte rregullash ose nënndarje.

Listing 5.4: Simpson i përbërë me kontroll të dyfishimit të rrjetit.

```
import numpy as np

def simpson(f, a, b, n):
    if n <= 0 or n % 2:
        raise ValueError("n duhet të jetë numër pozitiv çift.")
    x = np.linspace(a, b, n + 1)
    h = (b - a) / n
    return (h / 3.0) * (f(x[0]) + f(x[-1])
        + 4.0*np.sum(f(x[1:-1:2]))
        + 2.0*np.sum(f(x[2:-1:2])))

def kontroll_simpson(f, a, b, n):
    I_h = simpson(f, a, b, n)
    I_h2 = simpson(f, a, b, 2*n)
    gabimi = abs(I_h2 - I_h) / (2.0**4 - 1.0)
    return I_h2, gabimi
```

5.6.9 Përmbledhje dhe ushtrime

Derivimi numerik është intrinsikisht më i ndjeshëm ndaj zhurmës, ndërsa integrimi ka efekt mesatarizues. Rendi formal duhet konfirmuar me një studim rrjeti dhe jo vetëm cituar.

1. Nxirrni formulën qendrore me pesë pika për $f'(x)$ dhe termin kryesor të gabimit.
2. Vërtetoni saktësinë kubike të Simpsonit duke integruar monomet $1, x, x^2, x^3$.
3. Ndërttoni Gauss–Legendre me tri pika nga momentet dhe simetria.
4. Llogaritni periodën e lavjerrësit si integral dhe krahasoni Simpsonin me Gauss-in.

5.6.10 Kuadratura adaptive dhe vlerësimi lokal i gabimit

Një rrjet uniform harxhon pika në rajone ku funksioni është i lëmuar dhe mund të mos zgjidhë rajone me ndryshim të shpejtë. Kuadratura adaptive e ndan intervalin aty ku gabimi i vlerësuar është i madh. Për Simpsonin, le të jenë $S(a, b)$ vlerësimi në të gjithë intervalin dhe

$$S_2 = S(a, m) + S(m, b), \quad m = \frac{a+b}{2}. \quad (5.24)$$

Meqë gabimi kryesor shkallëzohet si h^4 globalisht, vlerësimi i Richardson-it është

$$E \approx \frac{S_2 - S(a, b)}{2^4 - 1}. \quad (5.25)$$

Nëse $|E|$ është nën tolerancën lokale, pranohet $S_2 + E$; përndryshe të dy gjysmat ndahen rekursivisht. Toleranca globale ndahet ndërmjet intervaleve, për shembull përgjysmohet në çdo degë. Duhet vendosur thellësi maksimale për të shmangur rekursion të pafundëm pranë singulariteteve ose zhurmës.

Vlerësimi mund të dështojë kur dy rregullat japin rastësisht të njëjtin rezultat, kur funksioni ka një kulm shumë të ngushtë që nuk kapet nga pikat ose kur ka ndërprerje. Një algoritëm profesional kombinon rregulla të futura Gauss–Kronrod, zbulim të sjelljes së keqe dhe raport të statusit, jo vetëm një numër.

Integralet e papërshtatshme

Për një kufi të pafundëm, transformimi

$$x = \frac{t}{1-t}, \quad dx = \frac{dt}{(1-t)^2}, \quad 0 \leq t < 1, \quad (5.26)$$

e kthen $[0, \infty)$ në $[0, 1)$. Transformimi duhet zgjedhur sipas shuarjes së integrandit; Jakobi mund të krijojë një funksion të vështirë pranë $t = 1$. Një alternativë është prerja në R dhe kufizimi analitik i bishtit.

Për singularitetin integrueshëm $x^{-1/2}$ në zero, zëvendësimi $x = t^2$ jep

$$\int_0^1 \frac{g(x)}{\sqrt{x}} dx = 2 \int_0^1 g(t^2) dt, \quad (5.27)$$

që është i rregullt nëse g është i lëmuar. Njohja e strukturës analitike është më efektive se zvogëlimi brutal i hapit.

Integralet shumëpërmasore

Rregulli tensorial me n pika për bosht kërkon n^d vlerësime në d përmasa. Kjo është mallkimi i dimensionalitetit. Për dimensione të ulëta dhe integrandë të lëmuar, kuadratura tensoriale ose rrjetet e rralla mund të jenë shumë të sakta. Për dimensione të larta, Monte Carlo me gabim $N^{-1/2}$ bëhet konkurrues sepse eksponenti nuk varet shprehimisht nga d .

Megjithatë, dimensionin ndikon përmes variancës dhe gjeometrisë. Nëse rajoni D zë një pjesë jashtëzakonisht të vogël të kutisë kufizuese, metoda hit-or-miss ka variancë të madhe. Një parametrizim që gjeneron pika drejtpërdrejt në D është shumë më efikas. Për një disk, përdorimi i $r = R\sqrt{U}$ dhe $\theta = 2\pi V$ prodhon shpërndarje uniforme në sipërfaqe; zgjedhja $r = RU$ do të grumbullonte pika pranë qendrës.

Verifikimi me funksione prove

Një rutinë integrimi testohet me polinome të gradës së saktësisë, funksione periodike, kulme të ngushta dhe raste me zgjidhje të njohur. Rendi matet duke vizatuar gabimin ndaj hapit në shkallë log-log. Pjerrësia duhet të jetë pranë rendit teorik vetëm para se rrumbullakimi të dominojë. Raporti duhet të përmbajë numrin e vlerësimeve të funksionit; dy metoda me të njëjtin gabim mund të kenë kosto shumë të ndryshme.

Kapitulli 6

Ekuacionet diferenciale dhe dinamika numerike

Rezultatet e të nxënit. Studenti zbaton Eulerin, Runge–Kutta dhe skemat me shumë hapa; analizon gabimin lokal, global dhe stabilitetin; simulon rënien e lirë, lavjerrësin dhe problemin e dy trupave; dallon probleme fillestare e kufitare.

Orientim për studim. Filloni nga forma e rendit të parë $\dot{\mathbf{y}} = \mathbf{f}(t, \mathbf{y})$ dhe ndani gabimin lokal nga ai global. Për sistemet mekanike kontrolloni edhe strukturën: energjinë, momentin këndor, hapësirën e fazës dhe ngjarjet. Një trajektore që duket e lëmuar nuk është vetvetiu provë e saktësisë.

6.1 Problemi i vlerës fillestare

Për

$$\dot{\mathbf{y}} = \mathbf{f}(t, \mathbf{y}), \quad \mathbf{y}(t_0) = \mathbf{y}_0, \quad (6.1)$$

metoda e Eulerit është

$$\mathbf{y}_{n+1} = \mathbf{y}_n + h\mathbf{f}(t_n, \mathbf{y}_n). \quad (6.2)$$

Gabimi lokal është $\mathcal{O}(h^2)$ dhe gabimi global $\mathcal{O}(h)$. Euler-i është i dobishëm pedagogjikisht, por rrallë është zgjedhja përfundimtare.

Metoda e mesit dhe Heun janë të rendit të dytë. Metoda klasike RK4 përdor katër pjerrësi,

$$\mathbf{k}_1 = \mathbf{f}(t_n, \mathbf{y}_n), \quad (6.3)$$

$$\mathbf{k}_2 = \mathbf{f}(t_n + h/2, \mathbf{y}_n + h\mathbf{k}_1/2), \quad (6.4)$$

$$\mathbf{k}_3 = \mathbf{f}(t_n + h/2, \mathbf{y}_n + h\mathbf{k}_2/2), \quad (6.5)$$

$$\mathbf{k}_4 = \mathbf{f}(t_n + h, \mathbf{y}_n + h\mathbf{k}_3), \quad (6.6)$$

$$\mathbf{y}_{n+1} = \mathbf{y}_n + \frac{h}{6}(\mathbf{k}_1 + 2\mathbf{k}_2 + 2\mathbf{k}_3 + \mathbf{k}_4). \quad (6.7)$$

Çiftet e futura Runge–Kutta me dy rende japin vlerësim të gabimit dhe hap adaptiv.

6.2 Stabiliteti

Për ekuacionin provë $y' = \lambda y$, Euler-i jep $y_{n+1} = (1 + h\lambda)y_n$. Stabiliteti kërkon $|1 + h\lambda| < 1$. Një metodë mund të ketë rend të lartë dhe përsëri të jetë e papërshtatshme për problem të ngurtë. Ngurtësia shfaqet kur shkallë kohore shumë të ndryshme imponojnë hap shumë të vogël për metoda eksplicite.

6.3 Metodatat me shumë hapa

Adams–Bashforth përdor pjerrësi të mëparshme, për shembull

$$y_{n+1} = y_n + \frac{h}{2}(3f_n - f_{n-1}). \quad (6.8)$$

Këto metoda janë ekonomike pas nisjes, por kërkojnë histori dhe kujdes kur ndryshon hapi. Metodatat implicite Adams–Moulton dhe BDF kanë zona stabiliteti më të favorshme për probleme të ngurta.

6.4 Dinamikë Hamiltoniane

Në mekanikë, ruajtja afatgjatë e strukturës mund të jetë më e rëndësishme se gabimi lokal minimal. Skema leapfrog/Verlet është simplektike:

$$\mathbf{v}_{n+1/2} = \mathbf{v}_n + \frac{h}{2}\mathbf{a}(\mathbf{r}_n), \quad (6.9)$$

$$\mathbf{r}_{n+1} = \mathbf{r}_n + h\mathbf{v}_{n+1/2}, \quad (6.10)$$

$$\mathbf{v}_{n+1} = \mathbf{v}_{n+1/2} + \frac{h}{2}\mathbf{a}(\mathbf{r}_{n+1}). \quad (6.11)$$

Ajo është e kthyeshme në kohë dhe mban energjinë të kufizuar rreth vlerës së saktë, në vend që të krijojë drift sistematik.




Figura 6.1: Euler-i krijon drift energjie, ndërsa Verlet ruan më mirë strukturën afatgjatë.

6.5 Shembuj fizikë

6.5.1 Rënia në ajër

Për bosht pozitiv lart,

$$\dot{y} = v, \quad m\dot{v} = -mg - c_1v - c_2v|v|. \quad (6.12)$$

Modeli lejon krahasimin e rezistencës lineare dhe kuadratike, shpejtësisë terminale dhe ndjeshmërisë ndaj parametrave.

6.5.2 Lavjerrësi jolinear

$$\ddot{\theta} + \gamma\dot{\theta} + \frac{g}{L}\sin\theta = A\cos\Omega t. \quad (6.13)$$

Pa forcim dhe fërkim, energjia ruhet. Me forcim mund të shfaqen rezonancë, shumëstabilitet dhe kaos; hapi duhet kontrolluar ndaj periodës më të shkurtër.

6.5.3 Problemi i dy trupave

Në njësi të shkallëzuara,

$$\ddot{\mathbf{r}} = -\mu \frac{\mathbf{r}}{r^3}. \quad (6.14)$$

Kontrollet janë energjia, momenti këndor dhe ligji i tretë i Keplerit. Një orbitë që duket e mbyllur për pak perioda mund të ketë drift të ngadalshëm numerik.




Figura 6.2: Orbitë e integruar me skemë simplektike.

6.6 Problemet e vlerave kufitare

Në një problem kufitar, kushtet jepen në skaje të ndryshme. Metoda e qitjes e kthen problemin në një kërkim të kushtit fillestar që plotëson skajin tjetër. Diferencat e fundme e kthejnë ekuacionin në sistem algjebrik. Qitja mund të jetë e ndjeshme; formulimi matricor është shpesh më robust.

Lidhja me laboratorin. Laboratori krahason Euler, RK4 dhe Verlet për rënien, lavjerrësin dhe orbitën. Për çdo metodë vizatohen gabimi, energjia dhe kostoja kundrejt hapit.

Pyetje kontrolli

1. Dalloni rendin nga stabiliteti.
2. Pse një metodë simplektike mund të jetë më e mirë për orbita afatgjata?
3. Si verifikohet numerikisht një integruer orbital?

6.7 Integruerit kohorë në Python

6.7.1 Euler dhe Runge–Kutta i rendit të katërt

Listing 6.1: Dy integruer të përgjithshëm për sisteme ODE.

```
def euler(f, t, y0):  
    y = np.empty((len(t), len(np.atleast_1d(y0))), float)
```

```

y[0] = y0
for n, h in enumerate(np.diff(t)):
    y[n+1] = y[n] + h*f(t[n], y[n])
return y

def rk4(f, t, y0):
    y = np.empty((len(t), len(np.atleast_1d(y0))), float)
    y[0] = y0
    for n, h in enumerate(np.diff(t)):
        k1 = f(t[n], y[n])
        k2 = f(t[n]+h/2, y[n]+h*k1/2)
        k3 = f(t[n]+h/2, y[n]+h*k2/2)
        k4 = f(t[n]+h, y[n]+h*k3)
        y[n+1] = y[n] + h*(k1+2*k2+2*k3+k4)/6
    return y

```

6.7.2 Modeli i lavjerrësit

```

def lavjerresi(t, y, g=9.81, L=1.0, gamma=0.0):
    theta, omega = y
    return np.array([omega, -g/L*np.sin(theta) - gamma*omega])

def energjia(y, g=9.81, L=1.0):
    theta, omega = y.T
    return 0.5*(L*omega)**2 + g*L*(1-np.cos(theta))

```

Për rastin pa fërkim, drift-i i energjisë mat cilësinë afatgjatë. Për rastin me fërkim, energjia duhet të bjerë; ruajtja nuk është më kontrolli i duhur.

6.7.3 Velocity Verlet për gravitetin

Listing 6.2: Skema simplektike për orbitën.

```

def verlet_orbite(r0, v0, dt, n, mu=1.0):
    r = np.empty((n, 2)); v = np.empty((n, 2))
    r[0], v[0] = r0, v0
    def a(q):
        return -mu*q/np.linalg.norm(q)**3
    for k in range(n-1):
        v_half = v[k] + 0.5*dt*a(r[k])
        r[k+1] = r[k] + dt*v_half
        v[k+1] = v_half + 0.5*dt*a(r[k+1])
    return r, v

```

6.7.4 Protokoli i verifikimit

1. Euler-i testohet te $y' = \lambda y$, ku zgjidhja njihet.
2. RK4 testohet me përgjysmim hapi dhe pritet faktor gabimi afërsisht 2^4 .
3. Për orbitën kontrollohen energjia dhe momenti këndor.
4. Për lavjerrësin e këndit të vogël krahasohet perioda me $2\pi\sqrt{L/g}$.
5. Koha dhe memoria raportohen bashkë me gabimin.

Kujdes numerik. Në terminologjinë numerike shqipe përdoren *metodë e shtjelluar* dhe *metodë e pashtjelluar* për explicit dhe implicit. Në tekst jepen edhe termat ndërkombëtarë kur ndihmojnë studentin të lexojë dokumentacionin e bibliotekave.

Për terminologjinë *problem i vlerës fillestare*, *gabim lokal*, *gabim global*, *metodë e shtjelluar* dhe *qëndrueshmëri* janë përdorur gjerësisht burimet shqip [4, 1, 2, 3, 5].

6.7.5 Gabimi lokal dhe global i Eulerit

Për problemin $\mathbf{y}' = \mathbf{f}(t, \mathbf{y})$, Taylor-i i zgjidhjes së saktë është

$$\mathbf{y}(t_n + h) = \mathbf{y}(t_n) + h\mathbf{f}(t_n, \mathbf{y}(t_n)) + \frac{h^2}{2}\mathbf{y}''(\xi_n). \quad (6.15)$$

Euler-i heq termin e fundit; defekti lokal është $\mathcal{O}(h^2)$. Nëse $\mathbf{f}$ është Lipschitz në $\mathbf{y}$ me konstante L , gabimet plotësojnë afërsisht

$$\|\mathbf{e}_{n+1}\| \leq (1 + hL)\|\mathbf{e}_n\| + Ch^2. \quad (6.16)$$

Pas $N = T/h$ hapash dhe përdorimit të pabarazisë diskrete të Grönwall-it merret $\|\mathbf{e}_N\| \leq C_T h$: rendi global është një më i ulët se rendi i defektit lokal.

6.7.6 Qëndrueshmëria absolute

Ekuacioni provë $y' = \lambda y$ ndan metodën nga problemi. Euler-i jep

$$y_{n+1} = (1 + h\lambda)y_n. \quad (6.17)$$

Për një zgjidhje fizike që shuhet, $\Re\lambda < 0$, kërkohet $|1 + h\lambda| < 1$. Bashkësia $\{z : |1 + z| < 1\}$ është rajoni i qëndrueshmërisë absolute. Për $\lambda < 0$ real, kushti bëhet $0 < h < 2/|\lambda|$. Një hap mund të jetë mjaft i vogël për saktësi dhe përsëri i papërshtatshëm për qëndrueshmëri, ose anasjelltas.

Problemet e shtyllura përmbajnë shkallë kohore shumë të ndryshme. Metodot eksplicite detyrohen të ndjekin shkallën më të shpejtë edhe kur interesi fizik është te evolucioni i ngadaltë. Euler-i i prapëm ka faktor $1/(1 - h\lambda)$ dhe është i qëndrueshëm për të gjithë gjysmëplanin $\Re(h\lambda) < 0$, por kërkon zgjidhje algjebrike në çdo hap.

6.7.7 Runge–Kutta i rendit të katërt

Metodat Runge–Kutta përputhin zhvillimin Taylor pa llogaritur derivate të larta të $\mathbf{f}$. Skema klasike është

$$\mathbf{k}_1 = \mathbf{f}(t_n, \mathbf{y}_n), \quad (6.18)$$

$$\mathbf{k}_2 = \mathbf{f}(t_n + h/2, \mathbf{y}_n + h\mathbf{k}_1/2), \quad (6.19)$$

$$\mathbf{k}_3 = \mathbf{f}(t_n + h/2, \mathbf{y}_n + h\mathbf{k}_2/2), \quad (6.20)$$

$$\mathbf{k}_4 = \mathbf{f}(t_n + h, \mathbf{y}_n + h\mathbf{k}_3), \quad (6.21)$$

$$\mathbf{y}_{n+1} = \mathbf{y}_n + \frac{h}{6}(\mathbf{k}_1 + 2\mathbf{k}_2 + 2\mathbf{k}_3 + \mathbf{k}_4). \quad (6.22)$$

Koeficientët plotësojnë kushtet e rendit që barazojnë zhvillimin e skemës me Taylor-in deri në h^4 . Gabimi lokal është $\mathcal{O}(h^5)$ dhe globali $\mathcal{O}(h^4)$. Katër vlerësime të funksionit kushtojnë më shumë se Euler-i, por për një tolerancë të dhënë zakonisht lejojnë hapa shumë më të mëdhenj.

6.7.8 Metodat me shumë hapa

Integrimi i identitetit

$$\mathbf{y}(t_{n+1}) = \mathbf{y}(t_n) + \int_{t_n}^{t_{n+1}} \mathbf{f}(t, \mathbf{y}(t)) dt \quad (6.23)$$

dhe interpolimi i $\mathbf{f}$ në pika të mëparshme jep Adams–Bashforth. Për dy hapa,

$$\mathbf{y}_{n+1} = \mathbf{y}_n + h \left(\frac{3}{2}\mathbf{f}_n - \frac{1}{2}\mathbf{f}_{n-1} \right). \quad (6.24)$$

Metoda kursen vlerësime të funksionit, por nuk nis vetë: nevojitet një metodë njëhapëshe për gjendjet fillestare. Stabiliteti dhe rrënjët e polinomit karakteristik duhet të kontrollohen; një formulë me rend formal të lartë mund të jetë zero-e-paqëndrueshme.

6.7.9 Leapfrog, Verlet dhe dinamika Hamiltoniane

Për $\ddot{q} = a(q)$, velocity Verlet shkruhet

$$v_{n+1/2} = v_n + \frac{h}{2}a(q_n), \quad (6.25)$$

$$q_{n+1} = q_n + hv_{n+1/2}, \quad (6.26)$$

$$v_{n+1} = v_{n+1/2} + \frac{h}{2}a(q_{n+1}). \quad (6.27)$$

Skema është e kthyeshme në kohë dhe simplektike. Ajo nuk e ruan energjinë pikë për pikë, por ruan një Hamiltonian të modifikuar pranë atij të vërtetë; prandaj gabimi i energjisë lëkundet pa drift sistematik për kohë të gjata. Kjo është arsyeja strukturore pse Verlet-i mund të jetë më i mirë se një metodë me rend lokal më të lartë për orbita afatgjata.

6.7.10 Problemet kufitare

Për $y'' = f(x, y, y')$ me $y(a) = \alpha$, $y(b) = \beta$, metoda e qitjes e zëvendëson pjerrësinë e panjohur $s = y'(a)$ me parametër. Integrohet problemi fillestar dhe zgjidhet ekuacioni skalar

$$\Phi(s) = y(b; s) - \beta = 0. \quad (6.28)$$

Qitja është intuitive, por mund të jetë e keqkushtëzuar. Diferencat e fundme ndërtojnë një sistem algjebrik për të gjitha nyjet dhe janë më të përshtatshme kur zgjidhja rritet ose shuhet shumë shpejt.

6.7.11 Përmbledhje dhe ushtrime

Zgjedhja e integruesit varet jo vetëm nga rendi, por nga stabiliteti, struktura e sistemit dhe horizonti kohor.

1. Nxirrni rajonin e qëndrueshmërisë së Eulerit të përmirësuar.
2. Verifikoni rendet e Eulerit dhe RK4 me metodën e përgjysmimit të hapit.
3. Krahasoni RK4 dhe Verlet për orbitën e Keplerit duke matur energjinë dhe momentin këndor.
4. Zgjidhni një problem kufitar me qitje dhe me diferenca të fundme; diskutoni kushtëzimin.

6.7.12 Lavjerrësi jolinear dhe perioda e varur nga amplituda

Ekuacioni pa fërkim është

$$\ddot{\theta} + \frac{g}{L} \sin \theta = 0. \quad (6.29)$$

Linearizimi $\sin \theta \simeq \theta$ jep periodën $T_0 = 2\pi\sqrt{L/g}$, por modeli linear humbet varësinë nga amplituda. Nga ruajtja e energjisë,

$$\frac{1}{2}L^2\dot{\theta}^2 + gL(1 - \cos \theta) = gL(1 - \cos \theta_0), \quad (6.30)$$

merret perioda

$$T = 4\sqrt{\frac{L}{g}} \int_0^{\pi/2} \frac{d\phi}{\sqrt{1 - k^2 \sin^2 \phi}}, \quad k = \sin \frac{\theta_0}{2}. \quad (6.31)$$

Ky integral eliptik mund të llogaritet me kuadraturë dhe të krahasohet me periodën e nxjerrë nga integrimi kohor. Për amplituda të vogla,

$$\frac{T}{T_0} = 1 + \frac{\theta_0^2}{16} + \frac{11\theta_0^4}{3072} + \dots \quad (6.32)$$

Krahasimi i tri rrugëve — seria, kuadratura dhe ODE-ja — është verifikim i fuqishëm ndërmetodik.

Perioda numerike nga trajektorja matet me kalime në zero ose me kulme. Interpolimi ndërmjet dy hapave zvogëlon gabimin e kuantizimit kohor. Për integrim afatgjatë, monitorohet energjia. Një metodë jo simplektike mund të japë periodë të mirë për disa cikle dhe pastaj të krijojë drift që ndryshon artificialisht amplitudën.

Problemi i dy trupave dhe reduktimi në një trup

Për masa m_1, m_2 me pozicione $\mathbf{r}_1, \mathbf{r}_2$, forcat janë të barabarta e të kundërta. Qendra e masës

$$\mathbf{R} = \frac{m_1 \mathbf{r}_1 + m_2 \mathbf{r}_2}{m_1 + m_2} \quad (6.33)$$

lëviz në mënyrë uniforme, ndërsa koordinata relative $\mathbf{r} = \mathbf{r}_1 - \mathbf{r}_2$ plotëson

$$\mu \ddot{\mathbf{r}} = -\frac{Gm_1 m_2}{r^3} \mathbf{r}, \quad \mu = \frac{m_1 m_2}{m_1 + m_2}. \quad (6.34)$$

Pas pjesëtimit me μ merret $\ddot{\mathbf{r}} = -G(m_1 + m_2)\mathbf{r}/r^3$. Invariantet janë energjia

$$E = \frac{1}{2}\mu|\dot{\mathbf{r}}|^2 - \frac{Gm_1 m_2}{r} \quad (6.35)$$

dhe momenti këndor $\mathbf{L} = \mu \mathbf{r} \times \dot{\mathbf{r}}$. Për orbitë të lidhur me gjysmëbosht të madh a ,

$$T^2 = \frac{4\pi^2}{G(m_1 + m_2)} a^3. \quad (6.36)$$

Një laborator i plotë nxjerr periodën nga simulimi për disa a , përshtat pjerrësinë në shkallë logaritmike dhe kontrollon konstanten fizike, jo vetëm eksponentin $3/2$.

Gabimi në ngjarje dhe hapa adaptivë

Shumë probleme kërkojnë kohën e një ngjarjeje: goditja e tokës, kalimi në periapsis ose arritja e një pragu. Nëse ngjarja ndodh ndërmjet t_n dhe t_{n+1} , kthimi i thjeshtë i t_{n+1} ka gabim të rendit h . Duhet interpoluar funksioni i ngjarjes $g(t, y)$ dhe zgjidhur $g = 0$ brenda haptit. Bibliotekat ODE e bëjnë këtë me interpolues të dendur, por përdoruesi duhet të përcaktojë drejtimin e kalimit dhe nëse integrimi ndalet.

Kontrolli adaptiv përdor dy vlerësime me rende të ndryshme ose step-doubling. Nëse gabimi lokal i vlerësuar është e , hapi i ri zgjidhet afërsisht

$$h_{\text{ri}} = sh \left(\frac{\text{tol}}{e} \right)^{1/(p+1)}, \quad (6.37)$$

me faktor sigurie $s < 1$. Toleranca absolute mbron komponentët pranë zeros; toleranca relative shkallëzon komponentët e mëdhenj. Në sisteme me njësi të ndryshme nevojiten toleranca komponentore ose nondimensionalizim.

Kapitulli 7

Diferencat e fundme dhe simulimi i valëve

Rezultatet e të nxënit. Studenti diskretizon derivatet hapësinore; ndërton skemën për ekuacionin e valës; zbaton kushte fillestare e kufitare; analizon kushtin CFL, dispersimin dhe reflektimin; interpreton valët bredhëse e të qëndrueshme.

Orientim për studim. Skema numerike duhet nxjerrë duke zëvendësuar secilin derivat me formulën e tij të diferencave. Më pas kryhen analiza e qëndrueshmërisë, analiza e dispersimit dhe kontrolli i energjisë diskrete. Animacioni i valës shërben për interpretim, por kushti CFL dhe studimi i konvergjencës përbëjnë provën.

7.1 Nga PDE te rrjeti

Në rrjetin $x_j = j\Delta x$, $t^n = n\Delta t$, fusha përfaqësohet nga $u_j^n \approx u(x_j, t^n)$. Për ekuacionin e valës

$$\frac{\partial^2 u}{\partial t^2} = c^2 \frac{\partial^2 u}{\partial x^2}, \quad (7.1)$$

diferencat qendrore japin

$$u_j^{n+1} = 2u_j^n - u_j^{n-1} + r^2(u_{j+1}^n - 2u_j^n + u_{j-1}^n), \quad r = \frac{c\Delta t}{\Delta x}. \quad (7.2)$$

Skema është eksplicite dhe e rendit të dytë në kohë e hapësirë.

7.2 Kushtet fillestare dhe kufitare

Nevojiten zhvendosja $u(x, 0)$ dhe shpejtësia $u_t(x, 0)$. Hapi i parë ndërtohet me zhvillim Taylor. Skaji i fiksuar përdor Dirichlet, $u = 0$; skaji i lirë përdor Neumann, $u_x = 0$; një skaj thithës synon të minimizojë valën e reflektuar.

7.3 Stabiliteti CFL

Analiza von Neumann zëvendëson u_j^n me një mod Fourier $G^n e^{ikj\Delta x}$. Për skemën standarde në një përmasë merret kushti

$$r = \frac{c\Delta t}{\Delta x} \leq 1. \quad (7.3)$$

Ky kusht ka interpretim kauzal: domeni numerik i varësisë duhet të përmbajë domenin fizik. Shkelja e tij prodhon rritje eksponenciale të gabimeve.




Figura 7.1: Evolucioni i një pulsi brezhës dhe përafrimi te kufiri reflektues.

7.4 Dispersimi numerik

Edhe kur skema është stabile, frekuenca numerike nuk përputhet saktësisht me $\omega = ck$. Për rrjetin hapësinor,

$$k_{\text{eff}} = \frac{2}{\Delta x} \sin \frac{k\Delta x}{2}. \quad (7.4)$$

Modet me gjatësi vale pranë $2\Delta x$ përhapen gabim. Një rregull praktik kërkon shumë pika për gjatësi vale, jo vetëm dy.




Figura 7.2: Shpejtësia fazore numerike zvogëlohet për numra valorë të lartë.

7.5 Valët e qëndrueshme

Për skaje të fiksuara, zgjidhjet modale janë

$$u_n(x, t) = A_n \sin \frac{n\pi x}{L} \cos(\omega_n t + \phi_n), \quad \omega_n = \frac{n\pi c}{L}. \quad (7.5)$$

Simulimi mund të nxjerrë spektrin përmes transformimit Fourier të sinjalit në një pikë. Krahasoni me ω_n verifikon rrjetin dhe kushtet kufitare.

7.6 Reflektimi nga plazma

Në një plazmë të ftohtë pa fushë magnetike,

$$\varepsilon_r(\omega) = 1 - \frac{\omega_p^2}{\omega^2}, \quad \omega_p = \sqrt{\frac{n_e e^2}{m_e \varepsilon_0}}. \quad (7.6)$$

Kur $\omega < \omega_p$, numri valor bëhet imagjinar dhe vala zbehet: plazma reflekton. Për $\omega > \omega_p$, vala përhapet me dispersim. Në model numerik, fusha elektromagnetike mund të lidhet me lëvizjen e elektroneve; ruajtja e energjisë dhe reflektimi teorik shërbejnë si kontrolle.

Kujdes numerik. Një kufi i rrjetit mund të krijojë reflektim artificial që ngatërrohet me reflektimin fizik nga plazma. Së pari testohet skaji thithës në vakum, pastaj shtohet mjedisi dispersiv.

Lidhja me laboratorin. Laboratori krijon valë bredhëse dhe të qëndrueshme, mat shpejtësinë, teston CFL dhe realizon një ndërfaqe vakum–plazmë. Studentët krahasojnë koeficientin numerik të reflektimit me parashikimin teorik.

Pyetje kontrolli

1. Çfarë dallimi ka stabiliteti nga dispersimi numerik?
2. Pse duhen më shumë se dy pika për gjatësi vale?
3. Si ndahet reflektimi fizik nga reflektimi artificial i kufirit?

7.7 Algoritmi me diferenca të fundme për valën

7.7.1 Zbatimi vektorial

Listing 7.1: Skema eksplicite e valës me skaje të fiksuara.

```
def vale_1d(u0, v0, c, dx, dt, n_hapa):
    r = c*dt/dx
    if r > 1.0:
        raise ValueError("Shkelet kushti CFL: c*dt/dx <= 1.")
    u0 = np.asarray(u0, float)
    u_prev = u0.copy()
    lap = u0[2:] - 2*u0[1:-1] + u0[:-2]
    u = u0.copy()
    u[1:-1] = u0[1:-1] + dt*v0[1:-1] + 0.5*r*r*lap
    u[[0, -1]] = 0.0
    historia = [u_prev.copy(), u.copy()]
    for _ in range(1, n_hapa):
        u_next = np.zeros_like(u)
        u_next[1:-1] = (2*u[1:-1] - u_prev[1:-1]
                       + r*r*(u[2:] - 2*u[1:-1] + u[:-2]))
        u_prev, u = u, u_next
        historia.append(u.copy())
    return np.asarray(historia)
```

7.7.2 Kontrollet numerike

Skema kontrollohet në katër nivele:

1. kufijtë plotësohen në çdo hap;
2. amplituda nuk rritet pa shkak për $r \leq 1$;
3. shpejtësia e pulsit afrohet me c kur rafinohet rrjeta;

4. energjia diskrete mbetet afërsisht konstante për kufij reflektues.

Një energji diskrete e dobishme është

$$E^n = \frac{1}{2} \sum_j \left(\frac{u_j^{n+1} - u_j^n}{\Delta t} \right)^2 \Delta x + \frac{c^2}{2} \sum_j \left(\frac{u_{j+1}^n - u_j^n}{\Delta x} \right)^2 \Delta x. \quad (7.7)$$

7.7.3 Matja e reflektimit

Në dy sonda, një para dhe një pas ndërfaqes, regjistrohet $u(t)$. Amplituda incidente merret para mbërritjes së reflektimit, ndërsa amplituda e reflektuar në një dritare të vonuar. Koeficienti i amplitudës është $R_A = A_r/A_i$ dhe ai i energjisë $R_E \approx R_A^2$ vetëm kur impedancat janë të njëjta.

```
def amplitude_dritare(sinjal, i0, i1):
    segment = sinjal[i0:i1]
    return 0.5*(segment.max() - segment.min())
```

7.7.4 Reflektimi nga plazma

Për një frekuencë të vetme, së pari llogaritet ω_p dhe parashikohet nëse vala duhet të përhapet. Simulimi nuk interpretohet para se të testohet vakumi dhe kufiri thithës. Në notebook, dendësia elektronike ndryshohet gradualisht dhe ndërtohet grafiku $R(\omega/\omega_p)$.

Lidhja me laboratorin. I njëjti funksion duhet të përdoret për valën brendëse, valën e qëndrueshme dhe ndërfaqen e plazmës; ndryshojnë vetëm hyrjet dhe kushtet kufitare. Kjo e bën krahasimin fizik të kontrolluar.

Diskretizimi dhe terminologjia e ekuacioneve me derivate të pjesshme mbështeten te tradita e analizës numerike në shqip [2, 1, 6]; pjesa e valëve dhe plazmës plotësohet me tekstet e fizikës llogaritëse [13, 17].

7.7.5 Diskretizimi i ekuacionit të valës

Për

$$u_{tt} = c^2 u_{xx}, \quad (7.8)$$

vendosim $x_j = j\Delta x$ dhe $t^n = n\Delta t$. Diferencat qendrore japin

$$\frac{u_j^{n+1} - 2u_j^n + u_j^{n-1}}{\Delta t^2} = c^2 \frac{u_{j+1}^n - 2u_j^n + u_{j-1}^n}{\Delta x^2} + \mathcal{O}(\Delta t^2 + \Delta x^2). \quad (7.9)$$

Pas zgjidhjes për shtresën e re,

$$u_j^{n+1} = 2u_j^n - u_j^{n-1} + \lambda^2(u_{j+1}^n - 2u_j^n + u_{j-1}^n), \quad \lambda = \frac{c\Delta t}{\Delta x}. \quad (7.10)$$

Skema është eksplite dhe e rendit të dytë në hapësirë e kohë. Për të nisur, nga $u_t(x, 0) = v_0(x)$ merret

$$u_j^1 = u_j^0 + \Delta t v_{0,j} + \frac{\lambda^2}{2}(u_{j+1}^0 - 2u_j^0 + u_{j-1}^0). \quad (7.11)$$

7.7.6 Analiza von Neumann dhe kushti CFL

Provojmë një mod Fourier $u_j^n = G^n e^{ij\theta}$. Zëvendësimi në skemë jep

$$G^2 - 2 \left(1 - 2\lambda^2 \sin^2 \frac{\theta}{2} \right) G + 1 = 0. \quad (7.12)$$

Qëndrueshmëria kërkon që të dy rrënjët të kenë modul jo më të madh se një. Kjo ndodh kur

$$\lambda = \frac{c\Delta t}{\Delta x} \leq 1. \quad (7.13)$$

Interpretimi është kauzal: gjatë një hapi kohor, informacioni fizik përshkon largësinë $c\Delta t$, e cila nuk duhet të tejkalojë shtrirjen Δx që skema përdor për komunikim ndërmjet nyjeve.

7.7.7 Dispersimi numerik

Duke vendosur $G = e^{-i\omega\Delta t}$ merret lidhja e dispersimit

$$\sin^2\left(\frac{\omega\Delta t}{2}\right) = \lambda^2 \sin^2\left(\frac{k\Delta x}{2}\right). \quad (7.14)$$

Në vazhdësi $\omega = ck$, por në rrjet raporti ω/k varet nga k . Modet me gjatësi vale të krahasueshme me Δx përhapen me shpejtësi fazore të gabuar. Prandaj kushti CFL garanton qëndrueshmëri, jo saktësi. Një rregull praktik është të përdoren shumë pika për gjatësi vale dhe të kryhet studim rrjeti.

7.7.8 Kushtet kufitare dhe energjia

Kufiri i fiksuar përdor $u = 0$ dhe reflekton me ndryshim shenje. Kufiri i lirë përdor $u_x = 0$. Një kusht dalës i rendit të parë,

$$u_t + cu_x = 0, \quad (7.15)$$

lejon kalimin e valës djathtas, por diskretizimi i tij mund të reflektojë pjesërisht. Energjia e vazhdueshme

$$E(t) = \frac{1}{2} \int (u_t^2 + c^2 u_x^2) dx \quad (7.16)$$

është konstante për kufij pa fluks. Një energji diskrete e qëndrueshme është provë e fortë e implementimit.

7.7.9 Valët dhe reflektimi nga plazma

Zgjidhja e d'Alembert-it $u(x, t) = F(x - ct) + G(x + ct)$ ndan valët bredhëse djathtas e majtas. Në një interval me skaje të fiksuara, kushtet kufitare zgjedhin numra valorë diskretë $k_n = n\pi/L$ dhe frekuenca $\omega_n = ck_n$, duke formuar valë të qëndrueshme.

Në një plazmë të ftohtë pa fushë magnetike, permitiviteti relativ është

$$\varepsilon_r(\omega) = 1 - \frac{\omega_p^2}{\omega^2}, \quad \omega_p = \sqrt{\frac{n_e e^2}{m_e \varepsilon_0}}. \quad (7.17)$$

Për $\omega < \omega_p$, numri valor bëhet imagjinar dhe fusha shuhet brenda plazmës; vala reflektohet. Në modelin me përplasje, ω^2 zëvendësohet në mënyrë efektive nga $\omega(\omega + i\nu)$ dhe shfaqet absorbimi. Simulimi duhet të dallojë reflektimin fizik nga ai artificial i kufirit numerik.

7.7.10 Përmbledhje dhe ushtrime

Diskretizimi i valëve kërkon njëkohësisht konsistencë, CFL, rezolucion spektral dhe kushte kufitare fizikisht të përshtatshme.

1. Nxirrni formulën e shtresës së parë nga Taylor-i dhe shpejtësia fillestare.
2. Provoni kushtin CFL me analizën von Neumann.
3. Matni shpejtësinë fazore numerike për disa numra valorë.
4. Ndërttoni një valë të qëndrueshme dhe verifikoni frekuencat normale.
5. Simuloni kalimin nga vakumi në plazmë dhe ndani reflektimin fizik nga ai i kufirit të djathtë.

7.7.11 Koeficientët e reflektimit dhe transmetimit

Kur një valë harmonike bie normalisht mbi një ndërfaqe, fusha në anën e parë shkruhet si shumë e valës rënëse dhe të reflektuar,

$$E_1(z) = E_i e^{ik_1 z} + E_r e^{-ik_1 z}, \quad (7.18)$$

ndërsa në mjedisin e dytë $E_2(z) = E_t e^{ik_2 z}$. Vazhdimësia e komponentëve tangjencialë të fushave elektrike dhe magnetike në $z = 0$ jep

$$1 + r = t, \quad \frac{1 - r}{Z_1} = \frac{t}{Z_2}, \quad (7.19)$$

ku $r = E_r/E_i$, $t = E_t/E_i$ dhe Z_j është impedanca e mjedisit. Zgjidhja është

$$r = \frac{Z_2 - Z_1}{Z_2 + Z_1}, \quad t = \frac{2Z_2}{Z_2 + Z_1}. \quad (7.20)$$

Koeficienti energjetik i reflektimit është $R = |r|^2$; transmetimi duhet të përfshijë raportin e flukseve dhe nuk është gjithmonë thjesht $|t|^2$.

Për plazmën e ftohtë pa përplasje, $\varepsilon_r = 1 - \omega_p^2/\omega^2$. Kur $\omega > \omega_p$, numri valor është real dhe vala transmetohet pjesërisht. Kur $\omega < \omega_p$, k është imagjinar: fusha depërton vetëm me një gjatësi karakteristike dhe nuk transporton fuqi në thellësi në modelin ideal. Në plazmë me përplasje, permitiviteti bëhet kompleks; pjesa imagjinare përfaqëson humbjen dhe ndan absorbimin nga reflektimi.

Ndërfaqja në rrjet dhe gabimi numerik

Në diferencat e fundme, koeficienti material mund të ndryshojë ndërmjet nyjeve. Vendosja e ndërfaqes pikërisht në një nyje ose gjysmëhapi ndikon në rendin lokal. Një diskretizim konservativ i ekuacionit

$$u_{tt} = \partial_x (c(x)^2 u_x) \quad (7.21)$$

përdor flukse në gjysmënyje,

$$\left[\partial_x (c^2 u_x) \right]_j \approx \frac{c_{j+1/2}^2 (u_{j+1} - u_j) - c_{j-1/2}^2 (u_j - u_{j-1})}{\Delta x^2}. \quad (7.22)$$

Mesatarja e koeficientit në ndërfaqe duhet zgjedhur nga kushtet e vazhdimësisë; në probleme fluksi, mesatarja harmonike shpesh ruan më mirë fizikën se mesatarja aritmetike.

Për të matur reflektimin numerik, sinjali regjistrohet në një sondë para ndërfaqes. Simulimi referencë pa ndërfaqe jep pulsin rënës; diferenca izolon pulsin e reflektuar. Dritaret kohore duhet të ndajnë pulset dhe kufiri i majtë nuk duhet të reflektojë para përfundimit të matjes. Koeficienti mund të nxirret nga amplituda, energjia ose transformimi Fourier, por përkufizimi duhet të përputhet me formulën teorike.

Absorbimi kufitar

Një domen i fundëm duhet të imitojë hapësirën e pafundme. Kushti $u_t + cu_x = 0$ është i saktë për valë njëdrejtimëshe në një përmasë dhe incidencë normale, por jo për të gjitha frekuencat dhe këndet. Një shtresë amortizuese shton termin $-\sigma(x)u_t$, me σ që rritet gradualisht drejt kufirit. Rritja e menjëhershme e σ krijon vetë një ndërfaqe dhe reflektim.

Shtresa e përputhur në mënyrë të përsosur (PML) projektohet që impedanca të mbetet e përputhur në hyrje dhe vala të shuhet brenda shtresës. Implementimi i saj është më i ndërlikuar, por shërben si shembull se kushti kufitar është pjesë e modelit numerik. Në laborator mund të krahasohen kufiri i fiksuar, kushti dalës i rendit të parë dhe shtresa amortizuese duke matur energjinë e kthyer.

Bilanci diskret i energjisë

Për skemën qendrore, shpejtësia diskrete mund të vendoset në gjysmëhapa. Një energji e përshtatshme është

$$E^{n+1/2} = \frac{\Delta x}{2} \sum_j \left(\frac{u_j^{n+1} - u_j^n}{\Delta t} \right)^2 + \frac{c^2 \Delta x}{2} \sum_j \left(\frac{u_{j+1}^{n+1} - u_j^{n+1}}{\Delta x} \right) \left(\frac{u_{j+1}^n - u_j^n}{\Delta x} \right). \quad (7.23)$$

Për kufij të përshtatshëm dhe CFL të plotësuar, kjo madhësi mbetet e kufizuar. Monitorimi i saj zbulon paqëndrueshmërinë shumë më herët se inspektimi vizual i animacionit.

Kapitulli 8

Probabiliteti dhe variablat e rastit

Rezultatet e të nxënit. Studenti interpreton probabilitetin, shpërndarjen, pritjen dhe variancën; punon me ndryshore diskrete e të vazhdueshme; përdor ligjin e numrave të mëdhenj dhe teoremën qendrore kufitare; raporton gabimin statistik.

Orientim për studim. Ky kapitull krijon gjuhën e pjesës Monte Carlo. Dalloni variablin fizik nga vlerësuesi i ndërtuar prej mostrës; dalloni devijimin standard nga gabimi standard. Në simulimet dinamike ndiqni jo vetëm histogramin, por edhe mesataren kumulative, intervalin e besimit dhe ligjin $N^{-1/2}$.

8.1 Ngjarjet dhe probabiliteti

Hapësira e mostrave Ω përmban rezultatet elementare. Probabiliteti plotëson $P(A) \geq 0$, $P(\Omega) = 1$ dhe aditivitetin për ngjarje të papajtueshme. Probabiliteti kushtor është

$$P(A|B) = \frac{P(A \cap B)}{P(B)}. \quad (8.1)$$

Pavarësia kërkon $P(A \cap B) = P(A)P(B)$. Ajo është supozim i fortë dhe nuk duhet ngatërruar me korrelacionin zero.

Teorema e Bayes-it,

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}, \quad (8.2)$$

ndan informacionin paraprak nga informacioni i të dhënave. Në fizikën eksperimentale ajo shfaqet në klasifikim, zbulim sinjali dhe vlerësim parametrash.

8.2 Ndryshoret e rastit

Për ndryshore diskrete X , funksioni masor $p(x)$ plotëson $\sum_x p(x) = 1$. Për ndryshore të vazhdueshme, dendësia $f(x)$ plotëson $\int f(x) dx = 1$ dhe probabiliteti merret nga integrali. Funksioni kumulativ është $F(x) = P(X \leq x)$.

Pritja dhe varianca janë

$$\mathbb{E}[X] = \sum_x xp(x) \quad \text{ose} \quad \int xf(x) dx, \quad \text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2]. \quad (8.3)$$

Për një funksion g , $\mathbb{E}[g(X)]$ llogaritet mbi shpërndarjen e X ; në përgjithësi $g(\mathbb{E}X) \neq \mathbb{E}[g(X)]$.

8.3 Shpërndarje të rëndësishme

Bernoulli përshkruan një provë me sukses p . Shuma e n provave të pavarura është binomiale,

$$P(K = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad \mathbb{E}K = np, \quad \text{Var } K = np(1-p). \quad (8.4)$$




Figura 8.1: Shpërndarja e numrit të stemave në 20 hedhje të një monedhe të paanshme.

Poisson përshkruan numërimet të rralla me normë λ : $P(K = k) = e^{-\lambda} \lambda^k / k!$. Eksponecialja përshkruan kohën ndërmjet ngjarjeve Poisson dhe ka vetinë pa kujtesë. Gauss-i del nga mbledhja e shumë kontributeve të vogla; parametrat e tij janë mesatarja dhe varianca.

8.4 Kovarianca dhe përhapja e pacaktueshmërisë

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)], \quad \rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}. \quad (8.5)$$

Për $z = f(\mathbf{x})$ dhe pacaktueshmëri të vogla,

$$\text{Var}(z) \approx \nabla f^T \Sigma \nabla f, \quad (8.6)$$

ku Σ është matrica e kovariancës. Termat jashtë diagonales nuk mund të hiqen kur hyrjet janë të korreluara.

8.5 Ligji i numrave të mëdhenj dhe CLT

Mesatarja e mostrës

$$\bar{X}_N = \frac{1}{N} \sum_{i=1}^N X_i \quad (8.7)$$

afrohet te μ . Për variancë të fundme, teorema qendrore kufitare jep

$$\frac{\sqrt{N}(\bar{X}_N - \mu)}{\sigma} \Rightarrow \mathcal{N}(0, 1). \quad (8.8)$$

Gabimi standard është $s/\sqrt{N}$. Katërfishimi i mostrave përgjysmon gabimin, një ligj që përcakton koston e Monte Carlo-s.

Kujdes numerik. Formula $s/\sqrt{N}$ kërkon mostra të pavarura ose një korrigjim për korrelacionin. Në seri Markov, madhësia efektive e mostrës mund të jetë shumë më e vogël se N .




Figura 8.2: Shpërndarja e mesatares së ndryshoreve uniforme afrohet me formën Gauss kur rritet numri i termave.

Lidhja me laboratorin. Laboratori simulon hedhjen e monedhës, ndërton intervale besimi dhe kontrollon shkallëzimin $N^{-1/2}$. Diskutohet dallimi ndërmjet luhatjes fizike dhe gabimit të vlerësuesit.

Pyetje kontrolli

1. Dalloni devijimin standard të popullatës nga gabimi standard i mesatares.
2. Kur kovarianca është thelbësore në përhapjen e pacaktueshmërisë?
3. Pse CLT nuk garanton konvergjencë të shpejtë për çdo shpërndarje?

8.6 Algoritmet bazë të simulimit probabilitar

8.6.1 Hedhja e monedhës

Listing 8.1: Vlerësimi i probabilitetit dhe gabimit standard.

```
import numpy as np

def monedha(N, p=0.5, seed=2026):
    rng = np.random.default_rng(seed)
    x = rng.random(N) < p
    p_hat = x.mean()
    se = np.sqrt(p_hat*(1-p_hat)/N)
    return p_hat, se, x

for N in [100, 1_000, 10_000, 100_000]:
    p_hat, se, _ = monedha(N)
    print(N, p_hat, se)
```

Vlerësimi duhet përsëritur për shumë fara për të parë shpërndarjen e $\hat{p}$, jo vetëm një trajektore të vetme.

8.6.2 Intervali Wilson

Intervali normal $\hat{p} \pm z\sqrt{\hat{p}(1-\hat{p})/N}$ sillet dobët për N të vogël ose $\hat{p}$ pranë 0 e 1. Intervali Wilson është më i qëndrueshëm:

$$\frac{\hat{p} + z^2/(2N) \pm z\sqrt{\hat{p}(1-\hat{p})/N + z^2/(4N^2)}}{1 + z^2/N}. \quad (8.9)$$

```
def interval_wilson(k, n, z=1.96):
    phat = k/n
    den = 1 + z*z/n
    q = phat + z*z/(2*n)
    d = z*np.sqrt(phat*(1-phat)/n + z*z/(4*n*n))
    return (q-d)/den, (q+d)/den
```

8.6.3 Përhapja Monte Carlo e pacaktueshmërisë

Listing 8.2: Përhapja e hyrjeve të korreluara.

```
rng = np.random.default_rng(7)
mu = np.array([10.0, 2.0])
Sigma = np.array([[0.25, 0.08], [0.08, 0.04]])
x = rng.multivariate_normal(mu, Sigma, size=200_000)
z = x[:, 0] / x[:, 1]**2
print(np.mean(z), np.std(z), np.quantile(z, [0.025, 0.975]))
```

Krahasimi me linearizimin $\nabla f^T \Sigma \nabla f$ tregon kur jolineariteti dhe asimetria bëhen të rëndësishme.

8.6.4 Kontrolli i CLT-së

Për çdo N gjenerohen shumë eksperimente të pavarura dhe studiohet

$$Z = \frac{\sqrt{N}(\bar{X} - \mu)}{\sigma}. \quad (8.10)$$

Histogrami i Z krahasohet me Gauss-in standard. Termi i rekomanduar është *shpërndarje normale* ose *Gauss*, jo përkthime jo të qëndrueshme.

Kujdes numerik. *Luhatje* përshkruan variacionin e një madhësie të rastit; *gabim standard* përshkruan pacaktueshmërinë e një vlerësuesi. Ato nuk janë sinonime.

Për probabilitetin, statistikën dhe terminologjinë e vlerësimit janë konsultuar materiale universitare shqip [9, 7, 8]; lidhja me simulimin fizik mbështetet te [12, 17].

8.6.5 Nga aksiomat te ndryshorja e rastit

Një hapësirë probabilitare $(\Omega, \mathcal{F}, P)$ përbëhet nga rezultatet e mundshme, ngjarjet e matshme dhe masa e probabilitetit. Ndryshorja e rastit $X : \Omega \rightarrow \mathbb{R}$ e shndërron rezultatin elementar në madhësi numerike. Për një ndryshore diskrete,

$$\mathbb{E}[g(X)] = \sum_x g(x)p_X(x), \quad (8.11)$$

ndërsa për një ndryshore të vazhdueshme,

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x)f_X(x) dx. \quad (8.12)$$

Varianca del nga identiteti

$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - \mu^2. \quad (8.13)$$

Ajo ka njësinë në katror të X ; devijimi standard ka të njëjtën njësi si madhësia fizike.

8.6.6 Hedhja e monedhës dhe shpërndarja binomiale

Le të jetë $X_i \in \{0, 1\}$ treguesi i suksesit me $P(X_i = 1) = p$. Për prova të pavarura, $S_N = \sum_i X_i$ ka shpërndarje binomiale. Numri i vargjeve me k suksese është $\binom{N}{k}$, prandaj

$$P(S_N = k) = \binom{N}{k} p^k (1-p)^{N-k}. \quad (8.14)$$

Nga lineariteti i pritjes dhe pavarësia,

$$\mathbb{E}[S_N] = Np, \quad \text{Var}(S_N) = Np(1-p). \quad (8.15)$$

Vlerësuesi $\hat{p} = S_N/N$ është i paanshëm dhe ka variancë $p(1-p)/N$. Kështu gabimi standard ulet si $N^{-1/2}$, jo si N^{-1} .

8.6.7 Ligji i numrave të mëdhenj dhe teorema qendrore kufitare

Ligji i numrave të mëdhenj pohon se mesatarja e mostrës $\bar{X}_N$ afrohet me μ kur N rritet. Teorema qendrore kufitare jep më shumë: për ndryshore të pavarura me variancë të fundme,

$$\frac{\sqrt{N}(\bar{X}_N - \mu)}{\sigma} \xrightarrow{d} \mathcal{N}(0, 1). \quad (8.16)$$

Kjo justifikon intervalin asimptotik $\bar{X} \pm z_{1-\alpha/2} s / \sqrt{N}$. Për mostra të vogla me variancë të panjohur përdoret shpërndarja Student. Për Bernoulli me p pranë zeros ose njësisë, intervali normal mund të dalë jashtë $[0, 1]$; intervali Wilson ka sjellje më të mirë.

8.6.8 Kovarianca dhe përhapja e pacaktueshmërisë

Për vektorin $\mathbf{X}$ me kovariancë Σ dhe $Y = g(\mathbf{X})$, linearizimi rreth mesatares jep

$$g(\mathbf{X}) \simeq g(\boldsymbol{\mu}) + \nabla g(\boldsymbol{\mu})^T (\mathbf{X} - \boldsymbol{\mu}), \quad (8.17)$$

prandaj

$$\text{Var}(Y) \simeq \nabla g(\boldsymbol{\mu})^T \Sigma \nabla g(\boldsymbol{\mu}). \quad (8.18)$$

Termat jashtë diagonales mund ta rrisin ose ta ulin pacaktueshmërinë. Supozimi i pavarësisë pa argument mund të jetë po aq problematik sa neglizhimi i një burimi gabimi.

Kur linearizimi nuk është i mjaftueshëm, përhapja Monte Carlo gjeneron $\mathbf{X}^{(r)}$ nga shpërndarja e hyrjeve dhe llogarit $Y^{(r)} = g(\mathbf{X}^{(r)})$. Shpërndarja empirike e Y mund të jetë asimetrike; atëherë raportohen kuantilet dhe jo vetëm mesatarja me devijimin standard.

Listing 8.3: Përhapje Monte Carlo e hyrjeve të korreluara.

```
import numpy as np

rng = np.random.default_rng(2026)
mes = np.array([2.0, 3.0])
kov = np.array([[0.04, 0.03],
                [0.03, 0.09]])
x = rng.multivariate_normal(mes, kov, size=100_000)
y = x[:, 0]**2 / x[:, 1]
q025, q50, q975 = np.quantile(y, [0.025, 0.5, 0.975])
print(q50, q025, q975)
```

8.6.9 Përmbledhje dhe ushtrime

Probabiliteti përshkruan modelin e rastësisë; statistika përdor të dhënat për të nxjerrë përfundime rreth këtij modeli. Pacaktueshmëria e rezultatit duhet lidhur me një procedurë kampionimi dhe me supozimet e saj.

1. Nxirrni mesataren dhe variancën e binomiales nga funksioni gjenerues i momenteve.
2. Krahasoni intervalin normal dhe Wilson për $k = 1$ sukses në $N = 20$ prova.
3. Provoni me simulim shkallëzimin $N^{-1/2}$ dhe shpjegoni shpërndarjen e pjerrësive të matura.
4. Për periodën $T = 2\pi\sqrt{L/g}$, nxirrni përhapjen lineare të pacaktueshmërisë dhe krahasojeni me Monte Carlo.

8.6.10 Vlerësuesi, animi dhe gabimi kuadratik mesatar

Një vlerësues $\hat{\theta}$ është ndryshore rasti sepse varet nga mostra. Animi është

$$\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta. \quad (8.19)$$

Gabimi kuadratik mesatar ndahet si

$$\mathbb{E}[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta})^2. \quad (8.20)$$

Ky identitet tregon se vlerësuesi i paanshëm nuk është automatikisht optimal: një anim i vogël mund të pranohet nëse ul ndjeshëm variancën. Në simulimet fizike, kjo shfaqet te rregullimi i modeleve, prerja e peshave ekstreme ose vlerësuesit me kontroll variabël.

Varianca e mostrës me emërues $N - 1$ është e paanshme për variancën e popullatës kur mostrat janë të pavarura,

$$s^2 = \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2. \quad (8.21)$$

Emëruesi $N - 1$ vjen sepse mbetjet kanë shumën zero dhe vetëm $N - 1$ shkallë lirie. Për seri të korreluara, formula ende përshkruan shpërndarjen marginale, por $s/\sqrt{N}$ nuk është gabimi standard i mesatares.

Intervalet e besimit dhe interpretimi

Një interval besimi 95% nuk do të thotë se, pasi të dhënat janë vëzhguar, parametri fiks ka probabilitet 95% të jetë brenda atij intervali. Interpretimi frekuentist është se procedura prodhon intervale që mbulojnë parametrin në 95% të përsëritjeve ideale. Ky dallim është i rëndësishëm në raportim.

Për një mesatare me variancë të panjohur dhe të dhëna Gauss të pavarura,

$$\frac{\bar{X} - \mu}{s/\sqrt{N}} \sim t_{N-1}. \quad (8.22)$$

Për mostra të mëdha, kuantilet t afrohen me ato normale. Për probabilitete binomiale, intervali Wilson ose një interval i bazuar në gjasë është më i qëndrueshëm se intervali Wald, sidomos pranë kufijve.

Bootstrap-i

Bootstrap-i joparametrik trajton shpërndarjen empirike si përafrim të popullatës. Nga mostra origjinale me N elemente krijohen mostra të reja me rizgjedhje dhe të njëjtën madhësi. Për secilën llogaritet statistiku $T^{*(b)}$. Shpërndarja e këtyre statistikëve vlerëson variancën, animin dhe intervalet.

Metoda funksionon mirë për shumë statistikë të lëmuar, por nuk është universale. Për maksimumin, bishtat ekstremë dhe mostra shumë të vogla mund të jetë e dobët. Për seri kohore nuk duhet rizgjedhur çdo pikë veçmas, sepse prishet varësia; përdoret bootstrap në blloqe. Në Monte Carlo me peshë, skema e rizgjedhjes duhet të respektojë mënyrën si u krijuan peshat.

Kovarianca nga burime të përbashkëta

Në eksperimente fizike, dy madhësi shpesh varen nga i njëjti kalibrim. Nëse $x = x_0(1 + \epsilon)$ dhe $y = y_0(1 + \epsilon)$ ndajnë të njëjtin gabim relativ, raporti x/y anulon gabimin e përbashkët në rendin e parë. Trajtimi i x dhe y si të pavarura do ta mbivlerësonte pacaktueshmërinë. Në diferencën $x - y$, i njëjti korrelacion mund ta ulë ose ta rrisë efektin në varësi të shenjave.

Matrica e kovariancës duhet të jetë simetrike pozitivisht gjysmë e përcaktuar. Një matricë e ndërtuar nga koeficientë korrelacioni të papajtueshëm mund të ketë vlera vetjake negative dhe të mos përfaqësojë asnjë shpërndarje. Para kampionimit shumënormal kontrollohen simetria dhe spektri; vlera të vogla negative nga rrumbullakimi mund të kërkojnë korrigjim të dokumentuar.

Ligji total i variancës

Kur modeli varet nga parametri i rastit Θ dhe nga zhurma e brendshme,

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y \mid \Theta)] + \text{Var}(\mathbb{E}[Y \mid \Theta]). \quad (8.23)$$

Termi i parë mat variabilitetin brenda realizimeve për parametra të fiksuar; i dyti mat ndryshimin ndërmjet parametrave. Kjo ndarje është e dobishme në simulimin e zbritjes së mjetit hapësinor, ku mund të dallohen ndryshimet atmosferike nga zhurma e sensorit ose e kontrollit.

Kapitulli 9

Numrat pseudorastësorë dhe kampionimi

Rezultatet e të nxënit. Studenti shpjegon gjeneratorët pseudorastësorë, farën dhe gjendjen; zbaton transformimin e anasjelltë, Box–Muller dhe kampionimin me refuzim; teston shpërndarjen dhe pavarësinë; shmang përdorimin e gabuar paralel.

Orientim për studim. Një gjenerator determinist prodhon një varg që përdoret si burim pseudorastësie; cilësia e tij vlerësohet nga testi dhe nga qëllimi i simulimit. Për çdo metodë kampionimi nxirrni shpërndarjen e daljes nga shpërndarja e hyrjes dhe matni efikasitetin. Fara ruhet si pjesë e rezultatit, jo si hollësi programimi.

9.1 Pseudo-rastësia

Një gjenerator pseudorastësor është algoritëm determinist që prodhon një varg me veti statistike të ngjashme me mostrat e pavarura uniforme. Gjeneratori kongruencial linear është

$$x_{n+1} = (ax_n + c) \bmod m, \quad u_n = x_n/m. \quad (9.1)$$

Zgjedhja e parametrave përcakton periodën dhe korrelacionet. Gjeneratorët modernë kanë gjendje më të madhe dhe teste më të mira, por nuk janë automatikisht kriptografikisht të sigurt.

Fara përcakton vargun. Ruajtja e saj mundëson riprodhim. Megjithatë, përdorimi i të njëjtës farë në procese paralele mund të krijojë vargje identike; duhen nënrryma të pavarura ose mekanizma *spawn*.




Figura 9.1: Grafiku (u_n, u_{n+1}) zbulon strukturë rrjete në një gjenerator të dobët.

9.2 Testet statistike

Histogrami kontrollon uniformitetin njëpërmator, por nuk zbulon çdo varësi. Përdoren testi χ^2 , Kolmogorov–Smirnov, autokorrelacioni dhe teste spektrale. Një vlerë- p nuk provon rastësinë; ajo vetëm mat përputhjen me një statistikë të zgjedhur. Testimi duhet të përfshijë shumë struktura dhe gjatësi vargu.

9.3 Transformimi i anasjelltë

Nëse $U \sim \mathcal{U}(0, 1)$ dhe F është kumulativi i synuar, atëherë

$$X = F^{-1}(U) \quad (9.2)$$

ka shpërndarje F . Për eksponencialen me normë λ ,

$$X = -\frac{1}{\lambda} \ln(1 - U). \quad (9.3)$$




Figura 9.2: Mostrat e gjeneruara me transformimin e anasjelltë dhe dendësia teorike.

9.4 Mostrat Gauss

Transformimi Box–Muller përdor dy uniforme të pavarura:

$$Z_1 = \sqrt{-2 \ln U_1} \cos(2\pi U_2), \quad (9.4)$$

$$Z_2 = \sqrt{-2 \ln U_1} \sin(2\pi U_2). \quad (9.5)$$

Kjo rrjedh nga kalimi në koordinata polare të dendësisë Gauss dydimensionale. Bibliotekat moderne mund të përdorin algoritme më të shpejta, por parimi mbetet shembull i rëndësishëm i transformimit të ndryshoreve.

9.5 Kampionimi me refuzim

Le të jetë $f(x)$ dendësia synuar dhe $g(x)$ propozimi, me $f(x) \leq M g(x)$. Gjenerohet $X \sim g$ dhe pranohet nëse

$$U \leq \frac{f(X)}{M g(X)}. \quad (9.6)$$

Norma mesatare e pranimit është $1/M$. Propozimi duhet të mbulojë të gjithë mbështetjen e f dhe bishtat e tij nuk duhet të jenë më të lehtë. Në dimension të lartë, refuzimi global bëhet shpesh joefikas.

9.6 Kampionimi i rëndësisë

Për një pritje nën p ,

$$\mathbb{E}_p[h(X)] = \int h(x) \frac{p(x)}{q(x)} q(x) dx \approx \frac{1}{N} \sum_{i=1}^N h(X_i) w(X_i), \quad X_i \sim q. \quad (9.7)$$

Propozimi q duhet të vendosë mostra atje ku $|h|p$ është i madh. Peshat shumë të pabarabarta japin madhësi të vogël efektive të mostrës,

$$N_{\text{eff}} \approx \frac{(\sum_i w_i)^2}{\sum_i w_i^2}. \quad (9.8)$$

Kujdes numerik. Ndryshimi i farës nuk zëvendëson analizën statistike. Rezultati duhet të jetë i qëndrueshëm ndaj disa farave, ndërsa raportimi duhet të japë vlerësuesin dhe gabimin standard.

Lidhja me laboratorin. Laboratori gjeneron uniforme, eksponenciale dhe Gauss; përdor histogramin, CDF empirike dhe autokorrelacionin; krahason transformimin e anasjelltë me refuzimin.

Pyetje kontrolli

1. Pse një histogram uniform nuk provon pavarësinë?
2. Çfarë ndodh nëse $Mg(x) < f(x)$ në një zonë?
3. Si organizohen vargjet pseudorastësore në llogaritje paralele?

9.7 Algoritmet e gjenerimit dhe kampionimit

9.7.1 Gjeneratori dhe gjendja e tij

Në NumPy rekomandohet objekti `Generator`. Ai e bën burimin e rastësisë të dukshëm dhe shmang varësinë nga një gjendje globale.

```
rng = np.random.default_rng(2026)
u = rng.random(1_000_000)
print(u.mean(), u.var()) # priten afërsisht 1/2 dhe 1/12
```

9.7.2 Transformimi i anasjelltë

Listing 9.1: Mostra eksponenciale pa përdorur funksionin e gatshëm.

```
def eksponenciale_anasjelltas(rng, lam, size):
    u = rng.random(size)
    return -np.log1p(-u) / lam

x = eksponenciale_anasjelltas(rng, lam=1.5, size=100_000)
print(x.mean(), 1/1.5)
```

Funksioni `log1p(-u)` është më i saktë kur u është i vogël. Kontrollohen mesatarja, varianca dhe CDF-ja empirike.

9.7.3 Box–Muller

Listing 9.2: Gjenerimi i çifteve Gauss standarde.

```
def box_muller(rng, n):
    u1 = rng.random(n)
```

```

u2 = rng.random(n)
r = np.sqrt(-2.0*np.log(u1))
phi = 2.0*np.pi*u2
return r*np.cos(phi), r*np.sin(phi)

```

Testohet jo vetëm histogrami i secilit komponent, por edhe kovarianca ndërmjet tyre.

9.7.4 Kampionimi me refuzim

Listing 9.3: Refuzimi për një dendësi në interval të fundmë.

```

def refuzim(rng, f, a, b, M, n):
    pranuar = []
    prova = 0
    while len(pranuar) < n:
        x = rng.uniform(a, b)
        y = rng.uniform(0.0, M)
        prova += 1
        if y <= f(x):
            pranuar.append(x)
    return np.asarray(pranuar), n/prova

```

Këtu M është kufi i sipërm i f në $[a, b]$. Në formulimin me propozim të përgjithshëm, kontrollohet $f(x) \leq Mg(x)$.

9.7.5 Testet minimale

1. krahasohen momentet empirike me ato teorike;
2. vizatohet CDF-ja empirike;
3. testohet autokorrelacioni;
4. përsëritet me fara të ndryshme;
5. matet norma e pranimit dhe kostoja për mostër.

Termi *kampionim* përdoret për sampling dhe *mostër* për sample. *Gjenerator pseudorastësor* thekson natyrën deterministe të vargut.

Terminologjia probabilitare shqip mbështetet te [9, 7, 8]; algoritmet e gjenerimit dhe testimit krahasohen me trajtimet standarde [14, 19].

9.7.6 Gjeneratorët pseudorastësorë si sisteme dinamike diskrete

Një gjenerator pseudorastësor është një algoritëm determinist me gjendje të fundme. Gjeneratori kongruencial linear,

$$x_{n+1} = (ax_n + c) \bmod m, \quad u_n = \frac{x_n}{m}, \quad (9.9)$$

e bën këtë strukturë të dukshme. Për shkak se ka vetëm m gjendje, vargu duhet të përsëritet; perioda dhe korrelacionet varen nga parametrat. Edhe kur histogrami i u_n duket uniform, çiftet (u_n, u_{n+1}) mund të shtrihen në një numër të vogël hiperplanesh. Prandaj uniformiteti njëpërmasor nuk provon cilësinë shumëpërmasore.

Gjeneratorët modernë kanë gjendje shumë më të madhe dhe cilësi të testuar, por mbeten deterministë. Fara përcakton trajektoren. Ruajtja e farës siguron riprodhueshmëri, ndërsa përdorimi i së njëjtës farë për eksperimente që duhet të jenë të pavarura mund të krijojë korrelacione artificiale.

9.7.7 Transformimi i anasjellë

Nëse $U \sim \mathcal{U}(0, 1)$ dhe F është funksioni kumulativ i vazhdueshëm e rritës, atëherë

$$X = F^{-1}(U) \quad (9.10)$$

ka funksion kumulativ F , sepse

$$P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x). \quad (9.11)$$

Për eksponencialen $F(x) = 1 - e^{-\lambda x}$ merret

$$X = -\frac{1}{\lambda} \ln(1 - U). \quad (9.12)$$

Shkrimi $\log 1p(-U)$ është më i saktë kur U është i vogël. Metoda është e thjeshtë kur inversi është i njohur; për shpërndarje të tjera nevojitet zgjidhje numerike ose metodë alternative.

9.7.8 Box–Muller për mostrën Gauss

Dy ndryshore Gauss standarde kanë dendësi të përbashkët

$$f(z_1, z_2) = \frac{1}{2\pi} \exp[-(z_1^2 + z_2^2)/2]. \quad (9.13)$$

Në koordinata polare, elementi i sipërfaqes është $r dr d\theta$, kështu që Θ është uniforme në $[0, 2\pi)$ dhe R^2 ka shpërndarje eksponenciale me parametër $1/2$. Me U_1, U_2 uniforme të pavarura,

$$R = \sqrt{-2 \ln U_1}, \quad \Theta = 2\pi U_2, \quad (9.14)$$

dhe

$$Z_1 = R \cos \Theta, \quad Z_2 = R \sin \Theta. \quad (9.15)$$

Duhet shmangur $U_1 = 0$. Mostrat verifikohen jo vetëm me histogram, por edhe me mesatare, variancë, kuantile dhe korrelacion ndërmjet Z_1 e Z_2 .

9.7.9 Kampionimi me refuzim

Le të jetë f dendësia e synuar dhe g dendësia propozuese, me $f(x) \leq M g(x)$. Gjenerohet $Y \sim g$ dhe $U \sim \mathcal{U}(0, 1)$; Y pranohet kur

$$U \leq \frac{f(Y)}{M g(Y)}. \quad (9.16)$$

Dendësia e një vlere të pranuar është proporcionale me

$$g(y) \frac{f(y)}{M g(y)} = \frac{f(y)}{M}, \quad (9.17)$$

pra pas normalizimit është f . Probabiliteti mesatar i pranimit është $1/M$. Një mbështjellëse e dobët e bën metodën të kushtueshme, sidomos në dimension të lartë.

9.7.10 Kampionimi i rëndësisë dhe madhësia efektive

Për një pritje nën p ,

$$I = \int h(x) p(x) dx = \int h(x) \frac{p(x)}{q(x)} q(x) dx, \quad (9.18)$$

gjenerohen $X_i \sim q$ dhe përdoren peshat $w_i = p(X_i)/q(X_i)$. Kushti themelor është që $q > 0$ kudo ku $|h|p$ kontribuon. Varianca mund të zvogëlohet shumë nëse q vendos mostra në rajonet me kontribut të madh, por peshat shumë të pabarabarta e bëjnë vlerësimin të paqëndrueshëm. Një diagnostikë është

$$N_{\text{eff}} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2}. \quad (9.19)$$

Kjo nuk është identike me madhësinë efektive të një zinxhiri Markov, megjithëse të dyja matin humbjen e informacionit kundrejt N mostrave ideale.

9.7.11 Testimi i mostrave

Një paketë minimale kontrollesh përfshin histogramin, CDF-në empirike, testin e momenteve dhe autokorrelacionin. Vlera- p nuk provon rastësinë; ajo mat sa i pazakontë është statistiku nën një hipotezë të caktuar. Me shumë teste shfaqen rezultate të vogla edhe për një gjenerator të mirë, prandaj duhet parë modeli i përgjithshëm dhe jo vetëm minimumi i vlerave- p .

9.7.12 Përmbledhje dhe ushtrime

Gjenerimi i mostrës është pjesë e algoritmit shkencor. Një transformim i saktë matematikisht mund të dështojë numerikisht ose të trashëgojë korrelacionet e gjeneratorit bazë.

1. Gjeni kushtet për periodë të plotë të një gjeneratori kongruencial linear dhe testojini në parametra të vegjël.
2. Nxirrni transformimin e anasjellë për shpërndarjen Pareto.
3. Vërtetoni Box–Muller-in duke përfshirë Jakobinin polar.
4. Ndërttoni një mbështjellëse refuzimi për një dendësi trekëndore dhe parashikoni normën e pranimit.
5. Krahasoni dy propozime të kampionimit të rëndësisë me anë të variancës dhe N_{eff} .

9.7.13 Rrymat e pavarura dhe ekzekutimi paralel

Në një simulim paralel, përdorimi i farave $s, s+1, s+2, \dots$ nuk garanton rryma të pavarura për çdo familje gjeneratorësh. Gjeneratorët modernë ofrojnë mekanizma për ndarje: kapërcim përpara, nënrryma ose ndërtim të gjendjeve fëmijë nga një sekuençë farash. Qëllimi është që asnjë punëtor të mos përdorë pjesë të mbivendosura të të njëjtit varg.

Rezultati duhet të jetë i riprodhueshëm edhe kur ndryshon numri i bërthamave. Një strategji është që çdo realizim të marrë farë të derivuar nga identifikuesi i realizimit, jo nga rendi i ekzekutimit. Atëherë planifikimi paralel mund të ndryshojë pa ndryshuar mostrat. Në raport ruhen fara bazë, metoda e ndarjes dhe versioni i bibliotekës.

Gjeneratori kriptografik nuk është domosdoshmërisht i nevojshëm për fizikë llogaritëse; kërkojnë periodë e gjatë, cilësi statistikë, shpejtësi dhe ndarje e sigurt e rrymave. Për aplikime sigurie, parashikueshmëria deterministe është e papranueshme dhe kërkesat janë të tjera.

Gjenerimi i vektorëve Gauss të korreluar

Le të jetë $\mathbf{Z} \sim \mathcal{N}(0, I)$ dhe $\Sigma = LL^T$ faktorizimi Cholesky i kovariancës. Atëherë

$$\mathbf{X} = \boldsymbol{\mu} + L\mathbf{Z} \quad (9.20)$$

ka mesatare $\boldsymbol{\mu}$ dhe kovariancë

$$\text{Cov}(\mathbf{X}) = L \text{Cov}(\mathbf{Z}) L^T = LL^T = \Sigma. \quad (9.21)$$

Nëse Σ është vetëm pozitivisht gjysmë e përcaktuar, Cholesky mund të dështojë; përdoret zbërthimi spektral dhe mbahen vlerat vetjake jo negative. Një vlerë vetjake zero përfaqëson kufizim të saktë linear dhe dimension efektiv më të vogël.

Kontrolli empirik kërkon shumë realizime dhe krahasim të mesatares e kovariancës së mostrës me objektivat. Devijimet priten të shkallëzohen me madhësinë e mostrës; nuk duhet kërkuar barazi e saktë. Grafikët e çifteve ndihmojnë të zbulohen shenja të gabuara ose renditje e gabuar e komponentëve.

Metoda e përbërjes dhe shpërndarjet diskrete

Nëse dendësia është përzjerje

$$f(x) = \sum_{k=1}^K w_k f_k(x), \quad w_k \geq 0, \quad \sum_k w_k = 1, \quad (9.22)$$

fillimisht gjenerohet komponenti K me probabilitete w_k , pastaj $X \sim f_K$. Kjo metodë është e saktë dhe shpesh më efikase se refuzimi. Për shembull, një model zhurme me bërthamë të ngushtë dhe bisht të gjerë mund të simulohet si përzierje e dy shpërndarjeve Gauss.

Për shpërndarje diskrete me shumë kategori, kërkimi kumulativ kushton $\mathcal{O}(\log K)$ me kërkim binar. Metoda alias kryen parapërpunim $\mathcal{O}(K)$ dhe pastaj gjeneron çdo kategori në kohë $\mathcal{O}(1)$. Zgjedhja varet nga sa herë përdoret e njëjta shpërndarje.

Efikasiteti i refuzimit në dimension të lartë

Në njësi d -dimensionale, raporti i vëllimit të sferës ndaj kubit kufizues është

$$\frac{V_d}{2^d} = \frac{\pi^{d/2}}{2^d \Gamma(d/2 + 1)}, \quad (9.23)$$

dhe shkon shpejt në zero. Prandaj gjenerimi uniform në kub dhe refuzimi jashtë sferës bëhet katastrofik në dimension të lartë. Ky shembull konkret tregon se një algoritëm intuitiv në dy përmasa mund të jetë i papërdorshëm në njëzet përmasa.

Transformimet që respektojnë gjeometrinë, kampionimi i rëndësisë ose MCMC shmangin këtë humbje. Megjithatë, MCMC prodhon korrelacion dhe kërkon diagnostikë; nuk ka metodë universale pa kosto.

Testet si bateri, jo si vulë

Një test uniformiteti kontrollon vetëm një aspekt. Testet seriale kontrollojnë çifte ose blloqe; testet spektrale kontrollojnë strukturën e rrjetës; testet e runs kontrollojnë vargjet rritëse dhe zbritëse. Kur kryhen shumë teste në nivel 5%, rreth 5% pritet të dështojnë rastësisht. Duhet parë shpërndarja e vlerave- p , përsëritja në fara të ndryshme dhe rëndësia për algoritmin konkret.

Prova më bindëse për një simulim është kombinimi i një gjeneratori të njohur, testeve standarde dhe verifikimit të observablave ndaj rezultateve teorike. Një gjenerator mund të kalojë një bateri dhe përsëri të bashkëveprojë keq me strukturën periodike të një algoritmi të veçantë.

Kapitulli 10

Integrimi Monte Carlo

Rezultatet e të nxënit. Studenti formulon integralin si pritje; ndërton vlerësuesin Monte Carlo dhe gabimin e tij; përdor kampionim të rëndësisë, variabla antitetike dhe variabla kontrolli; trajton integrale shumëdimensionale dhe pacaktueshmëri në modele fizike.

Orientim për studim. Shkruani fillimisht integralin si pritje dhe identifikoni ndryshoren që po mesatarizohet. Pastaj nxirrni vlerësuesin, variancën dhe gabimin standard. Metodat e reduktimit të variancës krahasohen me të njëjtin buxhet vlerësimesh të funksionit; përndryshe krahasimi nuk është i drejtë.

10.1 Integrali si pritje

Për domen D me vëllim V_D dhe mostra uniforme X_i ,

$$I = \int_D f(\mathbf{x}) \, d\mathbf{x} = V_D \mathbb{E}[f(X)], \quad \hat{I}_N = \frac{V_D}{N} \sum_{i=1}^N f(X_i). \quad (10.1)$$

Vlerësuesi është i paanshëm dhe

$$\text{SE}(\hat{I}_N) = V_D \frac{\sigma_f}{\sqrt{N}}. \quad (10.2)$$

Avantazhi kryesor është se rendi $N^{-1/2}$ nuk përkeqësohet drejtpërdrejt me dimensionin. Disavantazhi është konvergjenca e ngadaltë në dimension të ulët krahasuar me kuadraturat me rend të lartë.

10.2 Shembulli gjeometrik i π

Në katrorin njësi, probabiliteti që $x^2 + y^2 \leq 1$ është $\pi/4$. Prandaj

$$\hat{\pi}_N = 4 \frac{N_{\text{brenda}}}{N}. \quad (10.3)$$

Ky shembull është intuitiv, por jo metodë efikase për llogaritjen e π ; shërben për të demonstruar treguesit, ligjin binomial dhe intervalin e besimit.

10.3 Gabimi statistik

Varianca vlerësohet nga mostrat,

$$s_f^2 = \frac{1}{N-1} \sum_{i=1}^N (f_i - \bar{f})^2, \quad \widehat{\text{SE}}(\hat{I}_N) = V_D \frac{s_f}{\sqrt{N}}. \quad (10.4)$$

Raportimi $\hat{I} \pm \text{SE}$ pa treguar N , metodën e kampionimit dhe korrelacionin është i paplotë. Për integrandë me variancë të pafundme, CLT standard mund të mos zbatohet.




Figura 10.1: Vlerësimi gjeometrik i π dhe konvergjenca e vlerësuesit.




Figura 10.2: Shkallëzimi $N^{-1/2}$ në një integral katërpërmasor.

10.4 Reduktimi i variancës

10.4.1 Kampionimi i rëndësisë

Nëse p është dendësia e synuar dhe q dendësia e kampionimit,

$$I = \mathbb{E}_q \left[f(X) \frac{p(X)}{q(X)} \right]. \quad (10.5)$$

Zgjedhja ideale vendos më shumë mostra ku kontributi është i madh. Peshat duhet të monitorohen për degenerim.

10.4.2 Variablat antitetike

Për $U \sim \mathcal{U}(0, 1)$, çiftet U dhe $1 - U$ janë të korreluara negativisht për funksione monotone. Mesatarja e çiftit mund të ketë variancë më të vogël se dy mostra të pavarura.

10.4.3 Variablat kontrolli

Nëse g ka pritje të njohur,

$$\hat{I}_c = \bar{f} - c(\bar{g} - \mathbb{E}g). \quad (10.6)$$

Koeficienti optimal është $c^* = \text{Cov}(f, g) / \text{Var}(g)$. Metoda përdor korrelacionin me një model të thjeshtë për të korrigjuar modelin e shtrenjtë.

10.5 Integrale shumëfishta dhe rajone të ndërlikuara

Një tregues $1_D(\mathbf{x})$ e kthen integrimin mbi rajon të parregullt në pritje mbi një kuti. Efikasiteti bie kur D zë fraksion shumë të vogël. Atëherë përdoret parametrizim i rajonit, kampionim i rëndësisë ose ndarje stratifikore.

Quasi-Monte Carlo zëvendëson rastësinë me vargje me diskrepancë të ulët. Për integrandë të rregullt mund të tejkalojë $N^{-1/2}$, por vlerësimi i gabimit kërkon randomizim ose analiza të tjera.

10.6 Përhapja Monte Carlo e pacaktueshmërisë

Kur dalja $Y = g(\mathbf{X})$ varet jolinearisht nga hyrje të pacaktuara, kampionohen hyrjet sipas shpërndarjes së tyre dhe llogaritet Y për çdo realizim. Kjo ruan jo-Gaussianitetin, kufijtë dhe korrelacionet. Shpërndarja e daljes jep kuantile dhe probabilitete rreziku, jo vetëm mesatare.




Figura 10.3: Shpërndarja e shpejtësisë së uljes kur lartësia, shpejtësia fillestare dhe shtytja kanë pacaktueshmëri.

Shembull Zbritja e mjetit hapësinor. Për çdo realizim kampionohen masa, shtytja, lartësia dhe shpejtësia fillestare. Integruesi dinamik jep shpejtësinë e kontaktit. Probabiliteti $P(v_{\text{kontakt}} < v_{\text{kufi}})$ është madhësi më informative se një trajektore me parametra mesatarë.

Lidhja me laboratorin. Laboratori krahason kuadraturën dhe Monte Carlo-n, verifikon $N^{-1/2}$, përdor një teknikë reduktimi variance dhe zbaton përhapjen e pacaktueshmërisë në zbritjen e mjetit.

Pyetje kontrolli

1. Pse Monte Carlo bëhet më tërheqës në dimension të lartë?
2. Si zgjidhet një variabël kontrolli e mirë?
3. Pse simulimi me parametrat mesatarë nuk jep domosdoshmërisht daljen mesatare?

10.7 Algoritmet Monte Carlo në Python

10.7.1 Integruesi bazë me gabim standard

Listing 10.1: Integrimi uniform në një kuti shumëpërmasore.

```
def integral_mc(f, kufijte, N, seed=2026):
```

```

rng = np.random.default_rng(seed)
kufijte = np.asarray(kufijte, float)
a, b = kufijte[:, 0], kufijte[:, 1]
x = rng.uniform(a, b, size=(N, len(a)))
fx = np.asarray(f(x), float)
vellimi = np.prod(b - a)
vleresimi = vellimi * fx.mean()
se = vellimi * fx.std(ddof=1) / np.sqrt(N)
return vleresimi, se

f = lambda x: np.exp(x.sum(axis=1))
I, se = integral_mc(f, [(0, 1)]*4, N=200_000)
print(f"I = {I:.6f} +/- {se:.6f}")

```

10.7.2 Kontrolli i ligjit $N^{-1/2}$

Për secilin N kryhen R simulime të pavarura. Llogaritet RMSE kundrejt një reference dhe përshtatet pjerrësia në koordinata logaritmike.

```

Ns = 2*np.arange(8, 18)
rmse = []
for N in Ns:
    v = [integral_mc(f, [(0, 1)]*4, N, seed=s)[0]
          for s in range(40)]
    rmse.append(np.sqrt(np.mean((np.array(v) - I_ref)**2)))
pjerrtesia = np.polyfit(np.log(Ns), np.log(rmse), 1)[0]

```

Pjerrësia pritet afër $-1/2$. Devijimi mund të vijë nga numër i pamjaftueshëm përsëritjesh ose nga variancë e madhe e integrandit.

10.7.3 Variabli kontrollues

Listing 10.2: Reduktimi i variancës me një madhësi të korreluar.

```

def kontrolli(fx, gx, Eg):
    cov = np.cov(fx, gx, ddof=1)
    c = cov[0, 1] / cov[1, 1]
    korrigjuar = fx - c*(gx - Eg)
    return korrigjuar.mean(), korrigjuar.std(ddof=1)/np.sqrt(len(fx)), c

```

Raportohet faktori i reduktimit të variancës $\text{Var}(f)/\text{Var}(f_c)$. Nëse korrelacioni është i dobët, metoda mund të mos sjellë përfitim.

10.7.4 Pacaktueshmëria e zbritjes së mjetit

Algoritmi i plotë është i folezuar: jashtë kampionohen parametrat; brenda integrohet dinamika për çdo realizim. Rezultati është shpërndarja e shpejtësisë së kontaktit dhe probabiliteti i tejkalimit të kufirit.

```

rng = np.random.default_rng(12)
parametra = rng.multivariate_normal(mu, Sigma, size=20_000)
v_kontakt = np.array([simulo_zbritjen(p) for p in parametra])
rreziku = np.mean(v_kontakt < v_kufi)
se_rreziku = np.sqrt(rreziku*(1-rreziku)/len(v_kontakt))

```

Kujdes numerik. Në shqip dallohen *vlerësuesi* (estimator), *vlerësimi* (estimate), *varianca* dhe *gabimi standard*. Shprehja “gabimi Monte Carlo” duhet të shoqërohet me përkufizimin konkret.

Literatura shqip për Monte Carlo është më e kufizuar; për terminologjinë probabilitare dhe të rizgjedhjes janë përdorur [7, 8, 11], ndërsa baza algoritmike mbështetet te [12, 19, 14].

10.7.5 Integrimi Monte Carlo si vlerësim i një pritjeje

Le të jetë $X \sim p$ dhe

$$I = \int h(x)p(x) dx = \mathbb{E}_p[h(X)]. \quad (10.7)$$

Vlerësuesi bazë është

$$\hat{I}_N = \frac{1}{N} \sum_{i=1}^N h(X_i). \quad (10.8)$$

Për mostra të pavarura,

$$\mathbb{E}[\hat{I}_N] = I, \quad \text{Var}(\hat{I}_N) = \frac{\sigma_h^2}{N}. \quad (10.9)$$

Gabimi standard vlerësohet me $s_h/\sqrt{N}$. Teorema qendrore kufitare jep

$$\frac{\hat{I}_N - I}{s_h/\sqrt{N}} \approx \mathcal{N}(0, 1). \quad (10.10)$$

Kështu për ta përgjysmuar gabimin duhen afërsisht katër herë më shumë mostra. Shkalla $N^{-1/2}$ nuk varet drejtpërdrejt nga dimensionin, por varianca e integrandit dhe vështirësia e kampionimit mund të rriten fort me dimensionin.

Për integralin $J = \int_D f(\mathbf{x}) d\mathbf{x}$ mbi një rajon me vëllim V_D , nëse X është uniforme në D , atëherë $J = V_D \mathbb{E}[f(X)]$. Metoda gjeometrike hit-or-miss përdor një ndryshore treguese dhe zakonisht ka variancë më të madhe se mesatarja e drejtpërdrejtë e f .

10.7.6 Variablat antitetike

Nëse $U \sim \mathcal{U}(0, 1)$, edhe $1 - U$ është uniforme. Vlerësuesi

$$\hat{I}_{\text{anti}} = \frac{1}{N} \sum_{i=1}^N \frac{h(U_i) + h(1 - U_i)}{2} \quad (10.11)$$

ka variancë

$$\frac{1}{2N} [\text{Var}(h(U)) + \text{Cov}(h(U), h(1 - U))]. \quad (10.12)$$

Për h monotone, kovarianca zakonisht është negative dhe varianca ulet. Metoda nuk është automatikisht e dobishme për funksione jo monotone; kovarianca duhet matur.

10.7.7 Variabli kontrollues

Le të jetë Y madhësia e interesit dhe C një madhësi e korreluar me pritje të njohur μ_C . Vlerësuesi

$$Y_\beta = Y - \beta(C - \mu_C) \quad (10.13)$$

mbetet i paanshëm. Varianca është

$$\text{Var}(Y_\beta) = \text{Var}(Y) + \beta^2 \text{Var}(C) - 2\beta \text{Cov}(Y, C). \quad (10.14)$$

Derivimi ndaj β jep optimumin

$$\beta_* = \frac{\text{Cov}(Y, C)}{\text{Var}(C)}. \quad (10.15)$$

Në praktikë β_* vlerësohet nga një mostër pilot ose nga e njëjta mostër, duke raportuar qartë procedurën.

10.7.8 Kampionimi i rëndësisë për ngjarje të rralla

Kur integrali dominohet nga një rajon që p e viziton rrallë, kampionimi i drejtpërdrejtë prodhon shumicën e kontributeve zero dhe disa pesha shumë të mëdha. Me $X \sim q$,

$$I = \mathbb{E}_q \left[h(X) \frac{p(X)}{q(X)} \right]. \quad (10.16)$$

Propozimi ideal formal është $q_*(x) \propto |h(x)|p(x)$, por varet nga integrali i panjohur. Ai shërben si parim projektimi: q duhet të imitojë madhësinë e integrandit, jo vetëm dendësinë bazë.

10.7.9 Përhapja Monte Carlo në zbritjen e mjetit hapësinor

Në një model të thjeshtuar vertikal,

$$\dot{h} = v, \quad (10.17)$$

$$m\dot{v} = -mg(h) + \frac{1}{2}\rho(h)C_D A v|v| + T(t), \quad (10.18)$$

ku h është lartësia dhe $v < 0$ gjatë zbritjes. Parametrat C_D , masa, dendësia atmosferike dhe shtytja kanë pacaktueshmëri. Çdo realizim përdor një mostër të parametrave, integron ODE-në dhe regjistron shpejtësinë në kontakt. Probabiliteti i dështimit vlerësohet nga treguesi $I_r = 1$ kur $|v_{\text{kontakt}}|$ tejkalon kufirin.

Një analizë bindëse raporton intervalin e besimit të probabilitetit, jo vetëm numrin e dështimeve. Për ngjarje shumë të rralla, simulimi i drejtpërdrejtë është joefikas; nevojitet kampionim i rëndësisë ose ndarje e ngjarjeve, me korrigjimin përkatës të peshave.

Listing 10.3: Vlerësues Monte Carlo me gabim standard.

```
import numpy as np

def monte_carlo(h, gjenero, N, fare=2026):
    rng = np.random.default_rng(fare)
    x = gjenero(rng, N)
    y = np.asarray(h(x), float)
    vleresimi = y.mean()
    gabimi_standard = y.std(ddof=1) / np.sqrt(N)
    return vleresimi, gabimi_standard
```

10.7.10 Përmbledhje dhe ushtrime

Monte Carlo prodhon një vlerësim dhe një procedurë të matjes së gabimit. Numri i shifrave duhet të jetë në përputhje me gabimin standard.

1. Nxirrni variancën e metodës hit-or-miss për një sipërfaqe me probabilitet p .
2. Provoni formulën e β_* dhe zvogëlimin maksimal të variancës në terma të korrelacionit.
3. Krahasoni kuadraturën deterministe dhe Monte Carlo kur dimensionin rritet.
4. Ndërttoni një analizë konvergjence me shumë fara dhe përshtatni pjerrësinë në grafik log-log.
5. Vlerësoni probabilitetin e uljes së pasigurt të mjetit dhe jepni interval Wilson.

10.7.11 Kampionimi i shtresëzuar

Le të ndahet domeni në rajone pa mbivendosje D_k me probabilitete p_k . Integrali shkruhet

$$I = \sum_{k=1}^K p_k \mu_k, \quad \mu_k = \mathbb{E}[h(X) \mid X \in D_k]. \quad (10.19)$$

Nëse në shtresën k përdoren n_k mostra të pavarura,

$$\hat{I} = \sum_k p_k \bar{h}_k, \quad \text{qqquad} \text{Var}(\hat{I}) = \sum_k \frac{p_k^2 \sigma_k^2}{n_k}. \quad (10.20)$$

Me kosto të njëjtë për mostër dhe $\sum_k n_k = N$, minimizimi jep ndarjen Neyman $n_k \propto p_k \sigma_k$. Pra më shumë mostra vendosen në shtresa me peshë ose variancë të madhe. Kur σ_k nuk njihet, përdoret një fazë pilot.

Edhe ndarja proporcionale $n_k = N p_k$ zakonisht nuk është më e keqe se kampionimi i thjeshtë, sepse heq luhatjen e rastësishme të numrit të pikave në çdo shtresë. Në një integral njëpërmasor, ndarja e intervalit në qeliza dhe zgjedhja e një pike të rastit për qelizë kombinon mbulim të rregullt me paanshmëri.

Mesatarizimi kushtor

Nëse Y varet nga X dhe një burim tjetër rastësie, atëherë

$$\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}(Y | X)]. \quad (10.21)$$

Zëvendësimi i Y me $g(X) = \mathbb{E}(Y | X)$ ruan pritjen dhe, nga ligji total i variancës,

$$\text{Var}(g(X)) \leq \text{Var}(Y). \quad (10.22)$$

Kjo teknikë quhet Rao–Blackwellizim ose mesatarizim kushtor. Në një model transporti, nëse një pjesë e dinamikës mund të integrohet analitikisht për një trajektore të dhënë, është më mirë të përdoret pritja kushtore sesa të simulohet një hedhje shtesë.

Sekuencat me mospërputhje të ulët

Kuazi-Monte Carlo zëvendëson pikat e pavarura me sekuenca që mbulojnë kubin në mënyrë më uniforme, si Halton ose Sobol. Për funksione me variacion të kufizuar, pabarazia Koksma–Hlawka lidh gabimin me mospërputhjen e pikave. Shkallëzimi teorik mund t'i afrohet $N^{-1}(\log N)^d$, më i mirë se $N^{-1/2}$ për dimension efektiv të moderuar.

Pikat nuk janë të rastit, prandaj gabimi standard i zakonshëm nuk zbatohet. Randomizimi i sekuencës, për shembull scrambling, ruan mbulimin dhe lejon disa përsëritje të pavarura për vlerësimin e gabimit. Në dimension shumë të lartë, renditja e ndryshoreve ka rëndësi: dimensionet e para të një sekuence zakonisht kanë cilësi më të mirë dhe duhet t'u caktohen drejtimet më të rëndësishme.

Ngjarjet e rralla

Për një probabilitet $p \ll 1$, vlerësuesi binomial ka gabim relativ

$$\frac{\sqrt{p(1-p)/N}}{p} \simeq \frac{1}{\sqrt{Np}}. \quad (10.23)$$

Për të marrë gabim relativ 10% duhen rreth $100/p$ realizime. Nëse $p = 10^{-8}$, kjo kërkon rreth 10^{10} realizime dhe është e papërshtatshme. Kampionimi i rëndësisë zhvendos shpërndarjen drejt dështimit dhe korrigjon me peshën e gjasës.

Një propozim tepër agresiv mund të japë pesha me variancë të pafundme ose disa mostra dominuese. Diagnostika përfshin madhësinë efektive të peshave, maksimumin e peshës së normalizuar dhe përsëritjen me propozime alternative. Rezultati i ngjarjes së rrallë nuk duhet raportuar pa këto kontrole.

Buxheti i gabimit në Monte Carlo

Gabimi total mund të përfshijë diskretizimin e trajektores, animin e modelit, gabimin e kampionimit dhe gabimin nga vlerësimi i peshave. Rritja e N ul vetëm komponentin e kampionimit. Nëse ODE-ja brenda çdo realizimi zgjidhet me hap h , një strategji e balancuar zgjedh h që gabimi numerik të jetë dukshëm më i vogël, por jo shumë më i vogël, se gabimi Monte Carlo.

Për të kontrolluar këtë ndarje kryhen dy eksperimente: në një N të madh ndryshohet h për të matur animin numerik; në një h të vogël ndryshohet N dhe fara për të matur variancën. Raporti final jep të dy komponentët dhe koston në vlerësime modeli ose kohë procesori.

Kapitulli 11

Bredhjet e rastit, difuzioni dhe zinxhirët Markov

Rezultatet e të nxënit. Studenti lidh bredhjen e rastit me difuzionin; nxjerr ligjin e zhvendosjes katrore mesatare; simulon bredhje në një dhe dy përmasa; përkufizon zinxhirin Markov, shpërndarjen stacionare, kthyeshmërinë dhe kohën e korrelacionit.

Orientim për studim. Bredhja e rastit lidh modelin mikroskopik me difuzionin, ndërsa zinxhiri Markov lidh rregullin e kalimit me shpërndarjen stacionare. Ndiqni derivimin e $\langle X_n^2 \rangle$, kufirin e vazhdueshëm dhe spektrin e matricës së kalimit. Autokorrelacioni përcakton sa informacion të pavarur përmban trajektorja.

11.1 Bredhja simetrike në një përmasë

Le të jenë hapat $S_i = \pm\ell$ me probabilitet $1/2$. Pas N hapash,

$$X_N = \sum_{i=1}^N S_i, \text{ qquad } \mathbb{E}[X_N] = 0, \text{ qquad } \mathbb{E}[X_N^2] = N\ell^2. \quad (11.1)$$

Zhvendosja tipike rritet si $\sqrt{N}$, jo si N . Nëse çdo hap zgjat Δt , atëherë

$$\langle X^2 \rangle = 2Dt, \text{ qquad } D = \frac{\ell^2}{2\Delta t}. \quad (11.2)$$

Në d përmasa, $\langle r^2 \rangle = 2dDt$.

11.2 Kufiri i vazhdueshëm dhe difuzioni

Probabiliteti diskret plotëson ekuacionin master

$$p_j^{n+1} = \frac{1}{2}p_{j-1}^n + \frac{1}{2}p_{j+1}^n. \quad (11.3)$$

Zhvillimi Taylor dhe kufiri $\ell, \Delta t \rightarrow 0$ me $\ell^2/(2\Delta t) = D$ japin

$$\frac{\partial p}{\partial t} = D \frac{\partial^2 p}{\partial x^2}. \quad (11.4)$$

Për një grimcë fillimisht në origjinë,

$$p(x, t) = \frac{1}{\sqrt{4\pi Dt}} \exp\left(-\frac{x^2}{4Dt}\right). \quad (11.5)$$




Figura 11.1: Realizime të bredhjes dhe rritja lineare e zhvendosjes katrore mesatare.




Figura 11.2: Profili i difuzionit zgjerohet, ndërsa normalizimi ruhet.

11.3 Kufij, drift dhe kohë e parë kalimi

Një kufi reflektues ruan grimcën; një kufi thithës e heq kur arrihet. Koha e parë e kalimit është koha kur trajektorja prek për herë të parë një objektiv. Me drift v ,

$$\frac{\partial p}{\partial t} = -v \frac{\partial p}{\partial x} + D \frac{\partial^2 p}{\partial x^2}. \quad (11.6)$$

Kjo lidh transportin determinist me luhatjet. Në mjediset heterogjene, hapi ose probabiliteti mund të varen nga pozicioni.

11.4 Zinxhirët Markov

Një proces diskret është Markov nëse e ardhmja, me kusht gjendjen e tanishme, nuk varet nga historia:

$$P(X_{n+1} = j | X_n = i, X_{n-1}, \dots) = P_{ij}. \quad (11.7)$$

Matrica P ka elemente jo-negative dhe rreshta me shumë një. Shpërndarja evoluon si $\mathbf{p}_{n+1} = \mathbf{p}_n P$. Shpërndarja stacionare plotëson

$$\boldsymbol{\pi} = \boldsymbol{\pi} P. \quad (11.8)$$

Një zinxhir i fundmë, i pareduktueshëm dhe aperiodik ka shpërndarje stacionare unike dhe konvergon drejt saj.




Figura 11.3: Humbja graduale e kujtesës së gjendjes fillestare në një zinxhir me dy gjendje.

11.5 Kthyeshmëria dhe balanca e detajuar

Kushti

$$\pi_i P_{ij} = \pi_j P_{ji} \quad (11.9)$$

quhet balancë e detajuar. Ajo garanton stacionaritetin, por nuk është kusht i domosdoshëm. Interpretimi është ekuilibër i fluksit probabilitar ndërmjet çdo çifti gjendjesh.

11.6 Korrelacioni dhe madhësia efektive

Në një zinxhir, mostrat pasuese janë të korreluara. Për një observabël A ,

$$\rho_A(k) = \frac{\text{Cov}(A_n, A_{n+k})}{\text{Var}(A)}, \quad \tau_{\text{int}} = \frac{1}{2} + \sum_{k=1}^{\infty} \rho_A(k). \quad (11.10)$$

Varianca e mesatares sillet afërsisht si

$$\text{Var}(\bar{A}) \approx \frac{2\tau_{\text{int}}}{N} \text{Var}(A), \quad (11.11)$$

pra $N_{\text{eff}} \approx N/(2\tau_{\text{int}})$. Rritja e numrit të hapave nuk ndihmon shumë kur zinxhiri përzihet ngadalë.

Lidhja me laboratorin. Laboratori simulon bredhje 1D dhe 2D, mat $\langle r^2 \rangle$, zbaton kufij thithës e reflektues dhe vlerëson kohën e korrelacionit të një zinxhiri të vogël.

Pyetje kontrolli

1. Si del ekuacioni i difuzionit nga ekuacioni master?
2. Çfarë dallimi ka stacionariteti nga pavarësia?
3. Pse N hapa Markov nuk japin N mostra të pavarura?

11.7 Algoritmet e bredhjes dhe të zinxhirit Markov

11.7.1 Bredhja dydimensionale

Listing 11.1: Shumë realizime të bredhjes në 2D.

```
def bredhje_2d(rng, n_realizime, n_hapa):
    drejtimi = rng.integers(0, 4, size=(n_realizime, n_hapa))
```

```

dx = (drejtimi == 0) - (drejtimi == 1)
dy = (drejtimi == 2) - (drejtimi == 3)
x = np.c_[np.zeros(n_realizime), np.cumsum(dx, axis=1)]
y = np.c_[np.zeros(n_realizime), np.cumsum(dy, axis=1)]
return x, y

rng = np.random.default_rng(2026)
x, y = bredhje_2d(rng, 50_000, 2_000)
msd = np.mean(x*x + y*y, axis=0)

```

Përshtatja e $\langle r^2 \rangle$ kundrejt kohës jep $4D$ në dy përmasa. Pikat e hershme dhe efektet e kufirit trajtohen veçmas.

11.7.2 Kufiri thithës dhe koha e parë e kalimit

```

def koha_e_pare(x, prag):
    prekje = np.abs(x) >= prag
    ka = prekje.any(axis=1)
    t = np.full(len(x), np.nan)
    t[ka] = np.argmax(prekje[ka], axis=1)
    return t

```

Vlerat pa prekje janë të censuruara dhe nuk duhet të zëvendësohen me kohën maksimale pa e deklaruar.

11.7.3 Evolucion i matricës kalimi

Listing 11.2: Shpërndarja stacionare e një zinxhiri të fundmë.

```

P = np.array([[0.90, 0.10], [0.25, 0.75]])
p = np.array([1.0, 0.0])
for _ in range(100):
    p = p @ P
print(p, p @ P - p)

w, V = np.linalg.eig(P.T)
i = np.argmin(np.abs(w - 1.0))
pi = np.real(V[:, i]); pi /= pi.sum()

```

11.7.4 Autokorrelacioni dhe N_{eff}

Listing 11.3: Vlerësim fillestar i kohës së integruar të autokorrelacionit.

```

def autocorr(x, max_lag):
    x = np.asarray(x) - np.mean(x)
    c = np.correlate(x, x, mode="full")[len(x)-1:]
    c = c[:max_lag+1] / c[0]
    return c

rho = autocorr(observabli, 500)
pozitive = rho[1:][rho[1:] > 0]
tau_int = 0.5 + pozitive.sum()
N_eff = len(observabli)/(2*tau_int)

```

Prerja në vonesën e parë negative është rregull i thjeshtë, jo universal. Për analiza serioze përdoret dritare automatike ose bllokim.

Lidhja me laboratorin. Notebook-u duhet të paraqesë njëkohësisht trajektorët, $\langle r^2 \rangle$, shpërndarjen e pozicionit dhe kohën e parë të kalimit. Secila mat një aspekt të ndryshëm të procesit.

Për proceset e rastit dhe terminologjinë e statistikës janë konsultuar [9, 7, 8]; trajtimi i zinxhirëve Markov dhe autokorrelacionit mbështetet te [19, 18].

11.7.5 Bredhja e rastit dhe kufiri i difuzionit

Në një përmasë, hapi ξ_n merr vlerat $\pm\ell$ me probabilitete të barabarta dhe

$$X_N = \sum_{n=1}^N \xi_n. \quad (11.12)$$

Pavarësia jep $\mathbb{E}[X_N] = 0$ dhe $\text{Var}(X_N) = N\ell^2$. Nëse një hap zgjat Δt , atëherë $t = N\Delta t$ dhe

$$\mathbb{E}[X(t)^2] = \frac{\ell^2}{\Delta t} t = 2Dt, \quad D = \frac{\ell^2}{2\Delta t}. \quad (11.13)$$

Për të marrë kufirin e vazhdueshëm mbahen D dhe t të fiksuara ndërsa $\ell, \Delta t \rightarrow 0$. Shpërndarja e pozicionit i afrohet

$$p(x, t) = \frac{1}{\sqrt{4\pi Dt}} \exp\left(-\frac{x^2}{4Dt}\right), \quad (11.14)$$

që zgjidh $p_t = Dp_{xx}$. Ky është një shembull themelor ku një model mikroskopik stokastik çon në ekuacion makroskopik determinist.

Me drift, probabilitetet nuk janë të barabarta. Në kufirin e duhur shfaqet ekuacioni adveksion–difuzion

$$p_t = -vp_x + Dp_{xx}. \quad (11.15)$$

Kushtet thithëse përfaqësojnë largimin e grimcës; kushtet reflektuese ruajnë probabilitetin. Koha e parë e kalimit është ndryshore rasti dhe trajektorët që nuk e arrijnë kufirin brenda kohës së simulimit janë të censuruara, jo zero.

11.7.6 Zinxhirët Markov dhe shpërndarja stacionare

Për një zinxhir me hapësirë të fundme dhe matricë kalimi P , shpërndarja rresht evoluon si

$$\boldsymbol{\pi}_{n+1}^T = \boldsymbol{\pi}_n^T P. \quad (11.16)$$

Shpërndarja stacionare plotëson $\boldsymbol{\pi}^T P = \boldsymbol{\pi}^T$, $\pi_i \geq 0$ dhe $\sum_i \pi_i = 1$. Nëse zinxhiri është i pakthyeshëm dhe aperiodik, shpërndarja konvergon te stacionarja pavarësisht gjendjes fillestare. Shpejtësia lidhet me boshllëkun spektral ndërmjet vlerës vetjake 1 dhe vlerës së dytë në modul.

Balanca e detajuar,

$$\pi_i P_{ij} = \pi_j P_{ji}, \quad (11.17)$$

është kusht i mjaftueshëm për stacionaritet, sepse mbledhja sipas i jep $(\boldsymbol{\pi}^T P)_j = \pi_j$. Ai nuk është kusht i domosdoshëm: mund të ketë rryma stacionare që nuk anulohen çift më çift.

11.7.7 Autokorrelacioni dhe madhësia efektive

Për një seri stacionare A_n , autokovarianca është

$$C(k) = \mathbb{E}[(A_n - \mu)(A_{n+k} - \mu)], \quad \rho(k) = C(k)/C(0). \quad (11.18)$$

Varianca e mesatares për N vëzhgime është

$$\text{Var}(\bar{A}) = \frac{1}{N^2} \sum_{i,j} \text{Cov}(A_i, A_j) \quad (11.19)$$

$$\simeq \frac{C(0)}{N} \left[1 + 2 \sum_{k=1}^{\infty} \rho(k) \right] = \frac{2\tau_{\text{int}} C(0)}{N}, \quad (11.20)$$

ku

$$\tau_{\text{int}} = \frac{1}{2} + \sum_{k=1}^{\infty} \rho(k). \quad (11.21)$$

Prandaj

$$N_{\text{eff}} = \frac{N}{2\tau_{\text{int}}}. \quad (11.22)$$

Formula $s/\sqrt{N}$ nënvlerëson gabimin kur mostrat janë të korreluara. Shuma e autokorrelacionit duhet prerë në një vonesë ku zhurma e vlerësimit nuk dominon; alternativa praktike janë mesataret në blloqe dhe shumë zinxhirë të pavarur.

11.7.8 Koha e përzierjes dhe diagnostika

Koha e përzierjes mat sa shpejt shpërndarja e zinxhirit harron gjendjen fillestare. Heqja e një numri fiks hapash pa diagnostikë nuk garanton termalizim. Vëzhgohen trajektoret, mesataret kumulative dhe krahasimi i zinxhirëve nga gjendje të ndryshme. Hollimi i zinxhirit zakonisht hedh informacion; ruajtja e të gjitha mostrave dhe përdorimi i N_{eff} është më transparent, përveç kufizimeve të ruajtjes ose kostos së vlerësimit.

11.7.9 Përmbledhje dhe ushtrime

Bredhja e rastit lidh fluktuacionet mikroskopike me difuzionin. Zinxhiri Markov shton varësinë kohore dhe kërkon korrigjimin e gabimit standard me autokorrelacionin.

1. Nxirrni $\mathbb{E}[r^2] = 2dDt$ për bredhjen në d përmasa.
2. Zgjidhni kohën mesatare të daljes nga një interval me kufij thithës.
3. Gjeni shpërndarjen stacionare dhe vlerat vetjake të një matrice kalimi 3×3 .
4. Simuloni një zinxhir me dy gjendje dhe krahasoni N_{eff} teorik me atë të vlerësuar.
5. Tregoni me shembull se stacionariteti nuk nënkupton balancë të detajuar.

11.7.10 Koha mesatare e daljes

Për bredhjen simetrike në nyjet $0, 1, \dots, L$ me kufij thithës, le të jetë T_i numri mesatar i hapave deri në dalje kur nisemi nga i . Kushtëzimi ndaj hapit të parë jep

$$T_i = 1 + \frac{1}{2}T_{i-1} + \frac{1}{2}T_{i+1}, \quad T_0 = T_L = 0. \quad (11.23)$$

Riorganizimi jep diferencën e dytë

$$T_{i+1} - 2T_i + T_{i-1} = -2. \quad (11.24)$$

Zgjidhja kuadratike që plotëson kufijtë është

$$T_i = i(L - i). \quad (11.25)$$

Në kufirin e difuzionit, koha mesatare $\tau(x)$ plotëson ekuacionin e prapëm

$$D\tau''(x) = -1, \quad \tau(0) = \tau(a) = 0, \quad (11.26)$$

me zgjidhje $\tau(x) = x(a - x)/(2D)$. Kjo lidh drejtpërdrejt ekuacionin diskret me modelin e vazhdueshëm.

Nëse një kufi është reflektues, kushti bëhet derivat zero. Me drift, operatori i prapëm është $v\partial_x + D\partial_{xx}$. Kohët e para të kalimit janë të ndjeshme ndaj bishtave dhe kërkojnë shumë realizime; mesatarja vetëm mund të mos përshkruajë shpërndarjen.

Spektri i matricës së kalimit

Për një zinxhir të kthyeshëm, matrica e kalimit është vetë-adjunkte në prodhimin skalar të peshuar

$$\langle f, g \rangle_\pi = \sum_i \pi_i f_i g_i. \quad (11.27)$$

Vlerat vetjake janë reale dhe plotësojnë $1 = \lambda_1 > \lambda_2 \geq \dots \geq -1$. Komponentët jo stacionarë shuhën si λ_k^n . Boshllëku spektral $1 - \max_{k>1} |\lambda_k|$ kontrollon relaksimimin më të ngadaltë.

Për një observabël që projektohet fort mbi modin e dytë, autokorrelacioni mund të sillet si $\rho(n) \simeq \lambda_2^n$. Atëherë

$$\tau_{\text{int}} \simeq \frac{1}{2} + \frac{\lambda_2}{1 - \lambda_2} = \frac{1 + \lambda_2}{2(1 - \lambda_2)}. \quad (11.28)$$

Kjo tregon lidhjen ndërmjet përzierjes, boshllëkut spektral dhe gabimit të mesatares.

Vlerësimi praktik i autokorrelacionit

Vlerësuesi i autokovariancës në vonesën k është

$$\hat{C}(k) = \frac{1}{N - k} \sum_{n=1}^{N-k} (A_n - \bar{A})(A_{n+k} - \bar{A}). \quad (11.29)$$

Për k të madh mbeten pak çifte dhe vlerësuesi bëhet i zhurmshëm. Shuma naive deri në N mund të luhatet fort. Përdoret një dritare vetëkonsistente: shumën ndalet kur k është disa herë më i madh se $\hat{\tau}_{\text{int}}$, ose kur autokorrelacioni hyn në një rajon të pajtueshëm me zhurmën.

Metoda e blloqeve ndan serinë në blloqe me gjatësi B dhe llogarit mesataren e çdo blloku. Kur $B \gg \tau$, mesataret e blloqeve janë afërsisht të pavarura. Gabimi i vlerësuar duhet të arrijë një pllajë me rritjen e B , para se numri i blloqeve të bëhet tepër i vogël.

Ergodiciteti dhe kurthet

Stacionariteti nuk mjafton nëse zinxhiri nuk mund të arrijë të gjithë mbështetjen. Një zinxhir i reduktueshëm mund të ketë disa shpërndarje stacionare dhe rezultati varet nga gjendja fillestare. Periodiciteti mund të shkaktojë alternim pa konvergjencë pikë për pikë, edhe kur mesataret kohore sillen më mirë.

Në hapësira me moda të ndara nga barriera, zinxhiri mund të jetë teorikisht ergodik, por praktikisht të mos kalojë barrierën gjatë simulimit. Trajektorja duket e qëndrueshme brenda një mode dhe jep pacaktueshmëri artificialisht të vogël. Nisja e shumë zinxhirëve, propozimet globale, temperimi ose metodat e grupimeve përdoren për të zbuluar dhe zbutur këtë problem.

Renditja e faqeve dhe zinxhiri Markov

Në renditjen e faqeve, kalimi ndjek një lidhje me probabilitet α dhe “teleportohet” me probabilitet $1 - \alpha$. Termi i teleportimit e bën matricën pozitive, kështu që teorema Perron–Frobenius garanton një vektor stacionar unik pozitiv. Parametri α balancon respektimin e strukturës së lidhjeve me shpejtësinë e përzierjes.

Faqet pa dalje duhet të trajtohen: kolona përkatëse zëvendësohet me një shpërndarje probabilitare. Pa këtë hap, matrica nuk është stohastike dhe masa humbet. Ky shembull tregon se pastrimi i të dhënave është pjesë e modelit matematik, jo vetëm detaj programimi.

Kapitulli 12

Metropolis–Hastings dhe Monte Carlo në fizikën statistike

Rezultatet e të nxënit. Studenti ndërton algoritmin Metropolis–Hastings; provon ruajtjen e shpërndarjes synuar; dallon termalizimin, përzierjen dhe autokorrelacionin; simulon modelin Ising dhe interpreton energjinë, magnetizimin, kapacitetin termik dhe tranzicionin fazor.

Orientim për studim. Kapitulli kulmor lidh probabilitetin, zinxhirët Markov dhe fizikën statistike. Derivoni probabilitetin e pranimit nga balanca e detajuar, verifikoni ΔE lokalisht dhe ndani termalizimin nga matjet. Përfundimet mbi tranzicionin kërkojnë autokorrelacion, gabime me blloqe dhe disa madhësi rrjete; një konfigurim i vetëm është vetëm ilustrim.

12.1 Pse nevojitet MCMC

Në fizikën statistike duam pritje sipas shpërndarjes Boltzmann,

$$\pi(x) = \frac{e^{-\beta E(x)}}{Z}, \quad Z = \sum_x e^{-\beta E(x)}. \quad (12.1)$$

Numri i gjendjeve rritet eksponencialisht dhe Z është zakonisht i paarrtshëm. Metodot Markov Chain Monte Carlo ndërtojnë një zinxhir me shpërndarje stacionare π pa kërkuar konstanten e normalizimit.

12.2 Algoritmi Metropolis–Hastings

Nga gjendja x , propozohet $y \sim q(y|x)$ dhe pranohet me probabilitet

$$\alpha(x, y) = \min \left[1, \frac{\pi(y)q(x|y)}{\pi(x)q(y|x)} \right]. \quad (12.2)$$

Nëse propozimi është simetrik,

$$\alpha(x, y) = \min[1, e^{-\beta \Delta E}]. \quad (12.3)$$

Raporti anulon Z . Hapi i refuzuar nuk hidhet; gjendja e vjetër regjistrohet sërish. Kjo është e domosdoshme për shpërndarjen e saktë.

Shembull Algoritmi Metropolis–Hastings. Niset nga x_0 . Për çdo hap propozohet $y \sim q(\cdot|x_n)$ dhe gjenerohet $u \sim \mathcal{U}(0, 1)$. Llogaritet $a = \min\{1, \pi(y)q(x_n|y)/[\pi(x_n)q(y|x_n)]\}$. Nëse $u < a$, vendoset $x_{n+1} = y$; përndryshe vendoset $x_{n+1} = x_n$.

12.3 Termalizimi dhe diagnostika

Hapat e parë varen nga gjendja fillestare dhe hiqen si termalizim fillestar (*burn-in*). Gjatësia nuk zgjidhet me një numër universal; kontrollohen disa nisje, gjurmët, observatlat dhe koha e autokorrelacionit. Hollimi i zinxhirit zakonisht hedh informacion dhe nuk zëvendëson vlerësimin e N_{eff} .

Norma e pranimi nuk është qëllim në vetvete. Hapa shumë të vegjël pranohen shpesh, por lëvizin ngadalë; hapa shumë të mëdhenj refuzohen. Propozimi duhet të balancojë lëvizjen dhe pranimin. Për shpërndarje shumëmodale, zinxhiri mund të mbetet në një modë edhe kur gjurma duket e qëndrueshme.

12.4 Modeli Ising dydimensional

Në rrjet katror me spine $s_i = \pm 1$,

$$E = -J \sum_{\langle i,j \rangle} s_i s_j - H \sum_i s_i, \quad m = \frac{1}{N} \sum_i s_i. \quad (12.4)$$

Me kufij periodikë, çdo spin ka katër fqinjë. Për një kthim $s_i \rightarrow -s_i$,

$$\Delta E = 2s_i \left(J \sum_{j \in \text{fqinj}} s_j + H \right). \quad (12.5)$$

Në temperaturë të ulët, gjendjet e rreshtuara dominojnë; në temperaturë të lartë, entropia prodhon çrregullim.




Figura 12.1: Formimi i domeneve nën temperaturën kritike dhe çrregullimi sipër saj.

12.5 Observatlat termodinamike

Nga luhatjet merren

$$C_V = \frac{\beta^2}{N} (\langle E^2 \rangle - \langle E \rangle^2), \quad \chi = \frac{\beta}{N} (\langle M^2 \rangle - \langle M \rangle^2). \quad (12.6)$$

Në sistem të fundmë, tranzicioni shfaqet si maksimum i gjerë, jo singularitet i vërtetë. Temperatura kritike e rrjetit katror pa fushë është

$$\frac{k_B T_c}{J} = \frac{2}{\ln(1 + \sqrt{2})} \approx 2.269. \quad (12.7)$$




Figura 12.2: Rënia e magnetizimit pranë zonës kritike në një simulim të fundmë.

12.5.1 Ngadalësimi kritik dhe përmirësimet

Pranë T_c , domenet ekzistojnë në shumë shkallë dhe përditësimi me një spin përzihet ngadalë. Koha e autokorrelacionit rritet me madhësinë e sistemit. Algoritmet e grupeve, si Wolff dhe Swendsen–Wang, ndryshojnë bashkë rajone të korreluara dhe ulin ngadalësimin kritik.

12.5.2 Gabimet dhe analiza e të dhënave MCMC

Mesatarja llogaritet pas termalizimit, por gabimi nuk merret duke trajtuar çdo hap si të pavarur. Përdoren autokorrelacioni i integruar, bllokimi ose mesataret sipas blloqeve. Simulime të pavarura me fara të ndryshme ndihmojnë të zbulohet mos-përzierja.

Kujdes numerik. Një konfigurim tërheqës vizualisht nuk është rezultat termodinamik. Përfundimet kërkojnë seri të termalizuara, madhësi efektive, prova me përmasa të ndryshme të rrjetit dhe observabla me gabime statistike.

12.5.3 Nga Ising te probleme të tjera

I njëjti parim përdoret në mekanikën statistike, inferencën Bayesiane, modelet e materialeve dhe fushat në rrjet. Ndryshojnë energjia, hapësira e gjendjeve dhe propozimi; mbeten invarianca e shpërndarjes, ergodiciteti dhe analiza e korrelacionit.

Lidhja me laboratorin. Laboratori zbaton Ising 2D me Metropolis, verifikon ΔE , mat normën e pranimit, termalizimin dhe autokorrelacionin, pastaj paraqet $|m|$, C_V dhe χ kundrejt temperaturës.

Pyetje kontrolli

1. Pse konstanta e normalizimit anulohet në raportin Metropolis?
2. Pse hapat e refuzuar duhet të regjistrohen?
3. Çfarë është ngadalësimi kritik dhe si ndikon në gabimin statistik?
4. Pse një simulim me një madhësi rrjeti nuk mjafton për të vërtetuar tranzicionin favor?

12.6 Algoritmi Metropolis për modelin Ising

12.6.1 Energjia lokale dhe një sweep

Listing 12.1: Përditësimi Metropolis me një spin.

```
def delta_E(spin, i, j, J=1.0, H=0.0):
    L = spin.shape[0]
    fq = (spin[(i+1) % L, j] + spin[(i-1) % L, j]
          + spin[i, (j+1) % L] + spin[i, (j-1) % L])
    return 2.0*spin[i, j]*(J*fq + H)

def sweep_metropolis(spin, beta, rng, J=1.0, H=0.0):
    L = spin.shape[0]
    pranuar = 0
    for _ in range(L*L):
        i, j = rng.integers(0, L, size=2)
        dE = delta_E(spin, i, j, J, H)
        if dE <= 0.0 or rng.random() < np.exp(-beta*dE):
            spin[i, j] *= -1
            pranuar += 1
    return pranuar/(L*L)
```

12.6.2 Matja e energjisë pa numërim të dyfishtë

```
def observablat(spin, J=1.0, H=0.0):
    djathtas = np.roll(spin, -1, axis=1)
    poshte = np.roll(spin, -1, axis=0)
    E = -J*np.sum(spin*(djathtas + poshte)) - H*np.sum(spin)
    M = np.sum(spin)
    return E, M
```

Numërohen vetëm lidhjet djathtas dhe poshtë, në mënyrë që çdo çift fqinjësh të hyjë një herë.

12.6.3 Termalizimi dhe matjet

Listing 12.2: Struktura e një simulimi të plotë.

```
def simulo_ising(L, T, n_term, n_matje, hendek, seed):
    rng = np.random.default_rng(seed)
    spin = rng.choice([-1, 1], size=(L, L))
    beta = 1.0/T
    for _ in range(n_term):
        sweep_metropolis(spin, beta, rng)
    E, M = [], []
    for _ in range(n_matje):
        for _ in range(hendek):
            sweep_metropolis(spin, beta, rng)
        e, m = observablat(spin)
        E.append(e); M.append(m)
    return np.asarray(E), np.asarray(M)
```

Hendeku nuk garanton pavarësi. Autokorrelacioni matet dhe raportohet N_{eff} .

12.6.4 Observablat dhe gabimet

```
N = L*L
e = E/N; m = M/N
Cv = (np.mean(E**2) - np.mean(E)**2)/(N*T*T)
chi = (np.mean(M**2) - np.mean(M)**2)/(N*T)
m_abs = np.mean(np.abs(m))
```

Për gabimet përdoret bllokimi: seria ndahet në blloqe më të gjata se koha e korrelacionit dhe mesataret e blloqeve trajtohen si afërsisht të pavarura.

12.6.5 Protokolli i studimit termik

1. Ekzekutohen disa temperatura larg dhe pranë T_c .
2. Për çdo temperaturë kontrollohen termalizimi dhe pranimi.
3. Raportohen $\langle |m| \rangle$, $\langle e \rangle$, C_V , χ dhe gabimet.
4. Përsëritet për disa L për të dalluar efektet e përmasës së fundme.
5. Krahasohen nisja e rregullt dhe e çrregullt pranë zonës kritike.

Kujdes numerik. Përdoren *balancë e detajuar, shpërndarje stacionare, termalizim, përzierje, kohë autokorrelacioni dhe ngadalësim kritik*. Këto terma përkufizohen para përdorimit dhe nuk zëvendësohen me anglicizma të panevojshëm.

Termet e fizikës statistike janë harmonizuar me përdorimin universitar në shqip dhe me burimet probabilitare [9, 7]; algoritmi dhe analiza MCMC mbështeten te burimet themelore [20, 21, 18, 19, 22].

12.6.6 Ndërtimi i Metropolis–Hastings nga balanca e detajuar

Synohet shpërndarja $\pi(x)$, e njohur deri në një konstante normalizimi. Nga gjendja x propozohet $y \sim q(y|x)$ dhe pranohet me probabilitet

$$\alpha(x, y) = \min \left\{ 1, \frac{\pi(y)q(x|y)}{\pi(x)q(y|x)} \right\}. \quad (12.8)$$

Për $x \neq y$, kerneli i kalimit është $T(x, y) = q(y|x)\alpha(x, y)$. Nëse raporti është më i vogël se një,

$$\pi(x)T(x, y) = \pi(x)q(y|x)\frac{\pi(y)q(x|y)}{\pi(x)q(y|x)} = \pi(y)q(x|y), \quad (12.9)$$

ndërsa kalimi i kundërt pranohet me probabilitet një. Rasti tjetër është simetrik; kështu vlen balanca e detajuar. Probabiliteti i refuzimit vendos masën e mbetur në $T(x, x)$ dhe siguron normalizimin.

Kur $q(y|x) = q(x|y)$, raporti i propozimit anulohet. Për shpërndarjen Boltzmann $\pi(x) \propto e^{-\beta E(x)}$ merret

$$\alpha = \min\{1, e^{-\beta \Delta E}\}. \quad (12.10)$$

Konstantja e ndarjes nuk llogaritet: ky është një nga avantazhet kryesore të MCMC.

12.6.7 Zgjedhja e propozimit, pranimi dhe përzierja

Një hap shumë i vogël pranohet shpesh, por lëviz ngadalë; një hap shumë i madh refuzohet shpesh. Norma e pranimi nuk është objektivi i vetëm. Duhet parë largësia e përshkuar, autokorrelacioni dhe N_{eff} për koston llogaritëse. Propozimi duhet të ruajë mbështetjen e synuar dhe ta bëjë zinxhirin të pakthyeshëm e aperiodik.

Termalizimi hiqet vetëm pas kontrollit të trajektoreve nga gjendje të shpërndara. Pastaj maten observatlat në pjesën stacionare. Përfundimi shoqërohet me kohën e integruar të autokorrelacionit, madhësinë efektive dhe, kur është e mundur, krahasimin e shumë zinxhirëve.

12.6.8 Modeli Ising dydimensional

Në një rrjet katror me $N = L^2$ spine $s_i = \pm 1$ dhe kufij periodikë,

$$E = -J \sum_{\langle i, j \rangle} s_i s_j - H \sum_i s_i, \quad M = \sum_i s_i. \quad (12.11)$$

Çdo lidhje numërohet një herë. Kur përmbyset spini s_i , vetëm lidhjet lokale ndryshojnë dhe

$$\Delta E = 2s_i \left(J \sum_{j \in \text{fq}(i)} s_j + H \right). \quad (12.12)$$

Ky rezultat shmang rillogaritjen e energjisë së gjithë rrjetit dhe ul koston e një prove nga $\mathcal{O}(N)$ në $\mathcal{O}(1)$. Një kalim i plotë (*sweep*) përmban N prova, pra kushton $\mathcal{O}(N)$.

Observatlat termodinamike për spin janë

$$e = \frac{\langle E \rangle}{N}, \quad m = \frac{\langle |M| \rangle}{N}, \quad (12.13)$$

$$C_V = \frac{\beta^2}{N} (\langle E^2 \rangle - \langle E \rangle^2), \quad \chi = \frac{\beta}{N} (\langle M^2 \rangle - \langle M \rangle^2). \quad (12.14)$$

Përdorimi i $|M|$ në magnetizim shmang anulimin ndërmjet dy fazave të simetrisë në një rrjet të fundëm, por për susceptibilitetin duhet deklaruar qartë nëse përdoret M apo $|M|$.

12.6.9 Gabimet e matjeve të korreluara

Mesatarja e energjisë nuk ka gabim $s_E/\sqrt{N_{\text{matjeve}}}$ kur konfigurimet vijnë nga i njëjti zinxhir. Përdoret

$$\text{SE}(\bar{E}) = \sqrt{\frac{2\tau_{\text{int},E} \text{Var}(E)}{N_{\text{matjeve}}}}. \quad (12.15)$$

Për C_V dhe χ , që janë funksione jolineare të momenteve, bllokimi ose jackknife ruan korrelacionet dhe përhap pacaktueshmërinë. Madhësia e bllokut duhet të jetë dukshëm më e madhe se koha e autokorrelacionit; qëndrueshmëria e gabimit ndaj rritjes së bllokut është diagnostikë.

12.6.10 Ngadalësimi kritik dhe madhësia e fundme

Pranë temperaturës kritike, gjatësia e korrelacionit rritet dhe përditësimet lokale ndryshojnë vetëm ngadalë domenet e mëdha. Koha e autokorrelacionit rritet afërsisht si $\tau \sim L^z$. Ky ngadalësim kritik ul rëndë N_{eff} . Algoritmet e grupimeve Wolff ose Swendsen–Wang përmbysin rajone të korreluara dhe mund ta zvogëlojnë këtë efekt, por Metropolis-i mbetet themeli pedagogjik për balancën e detajuar.

Për rrjet të fundëm nuk ka singularitet të vërtetë. Kulmet e C_V dhe χ zhvendosen dhe mprehen me L . Prandaj një temperaturë kritike e vlerësuar nga një rrjet i vetëm është rezultat me efekt madhësie të fundme, jo kufiri termodinamik.

Listing 12.3: Një sweep Metropolis për modelin Ising.

```
import numpy as np

def sweep_metropolis(spin, beta, rng, J=1.0, H=0.0):
    L = spin.shape[0]
    for _ in range(L * L):
        i = rng.integers(L); j = rng.integers(L)
        fqinjet = (spin[(i+1) % L, j] + spin[(i-1) % L, j]
                  + spin[i, (j+1) % L] + spin[i, (j-1) % L])
        delta_E = 2.0 * spin[i, j] * (J * fqinjet + H)
        if delta_E <= 0.0 or rng.random() < np.exp(-beta * delta_E):
            spin[i, j] *= -1
    return spin
```

12.6.11 Protokoli i një studimi të riprodhueshëm

Një studim termik duhet të deklarojë L , J , H , temperaturat, farat, gjendjet fillestare, numrin e kalimeve të plota të termalizimit, numrin e matjeve dhe mënyrën e vlerësimit të autokorrelacionit. Duhet provuar energjia lokale ndaj rillogaritjes së plotë në rrjete të vogla, të krahasohen kufijtë $T \rightarrow 0$ dhe $T \rightarrow \infty$, dhe të kontrollohet simetria $M \leftrightarrow -M$ kur $H = 0$.

12.6.12 Përmbledhje dhe ushtrime

Metropolis–Hastings ndërton një dinamikë artificiale me shpërndarje stacionare të zgjedhur. Koha Monte Carlo nuk është domosdoshmërisht kohë fizike; interpretimi termodinamik vjen nga shpërndarja e ekuilibrit.

1. Provoni balancën e detajuar për raportin e përgjithshëm Hastings.
2. Nxirrni ΔE për përmbyshjen e një spini dhe kontrolloni numërimin e dyfishtë të lidhjeve.
3. Matni τ_{int} të energjisë dhe magnetizimit në disa temperatura.
4. Krahasoni nisjen e renditur dhe të çrregullt për të përcaktuar termalizimin.
5. Kryeni studim me disa L dhe diskutoni zhvendosjen e kulmit të susceptibilitetit.
6. Implementoni bllokimin ose jackknife për pacaktueshmërinë e kapacitetit termik.

12.6.13 Kufijtë analitikë të modelit Ising

Në temperaturë zero dhe $H = 0$, energjia minimizohet kur të gjitha spinet janë të njëjta. Në rrjetin katror çdo spin ka katër fqinjë, por çdo lidhje numërohet një herë; ka $2N$ lidhje. Prandaj energjia bazë është

$$E_0 = -2JN, \text{ qquad } e_0 = -2J. \quad (12.16)$$

Magnetizimi për spin ka modul një. Këto janë teste të drejtpërdrejta për kodin në temperaturë të ulët.

Në temperaturë të pafundme, konfigurimet janë të barasvlershme dhe spinet janë të pavarura me mesatare zero. Atëherë $\langle E \rangle \rightarrow 0$, $\langle M \rangle = 0$ dhe

$$\langle M^2 \rangle = N. \quad (12.17)$$

Prandaj $\langle M^2 \rangle / N^2 = 1/N$. Një simulim me temperaturë shumë të lartë duhet t'i afrohet këtyre kufijve. Për rrjete shumë të vogla, të gjitha 2^N konfigurimet mund të enumerohen dhe të japin vlera të sakta të funksionit të ndarjes; ky është testi më i fortë i algoritmit dhe i observablave.

Pranimi dhe bilanci energjetik lokal

Në $H = 0$, shuma e katër fqinjëve merr vlerat $-4, -2, 0, 2, 4$. Për rrjedhojë, ndryshimi i energjisë kufizohet në bashkësinë

$$\Delta E \in \{-8J, -4J, 0, 4J, 8J\}. \quad (12.18)$$

Faktorët $e^{-4\beta J}$ dhe $e^{-8\beta J}$ mund të parallogariten. Ky optimizim shmang eksponencialen në çdo provë dhe ruan saktësisht algoritmin.

Një matje e energjisë duhet të numërojë vetëm lidhjet djathtas dhe lart, ose të ndajë me dy shumën mbi të katër fqinjët. Gabimi i numërimit të dyfishtë ndryshon energjinë dhe temperaturën efektive. Testi lokal zgjedh një spin, llogarit energjinë e plotë para dhe pas përmbyshjes dhe kontrollon barazinë me formulën e ΔE për shumë konfigurime të rastit.

Kapaciteti termik, susceptibiliteti dhe kumulanti Binder

Derivimi i pritjes kanonike jep

$$\frac{\partial \langle E \rangle}{\partial \beta} = - \left(\langle E^2 \rangle - \langle E \rangle^2 \right). \quad (12.19)$$

Me $\beta = 1/(k_B T)$ merret formula e fluktuacioneve për C_V . Në mënyrë analoge, derivimi ndaj fushës jep susceptibilitetin nga fluktuacionet e magnetizimit. Këto marrëdhënie lidhin përgjigjen makroskopike me luhatjet mikroskopike.

Kumulanti Binder për magnetizimin është

$$U_L = 1 - \frac{\langle M^4 \rangle}{3 \langle M^2 \rangle^2}. \quad (12.20)$$

Në fazën e çrregullt Gauss, $U_L \rightarrow 0$; në një shpërndarje me dy maja të ngushta pranë $\pm M_0$, $U_L \rightarrow 2/3$. Kurbat për madhësi të ndryshme rrjeti priten pranë temperaturës kritike, duke dhënë një vlerësim më robust se maksimumi i një observable të vetëm.

Shkallëzimi me madhësinë e fundme

Pranë pikës kritike, gjatësia e korrelacionit sillet si $\xi \sim |t|^{-\nu}$, ku $t = (T - T_c)/T_c$. Në rrjet të fundëm, rritja ndalet kur $\xi \sim L$. Kjo çon në forma shkallëzimi, për shembull

$$m(T, L) = L^{-\beta_m/\nu} \mathcal{M}(tL^{1/\nu}), \quad (12.21)$$

ku β_m është eksponent kritik, jo inversi i temperaturës. Në T_c , grafiku log-log i m ndaj L ka pjerrësi $-\beta_m/\nu$.

Maksimumi i susceptibilitetit rritet afërsisht si $L^{\gamma/\nu}$ dhe temperatura e pseudokritike zhvendoset si $L^{-1/\nu}$. Një studim serioz përdor disa madhësi, interpolon observatlat me pacaktueshmëri dhe kontrollon shembjen e të dhënave. Një kurbë e vetme magnetizimi nuk mjafton për të përcaktuar tranzicionin.

Jackknife për madhësi jolineare

Le të ndahen matjet në B blloqe. Për çdo b llogaritet statistiku $\theta_{(b)}$ duke hequr bllokun b . Mesatarja jackknife është $\bar{\theta}_J = B^{-1} \sum_b \theta_{(b)}$ dhe varianca vlerësohet me

$$\widehat{\text{Var}}_J(\theta) = \frac{B-1}{B} \sum_{b=1}^B (\theta_{(b)} - \bar{\theta}_J)^2. \quad (12.22)$$

Kjo metodë përhap kovariancën ndërmjet $\langle E \rangle$ dhe $\langle E^2 \rangle$ në C_V , ose ndërmjet momenteve në kumulantin Binder. Blloqet duhet të jenë më të gjata se autokorrelacioni; përndryshe pseudo-mostrat nuk janë afërsisht të pavarura.

Krahasimi i algoritmeve

Kostoja nuk matet vetëm me kalime të plota. Krahasimi përdor kohën e procesorit për një mostër efektivisht të pavarur,

$$C_{\text{eff}} \propto C_{\text{sweep}} 2\tau_{\text{int}}. \quad (12.23)$$

Metropolis-i lokal ka kalim të plotë me kosto të ulët, por τ të madh pranë kritikës. Algoritmi Wolff ndërton një grup spinesh të lidhura dhe e përmbys; kostoja për hap ndryshon, por autokorrelacioni kritik zvogëlohet fort. Krahasimi duhet bërë për të njëjtin observable dhe të njëjtën madhësi rrjeti.

Koha Monte Carlo e këtyre algoritmeve nuk është dinamika reale e magnetit, përveç rasteve kur rregullat e përditësimit janë zgjedhur si model kinetik. Për observatlat e ekuilibrit mjafton shpërndarja stacionare; për koha relaksimi fizik nevojitet model dinamik me interpretim të veçantë.

Appendix A

Fjalorth, standarde të kodit dhe ura drejt notebook-eve

Kjo shtojcë standardizon gjuhën e përdorur në leksione dhe në laborator. Qëllimi është që termi fizik, simboli matematik dhe emri në kod të tregojnë të njëjtin koncept. Kur dokumentacioni i një biblioteke përdor termin anglisht, ai jepet në kllapa vetëm në paraqitjen e parë.

A.1 Fjalorth i termave kryesorë

Termi në shqip	Termi ndërkombëtar	Kuptimi në këtë tekst
algoritëm	algorithm	Varg i fundmë hapash që prodhon një rezultat nga hyrjet.
zbatim	implementation	Realizimi i algoritmit në një gjuhë programimi.
rrjetë	grid, mesh	Bashkësia diskrete e pikave në kohë ose hapësirë.
hap	step size	Largësia h , Δt ose Δx ndërmjet pikave të rrjetës.
gabim absolut	absolute error	$ \tilde{x} - x $.
gabim relativ	relative error	$ \tilde{x} - x / x $, kur emëruesi është i përshtatshëm.
gabim i përparmë	forward error	Gabimi në rezultatin e llogaritur.
gabim i prapëm	backward error	Perturbimi minimal i të dhënave që e bën rezultatin të saktë.
gabim i këputjes	truncation error	Gabimi nga zëvendësimi i një procesi të pafundëm me formulë të fundme.
gabim rrumbullakimi	round-off error	Gabimi nga paraqitja dhe veprimet me saktësi të fundme.
kushtëzim	conditioning	Ndjeshmëria e problemit ndaj perturbimeve të hyrjeve.
qëndrueshmëri	stability	Kontrolli i përhapjes së gabimeve nga algoritmi.
pajtueshmëri	consistency	Përafrimi i formulës diskrete me ekuacionin kur hapi shkon në zero.
konvergjencë	convergence	Përafrimi i zgjidhjes numerike me zgjidhjen e problemit.
mbetje	residual	Diferenca që mbetet kur përafrimi zëvendësohet në ekuacion.
tolerancë	tolerance	Prag numerik për ndalim ose pranim.
metodë e shtjelluar	explicit method	Hapi i ri llogaritet drejtpërdrejt nga vlerat e njohura.
metodë e pashtjelluar	implicit method	Hapi i ri gjendet duke zgjidhur një ekuacion.
problem i vlerës fillestare	initial-value problem	Kushti jepet në kohën fillestare.
problem i vlerave kufitare	boundary-value problem	Kushtet jepen në kufij të ndryshëm të domenit.
përshtatje	fitting	Përcaktimi i parametrave të modelit nga të dhënat.

Termi në shqip	Termi ndërkombëtar	Kuptimi në këtë tekst
mбетje e regresit rizgjedhje	regression residual resampling	$r_i = y_i - \hat{y}_i$. Ndërtimi i mostrave të reja nga të dhënat ekzistuese.
ndryshore rasti mostër kampionim	random variable sample sampling	Funksion numerik mbi hapësirën e rezultateve. Bashkësi realizimesh të një ndryshoreje rasti. Procedura e gjenerimit ose përzgjedhjes së mostrave.
vlerësues	estimator	Rregull që i shoqëron mostrës një vlerë për parametrin.
vlerësim gabim standard interval besimi	estimate standard error confidence interval	Vlera konkrete e prodhuar nga vlerësuesi. Devijimi standard i shpërndarjes së vlerësuesit. Procedurë intervalore me mbulim të përcaktuar në përsëritje.
pacaktueshmëri	uncertainty	Diapazoni i arsyeshëm i vlerave për shkak të informacionit të kufizuar.
luhatje gjenerator pseudorastësor	fluctuation pseudorandom genera- tor	Variacion fizik ose statistik i observablit. Algoritëm determinist që prodhon varg me veti të kërkuara statistike.
farë	seed	Gjendje fillestare që identifikon një varg pseudo-rastësor.
kampionim i rëndësisë	importance sampling	Kampionim nga një propozim dhe korrigjim me pesha.
variabël kontrollues	control variate	Madhësi me pritje të njohur që ul variancën e vlerësuesit.
bredhje e rastit zinxhir Markov	random walk Markov chain	Proces i ndërtuar nga hapa të rastit. Proces ku kalimi i ardhshëm varet nga gjendja e tanishme.
shpërndarje stacionare	stationary distribution	Shpërndarje që nuk ndryshon nën operatorin e kalimit.
balancë e detajuar	detailed balance	Barazi e flukseve probabilitare ndërmjet çifteve të gjendjeve.
përzierje termalizim	mixing thermalization	Humbja e varësisë nga gjendja fillestare. Përafrimi i simulimit të fizikës statistike drejt ekuilibrit.
kohë autokorrelacioni madhësi efektive e mostrës	autocorrelation time effective sample size	Shkalla e varësisë ndërmjet mostrave të zinxhirit. Numri i përafërt i mostrave të pavarura me të njëjtën saktësi.
ngadalësim kritik	critical slowing down	Rritja e kohës së korrelacionit pranë tranzicionit kritik.
observabël	observable	Madhësi e matshme e llogaritur nga gjendja e sistemit.
vleftësim	validation	Kontrolli i përshtatshmërisë së modelit ndaj dukurisë reale.
verifikim	verification	Kontrolli nëse ekuacionet e zgjedhura zgjidhen saktë.
riprodhueshmëri	reproducibility	Mundësia për të marrë të njëjtin rezultat me të njëjtat të dhëna dhe procedurë.

A.2 Emërtimi i madhësive në kod

Emrat duhet të jenë të shkurtër, por jo të paqartë. Simbolet standarde mund të ruhen kur konteksti është i qartë: `dt`, `dx`, `beta`, `omega`. Për madhësi të përpunuara përdoren emra përshkrues: `gabimi_relative`, `energji_totale`, `koha_autokorrelacionit`. Njësia jepet në docstring ose në emër kur rreziku i ngatërimit është i madh.

Listing A.1: Funksion me kontratë të qartë numerike.

```
def shpejtesia_terminale(masa_kg: float,
                        g_ms2: float,
                        koeficienti_kg_s: float) -> float:
    """Kthen shpejtesine terminale [m/s] per rezistence lineare."""
    if masa_kg <= 0 or koeficienti_kg_s <= 0:
        raise ValueError("Masa dhe koeficienti duhet te jene pozitivë.")
    return masa_kg * g_ms2 / koeficienti_kg_s
```

A.3 Struktura standarde e çdo notebook-u

Çdo notebook i kursit duhet të ketë të njëjtën skelet pedagogjik. Kjo lejon që studenti të përqendrohet te fizika dhe metoda, jo te gjetja e strukturës së raportit.

1. **Titulli dhe pyetja fizike.** Një fjali që mund të marrë përgjigje numerike.
2. **Rezultatet e të nxënit.** Tre deri pesë aftësi të verifikueshme.
3. **Modeli.** Ekuacionet, supozimet, njësitë dhe domeni i vlefshmërisë.
4. **Algoritmi.** Hapat, rendi, stabiliteti, kostoja dhe kriteri i ndalimit.
5. **Zbatimi.** Funksione të vogla, parametra të përqendruar dhe komente për arsyen, jo për sintaksën e dukshme.
6. **Verifikimi.** Rast analitik, ligj ruajtjeje, mbetje ose provë konvergjence.
7. **Eksperimenti.** Ndryshohet një faktor në çdo seri; ruhen të dhënat e papërpunuara.
8. **Analiza.** Figura me njësi, tabela, gabim numerik dhe pacaktueshmëri.
9. **Interpretimi.** Përgjigjja fizike dhe kufijtë e saj.
10. **Detyra.** Ndryshim modeli, metode ose të dhënash që kërkon arsyetim të ri.

A.4 Kontrollat minimale të cilësisë

Kontrolli	Pyetjet që duhet të marrin përgjigje
Fizika	A janë njësitë të pajtueshme? A respektohen kufijtë dhe shenjat?
Matematika	A ekziston dhe është unike zgjidhja? A është problemi i mirëkushtëzuar?
Algoritmi	Cili është rendi? Cili është kushti i stabilitetit? Sa kushton në kohë dhe memorie?
Kodi	A testohen hyrjet? A shmangen inverset e panevojshme? A është fara e kontrolluar?
Konvergjencia	A ndryshon rezultati siç pritet kur përgjysmohet hapi ose rritet N ?
Statistika	A janë mostrat të pavarura? A raportohet gabimi standard ose N_{eff} ?
Figura	A kanë boshtet emra dhe njësi? A dallohen të dhënat nga modeli?
Raportimi	A përmenden supozimet, tolerancat, versionet dhe kufijtë e përfundimit?

A.5 Lidhja ndërmjet kapitujve dhe laboratorëve

Nr.	Boshti i leksionit	Produkti minimal i notebook-ut
1	Programimi shkencor	Funksione, figura me njësi, test fillestar dhe raport i shkurtër.

Nr.	Boshti i leksionit	Produkti minimal i notebook-ut
2	Gabimet dhe kushtëzimi	Grafik gabimi–hap dhe sistem me $\kappa(A)$ të ndryshueshme.
3	Rrënjët, sistemet, modet	Krahasim konvergjence dhe mode normale masë–sustë.
4	Interpolimi dhe regresi	Ligji i Keplerit, mbetje dhe pacaktueshmëri parametrash.
5	Derivatet dhe integralet	Perioda e lavjerrësit dhe studim konvergjence.
6	Ekuacionet diferenciale	Rënie, lavjerrës dhe orbitë me kontrolle energjie.
7	Valët	Puls, valë e qëndrueshme, CFL dhe reflektim nga plazma.
8	Probabiliteti	Hedhje monedhe, interval besimi dhe CLT empirike.
9	Kampionimi	Gjenerim shpërndarjesh dhe teste të CDF-së e korrelacionit.
10	Integrimi Monte Carlo	Integral shumëpërmasor, $N^{-1/2}$ dhe zbritje me pacaktueshmëri.
11	Bredhjet dhe Markov	Difuzion, kohë e parë kalimi dhe N_{eff} .
12	Metropolis dhe Ising	Termalizim, autokorrelacion, magnetizim dhe efekte të përmasës.

A.6 Parimi i kalimit nga notebook-u te paketa

Në fillim funksionet shkruhen pranë shpjegimit. Kur përdoren në dy ose më shumë notebook-e, ato zhvendosen në modul. Paketa përfundimtare duhet të ketë ndarje ndërmjet modelit, algoritmeve, analizës dhe paraqitjes. Testet ruhen veçmas dhe ekzekutohen pa hapur notebook-un.

Listing A.2: Struktura e rekomanduar e paketës së studentit.

```
projekti/
|-- pyproject.toml
|-- README.md
|-- src/simulim_fizik/
| |-- modele.py
| |-- algoritme.py
| |-- statistike.py
| '-- vizualizim.py
|-- notebooks/
| |-- 01_verifikimi.ipynb
| '-- 02_eksperimenti.ipynb
|-- tests/
| |-- test_modele.py
| '-- test_algoritme.py
'-- results/
```

Kjo strukturë ruan parimin e kursit pararendës: notebook-u për kuptim dhe komunikim; paketa për ripërdorim, testim dhe zgjerim.

A.7 Udhëzues i burimeve shkencore në shqip

Literatura universitare në shqip përdoret në këtë tekst për tri qëllime: për terminologjinë, për rendin didaktik të analizës numerike dhe për shembujt që janë familjarë në programet shqiptare. Ajo plotësohet me literaturë ndërkombëtare kur kërkohen algoritme moderne, analiza të hollësishme të qëndrueshmërisë ose metoda Monte Carlo të avancuara.

A.7.1 Analiza numerike me MATLAB

Teksti i L. Hanellit dhe F. Osmanit [1] është burim qendror për trajtimin në shqip të gabimeve, ekuacioneve jolineare, sistemeve lineare, interpolimit, kuadraturës, ekuacioneve diferenciale dhe problemeve të vlerave vetjake. Në këto leksione ruhet ndarja e qartë ndërmjet problemit matematik, metodës dhe zbatimit, por shembujt e kodit janë përditësuar kryesisht në Python dhe lidhen me eksperimente fizike.

A.7.2 Metoda të Analizës Numerike

Teksti i F. Hoxhës [2] përdoret për përkufizimet, rendin e temave dhe emërtimet tradicionale shqip. Veçanërisht të dobishme janë dallimet ndërmjet gabimit, kushtëzimit, qëndrueshmërisë dhe konvergjencës. Në leksione këto koncepte shoqërohen me eksperimente kompjuterike, sepse studenti duhet t'i shohë si sjellje të matshme dhe jo vetëm si përkufizime.

A.7.3 Leksionet e Universitetit Politeknik të Tiranës

Materialet e R. Datjës [3] japin një urë të vlefshme ndërmjet analizës numerike, MATLAB-it dhe programeve inxhinierike. Ato janë përdorur për të kontrolluar terminologjinë e metodave të rrënjëve, interpolimit, kuadraturës dhe vlerave vetjake. Në këtë tekst ruhet lidhja me MATLAB/Octave, edhe kur snippet-i kryesor jepet në Python.

A.7.4 Ekuacionet diferenciale dhe qëndrueshmëria

Disertacioni dhe punimet e E. Dishmemës [4, 5] përmbajnë një trajtim të gjerë në shqip të metodave me një hap, gabimit lokal e global, pajtueshmërisë, konvergjencës dhe qëndrueshmërisë. Ky burim ka ndihmuar veçanërisht në përdorimin e termave *metodë e shtjelluar* dhe *metodë e pashtjelluar*. Leksionet tona fokusohen te ekuacionet e zakonshme pa vonesë, por parimet numerike janë të përbashkëta.

A.7.5 Problemet kufitare dhe ekuacionet me derivate të pjesshme

Puna e A. Naços [6] dhe materialet shqiptare të analizës numerike shërbejnë si pikë reference për problemet kufitare. Për valët, diferencat e fundme dhe kushtin CFL, këto burime plotësohen me tekstet e fizikës llogaritëse, sepse interpretimi fizik i dispersimit dhe reflektimit është po aq i rëndësishëm sa skema numerike.

A.7.6 Probabiliteti, rizgjedhja dhe analiza e të dhënave

Materialet e probabilitetit dhe statistikës [9], si edhe disertacionet mbi bootstrap-in dhe vlerat e humbura [7, 8], ndihmojnë në standardizimin e termave *mostër*, *vlerësues*, *rizgjedhje*, *gabim standard* dhe *interval besimi*. Këto koncepte janë themelore për Monte Carlo-n, edhe kur objektivi përfundimtar është një integral ose një observabël termodinamik.

A.7.7 Monte Carlo dhe fizika statistike

Burimet e plota në shqip për MCMC dhe modelin Ising janë më të pakta. Për këtë arsye, terminologjia probabilitare lidhet me burimet shqiptare, ndërsa hollësitë algoritmike mbështeten te Metropolis et al., Hastings, Krauth dhe Robert–Casella [20, 21, 18, 19]. Ky kombinim shmang dy rreziqe: përkthimin mekanik të termave dhe thjeshtimin e tepërt të teorisë.

A.8 Rruga e rekomanduar e leximit

Nevoja e studentit	Kapitujt e këtij teksti	Burimet plotësuese
Bazat e gabimit dhe algoritmit	1–2	Hanelli–Osmani; Hoxha; Higham
Rrënjë dhe sisteme	3	Hanelli–Osmani; Datja; Burden–Faires
Vlera vetjake dhe mode	3	Datja; Newman; Landau et al.
Interpolim dhe përshatje	4	Hanelli–Osmani; Hoxha; Press et al.
Derivim dhe kuadraturë	5	Hoxha; Datja; Newman
Ekuacione diferenciale	6	Dishmema; Hanelli–Osmani; Giordano–Nakanishi
Valë dhe diferenca të fundme	7	Naço; Giordano–Nakanishi; Landau et al.
Probabilitet dhe pacaktueshmëri	8	Çapollari et al.; Butka; Tasho Milo
Gjeneratorë dhe kam pionim	9	Press et al.; Robert–Casella
Integrim Monte Carlo	10	Newman; Press et al.; Robert–Casella
Bredhje dhe Markov	11	Newman; Krauth; Robert–Casella
Metropolis dhe Ising	12	Metropolis et al.; Hastings; Krauth

A.9 Parime për citimin në notebook

Kur një formulë, algoritëm ose grup të dhënash merret nga një burim, notebook-u duhet të japë autorin, titullin dhe vendin e saktë ku është përdorur. Dokumentacioni i NumPy, SciPy ose MATLAB citohet për sjelljen e funksionit të gatshëm; ai nuk zëvendëson burimin shkencor të metodës. Për figurat e prodhuara nga kodi i studentit shënohet “llogaritje e autorit” dhe ruhen skripti, parametrat dhe të dhënat që e gjeneruan.

Një listë e gjatë referencash nuk garanton cilësi. Çdo citim duhet të ketë rol të qartë: përkufizim, metodë, të dhëna, krahasim ose interpretim. Burimet në shqip ndihmojnë terminologjinë dhe vazhdimësinë akademike; burimet ndërkombëtare sigurojnë mbulimin e zhvillimeve dhe standardeve të fushës.

Përfundime

Metodat numerike dhe Monte Carlo nuk janë vetëm teknika llogaritëse. Ato janë mënyra për të ndërtuar argumente shkencore kur zgjidhja analitike mungon, të dhënat kanë pacaktueshmëri ose hapësira e gjendjeve është shumë e madhe. Një simulim bindës bashkon modelin fizik, analizën e gabimit, kontrollin e kodit, eksperimentin numerik dhe interpretimin e matur.

Literatura

- [1] L. Hanelli dhe F. Osmani, *Analiza numerike me MATLAB*, Pegi, Tiranë, 2013.
- [2] F. Hoxha, *Metoda të Analizës Numerike*, Tiranë, 2008.
- [3] R. Datja, *Analizë Numerike: leksione dhe seminare të shkruara për Inxhinieri Elektronike dhe Mekatronikë*, Universiteti Politeknik i Tiranës, 2022–2023.
- [4] E. Dishmema, *Metoda numerike për ekuacionet diferenciale me vonesa*, disertacion, Fakulteti i Shkencave të Natyrës, Universiteti i Tiranës, 2020.
- [5] E. Dishmema et al., “Krahasim i strategjive numerike për problemin e vlerës fillestare të ekuacioneve diferenciale të zakonshme dhe me vonesa”, *Buletini i Shkencave të Natyrës*, Universiteti i Tiranës.
- [6] A. Naço, *Analizë krahasuese e metodave për zgjidhjen e problemit kufitar*, punim në Analizë Numerike, Universiteti Politeknik i Tiranës.
- [7] A. Butka, *Metoda bootstrap tek modelet e serive kohore, në veçanti tek modelet ARFIMA*, disertacion, Fakulteti i Shkencave të Natyrës, Universiteti i Tiranës.
- [8] E. Tasho Milo, *Vlerat e humbura me metodat e rizgjedhjes*, disertacion, Programi Metodat Probabilitare, Statistike dhe Metodat e Analizës Numerike, Universiteti i Tiranës, 2019.
- [9] Gj. Çapollari dhe bashkautorë, *Ushtrime probabiliteti dhe statistike*, material universitar, Tiranë, 2007.
- [10] A. Zeqiri et al., punim mbi algjibrën lineare numerike dhe metodat iterative, *Buletini i Shkencave të Natyrës*, Universiteti i Tiranës, 29, 2020.
- [11] N. Hyka, materiale mësimore dhe trajnuese mbi metodat Monte Carlo dhe analizën e të dhënave, Universiteti i Mjekësisë, Tiranë.
- [12] M. Newman, *Computational Physics*, CreateSpace, 2012.
- [13] N. J. Giordano dhe H. Nakanishi, *Computational Physics*, Pearson, 2005.
- [14] W. H. Press et al., *Numerical Recipes*, 3rd ed., Cambridge University Press, 2007.
- [15] R. L. Burden dhe J. D. Faires, *Numerical Analysis*, 9th ed., Brooks/Cole, 2011.
- [16] N. J. Higham, *Accuracy and Stability of Numerical Algorithms*, 2nd ed., SIAM, 2002.
- [17] R. H. Landau, M. J. Páez dhe C. C. Bordeianu, *Computational Physics*, 3rd ed., Wiley-VCH, 2015.
- [18] W. Krauth, *Statistical Mechanics: Algorithms and Computations*, Oxford University Press, 2006.
- [19] C. P. Robert dhe G. Casella, *Monte Carlo Statistical Methods*, 2nd ed., Springer, 2004.

- [20] N. Metropolis et al., “Equation of State Calculations by Fast Computing Machines”, *J. Chem. Phys.* 21, 1087–1092, 1953.
- [21] W. K. Hastings, “Monte Carlo Sampling Methods Using Markov Chains and Their Applications”, *Biometrika* 57, 97–109, 1970.
- [22] J.-C. Walter dhe G. T. Barkema, “An Introduction to Monte Carlo Methods”, arXiv:1404.0209, 2014.